心於至善

SOUTHEAST UNIVERSITY

基于内部表征的大语言模型幻觉检测方法研究

曾晗

东南大学

学校代码: 10286

分 类 号: TP183

密 级: 公开

U D C: 004.8

学 号: 232218

東南大學

SOUTHEAST UNIVERSITY

硕士学位论文

基于内部表征的大语言模型幻觉检测方法研究

研究生姓名: 曾晗

导 师 姓 名: 魏通

申请学位类别 工学硕士　　学位授予单位 东南大学

一级学科名称 计算机科学与技术　　论文答辩日期 2026 年 月 日

二级学科名称 _____　　学位授予日期 2026 年 月 日

答辩委员会主席 _____　　评 阅 人 _____

_____

2026 年 4 月 1 日

学校代码: 10286
分 类 号: TP183
密 级: 公开
U D C: 004.8
学 号: 232218

東南大學

SOUTHEAST UNIVERSITY

硕士学位论文

基于内部表征的大语言模型幻觉检测方法研究

研究生姓名: 曾晗

导 师 姓 名: 魏通

申请学位类别 工学硕士　　学位授予单位 东南大学

一级学科名称 计算机科学与技术　　论文答辩日期 2026 年 月 日

二级学科名称 _____　　学位授予日期 2026 年 月 日

答辩委员会主席 _____　　评 阅 人 _____

_____

2026 年 4 月 1 日

東南大學

硕士学位论文

基于内部表征的大语言模型幻觉检测方法研究

专 业 名 称: 计算机科学与技术

研究生姓名: 曾 晗

导 师 姓 名: 魏 通

RESEARCH ON INTERNAL-REPRESENTATION-BASED HALLUCINATION DETECTION METHODS FOR LARGE LANGUAGE MODELS

A Thesis Submitted to

Southeast University

For the Academic Degree of Master of Engineering

BY

ZENG Han

Supervised by

Associate Professor WEI Tong

School of Computer Science and Engineering

Southeast University

April 2026

东南大学学位论文独创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

研究生签名：_____ 日 期：_____

东南大学学位论文使用授权声明

东南大学、中国科学技术信息研究所、国家图书馆、《中国学术期刊（光盘版）》电子杂志社有限公司、万方数据电子出版社、北京万方数据股份有限公司有权保留本人所送交学位论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括以电子信息形式刊登）论文的全部内容或中、英文摘要等部分内容。论文的公布（包括以电子信息形式刊登）授权东南大学研究生院办理。

研究生签名：_____ 导师签名：_____ 日 期：_____

摘　要

近年来，大语言模型在问答、生成与检索等任务中表现出较强能力，但仍容易产生与事实不符、逻辑错误或缺乏依据的幻觉内容，影响系统的可靠性与安全性。检索增强生成（Retrieval-Augmented Generation, RAG）框架通过引入外部检索知识源，增强了模型的生成能力，一定程度上缓解了幻觉问题；但其并未能根除幻觉，模型仍有可能输出与检索知识不一致的内容。幻觉检测任务旨在有效识别和检测大语言模型生成的幻觉内容，其现有方法主要分为基于输出信息的黑盒方法和基于内部表征的白盒方法。现有方法虽已取得一定进展，但仍存在两方面不足：其一，在通用幻觉检测领域中，对内部表征信息利用不充分，常局限于单层、单 token 或静态表示；其二，在 RAG 幻觉检测领域中，对外部检索知识信号利用不足，难以有效刻画模型内部与外部检索知识之间的冲突关系。

针对通用幻觉检测任务，本文提出 ATScore，一种基于多方向表征建模的幻觉检测方法。该方法从大语言模型生成过程中的隐藏状态出发，构建统一的三维激活张量表示，并分别沿层方向与 token 两个方向进行链式表征建模，通过提取链长度、转折角度等几何统计特征，构造无需额外训练的白盒幻觉检测信号。相较于现有多数仅沿单一方向建模、仅利用局部表征的方法，ATScore 能够在统一视角下更充分地利用跨层与跨 token 信息，挖掘内部表征演化过程中与幻觉相关的异常模式。实验结果表明，ATScore 在多个公开数据集和多种评价指标上均取得了良好的检测效果，整体优于多种黑盒与白盒基线方法，表现出较好的稳定性、跨数据集泛化能力和跨场景适用性。

针对 RAG 幻觉检测任务，本文进一步提出 SKID，一种基于检索知识冲突消解的幻觉检测方法。该方法首先利用稀疏自编码器将隐藏状态映射到高维稀疏特征空间，以获得更具语义可解释性的稀疏表征；随后通过互信息筛选出与幻觉判别最相关的特征维度，并结合检索文档对输出 token 进行过滤，重点关注未被外部知识直接支持的生成片段，以更直接地刻画并消解模型内部知识与外部检索知识之间的潜在冲突；最后采用广义加性模型实现对 RAG 幻觉的有效检测。实验结果表明，SKID 在多个 RAG 数据集和多种评价指标上均具有较强竞争力，整体优于多类基线方法。进一步分析还表明，SKID 不仅能够提升 RAG 幻觉检测性能，还能够通过稀疏特征的语义归纳解释模型被判定为幻觉的原因，从而兼顾检测准确性与结果可解释性。

关键词： 大语言模型，幻觉检测，内部表征，检索增强生成，稀疏自编码器

Abstract

In recent years, large language models have demonstrated strong capabilities in tasks such as question answering, text generation, and retrieval, yet they still tend to produce hallucinated content that is factually incorrect, logically flawed, or unsupported by evidence, thereby undermining the reliability and safety of such systems. The Retrieval-Augmented Generation (RAG) framework enhances model generation by introducing external retrieved knowledge sources and alleviates hallucination to some extent; however, it does not eliminate hallucinations entirely, and models may still generate content inconsistent with retrieved knowledge. The goal of hallucination detection is to effectively identify hallucinated content generated by large language models. Existing methods can be broadly categorized into black-box methods based on output information and white-box methods based on internal representations. Although existing studies have achieved some progress, they still suffer from two major limitations. First, in general hallucination detection, internal representation information is not fully exploited, and existing methods are often restricted to single-layer, single-token, or static representations. Second, in RAG hallucination detection, external retrieved knowledge signals are insufficiently utilized, making it difficult to effectively characterize the conflict between the model’s internal knowledge and external retrieved knowledge.

For the task of general hallucination detection, this thesis proposes ATScore, a hallucination detection method based on multi-directional representation modeling. Starting from the hidden states generated during the inference process of large language models, this method constructs a unified three-dimensional activation tensor representation, and further performs chain-based representation modeling along both the layer direction and the token direction. By extracting geometric statistical features such as chain length and turning angle, it constructs a white-box hallucination detection signal without requiring additional training. Compared with existing methods that mostly model representations along only a single direction and rely only on local representations, ATScore can make more sufficient use of cross-layer and cross-token information under a unified perspective, thereby capturing anomalous patterns related to hallucinations during the evolution of internal representations. Experimental results show that ATScore achieves strong detection performance on multiple public datasets and evaluation metrics, overall outperforming a variety of black-box and white-box baselines, and demonstrating good stability, cross-dataset generalization ability, and cross-scenario applicability.

For the task of RAG hallucination detection, this thesis further proposes SKID, a hallucination detection method based on retrieved knowledge conflict resolution. This method first

maps hidden states into a high-dimensional sparse feature space by using a sparse autoencoder, so as to obtain sparse representations with better semantic interpretability. It then selects the feature dimensions most relevant to hallucination discrimination through mutual information, and filters output tokens in conjunction with retrieved documents, focusing on generated fragments that are not directly supported by external knowledge, so as to more directly characterize and resolve the potential conflict between the model’s internal knowledge and external retrieved knowledge. Finally, a generalized additive model is adopted to achieve effective RAG hallucination detection. Experimental results show that SKID is highly competitive on multiple RAG datasets and evaluation metrics, and overall outperforms various baseline methods. Further analysis also shows that SKID can not only improve the performance of RAG hallucination detection, but also explain why the model is judged as hallucinating through semantic induction over sparse features, thereby balancing detection accuracy and result interpretability.

Keywords: Large Language Models, Hallucination Detection, Internal Representations, Retrieval-Augmented Generation, Sparse Autoencoder

目　录

摘　要 I

Abstract III

插图目录 VII

表格目录 IX

算法目录 XI

第一章　绪论 1
- 1.1　研究背景及意义 1
- 1.2　研究现状及挑战 3
  - 1.2.1　通用幻觉检测 3
  - 1.2.2　RAG 幻觉检测 6
  - 1.2.3　现有方法的不足 8
- 1.3　本文研究内容 9
- 1.4　本文组织结构 10

第二章　相关工作 13
- 2.1　基础概念与技术 13
  - 2.1.1　大语言模型基础 13
  - 2.1.2　检索增强生成基本流程 14
  - 2.1.3　稀疏自编码器基础 16
- 2.2　白盒幻觉检测 17
  - 2.2.1　无需额外训练的方法 17
  - 2.2.2　需要额外训练的方法 19
- 2.3　RAG 幻觉检测 21
- 2.4　知识冲突消解 24
- 2.5　本章小结 27

第三章　基于多方向表征建模的幻觉检测方法 29
- 3.1　问题设定 29
- 3.2　ATScore 算法 30

3.2.1 三维内部表征建模 30
3.2.2 多方向链式表征建模 31
3.3 实验分析 35
3.3.1 实验设置 35
3.3.2 结果分析 40
3.3.3 消融实验 45
3.4 本章小结 47

第四章 基于检索知识冲突消解的幻觉检测方法 49
4.1 问题设定 49
4.2 SKID 算法 51
4.2.1 稀疏表征提取 51
4.2.2 知识冲突消解 52
4.2.3 幻觉指标构建 54
4.3 实验分析 57
4.3.1 实验设置 57
4.3.2 结果分析 60
4.3.3 消融实验 61
4.4 本章小结 68

第五章 总结与展望 69
5.1 本文总结 69
5.2 未来展望 70

致 谢 73

参考文献 75

插图目录

1-1 本文讨论的两类幻觉检测任务示例图 2
1-2 本文组织结构图 11

2-1 大语言模型架构图 15
2-2 INSIDE 方法框架图 18
2-3 ACT-ViT 方法框架图 21

3-1 ATScore 算法框架图 31
3-2 ATScore 和对比方法在 GSM8K（MGSM）上的幻觉分数分布 44
3-3 ATScore 和对比方法在 CommonsenseQA 上的幻觉分数分布 45

4-1 SKID 算法框架图 51
4-2 SKID 与 RAGLens 在 AggreFact 与 Dolly 数据集上的幻觉分数分布 62
4-3 SKID 与对比算法在 RAGTruth 数据集上的 AUROC 性能随 k 值变化图 . . 64

表格目录

3.1 ATScore 实验数据集概览 38
3.2 ATScore 在 GSM8K（MGSM）数据集上的实验结果（模型幻觉率：17.6%） 41
3.3 ATScore 在 CommonenseQA 数据集上的实验结果（模型幻觉率：27.1%） 41
3.4 ATScore 在 Belebele 数据集上的实验结果（模型幻觉率：11.6%） 42
3.5 ATScore 在 TheoremQA 数据集上的实验结果（模型幻觉率：83.2%） . . . 42
3.6 ATScore 在 TruthfulQA 数据集上的实验结果（模型幻觉率：65.2%） . . . 43
3.7 ATScore 在 GSM8K（MGSM）数据集上不同辅助方向聚合方式的性能 . . 46
3.8 ATScore 在 TruthfulQA 数据集上不同辅助方向聚合方式的性能 46
3.9 ATScore 在 TruthfulQA 数据集上基于不同判定幻觉标签方法的性能 47

4.1 SKID 实验数据集概览 58
4.2 SKID 在 RAGTruth 与 Dolly 数据集上的实验结果 60
4.3 SKID 在更多评价指标与数据集上的实验结果 62
4.4 SKID 在 RAGTruth 的三个子数据集上的实验结果 63
4.5 SKID 的不同模块变体在 TofuEval 数据集上的实验结果 65
4.6 SKID 在 TofuEval 上的可解释性分析 67

算法目录

2.1 检索增强生成（RAG）基本流程 15
3.1 ATScore 算法 36
4.1 SKID 算法（训练阶段） 56
4.2 SKID 算法（测试阶段） 56

第一章 绪论

1.1 研究背景及意义

近年以来，以大语言模型（Large Language Models, LLMs）[1–3] 为代表的生成式人工智能技术取得了突破性进展。得益于海量语料训练与大规模参数建模能力，LLM 在自然语言理解与生成任务中展现出了卓越的性能，在机器翻译、智能问答、文本摘要、代码生成以及对话系统等多个领域取得了广泛应用。以 GPT[4–7]、LLaMA[8–10]、Qwen[11,12] 等模型为代表的大语言模型已经逐渐成为智能信息处理系统的重要基础设施，并被广泛集成于搜索引擎、智能助手、教育辅助、医疗咨询以及知识管理等实际应用场景中。

尽管大语言模型在生成能力和语言理解能力方面取得了显著进展，但其在生成过程中仍然存在一个重要问题，即“幻觉”（Hallucination）[13–15]。所谓幻觉，是指模型在生成文本时产生与事实不符、逻辑错误或缺乏依据的内容。例如，模型可能生成不存在的参考文献、错误的事实描述、虚构的实体关系，甚至给出看似合理但实际上并不正确的推理结论。由于大语言模型本质上是基于概率分布采样进行文本生成的，其生成过程并不直接依赖真实世界知识验证，因此在缺乏可靠约束的情况下容易产生此类错误信息。

幻觉问题在实际应用中可能带来严重影响。在智能问答系统中，幻觉可能导致错误信息的传播；在医疗、法律、自动驾驶等高风险领域，错误的生成内容甚至可能造成决策风险；在知识检索与信息整合任务中，虚构事实或错误引用也会严重降低系统的可信度。因此，如图 1-1 左半部分所示，幻觉检测（Hallucination Detection）[16] 这一研究领域应运而生，旨在有效识别和检测大语言模型生成过程中的幻觉内容，并已经成为当前大模型安全性与可靠性研究中的关键问题之一。近年来，研究者提出了多种幻觉检测与评估方法，试图从不同角度识别模型生成结果的真实性与可靠性，从而提高大语言模型在实际应用中的可信度。

为了缓解大语言模型中由于知识不完整或事实不准确所带来的幻觉问题，研究者提出了检索增强生成（Retrieval-Augmented Generation, RAG）[17–19] 框架。RAG 通过在输入端或生成过程中引入外部知识检索机制，使模型能够结合实时或高质量的知识库信息进行文本生成，从而大幅提高生成内容的事实准确性和可解释性。然而，在实际应用中，受限于大模型本质的输出概率采样机制，RAG 系统仍然难以完全避免幻觉现象。当模型内部知识与检索得到的外部知识之间存在冲突时，即便提供有给定的检索知识上下文，模型也可能忽略检索到的证据，依然依据自身参数化知识生成内容，从而产生与检索知识不一致的结果。因此，即便在引入外部知识的情况下，RAG 系统仍可能出现幻觉问题，这一新的幻觉形式通常被称为 RAG 幻觉或检索增强生成幻觉（RAG Hallucination），如图 1-1 右半部分所示。

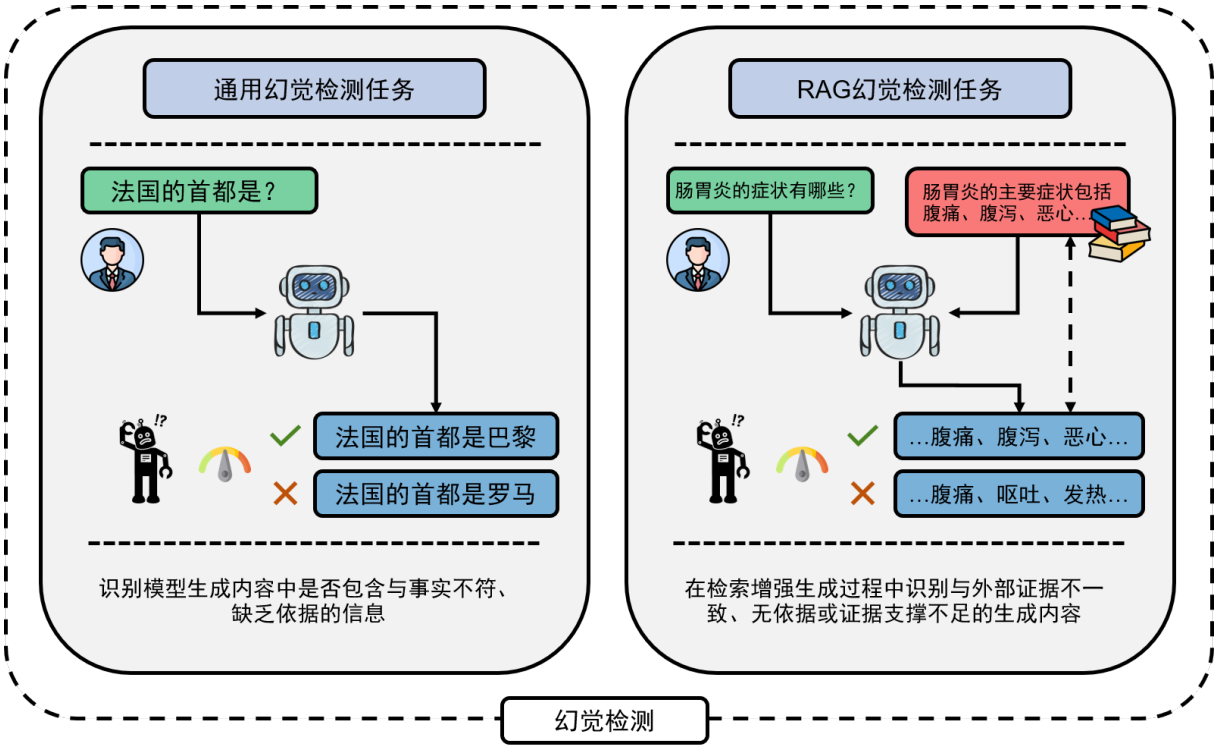

图 1-1 本文讨论的两类幻觉检测任务示例图

一类简单的幻觉检测方法是依赖于生成不确定性、自一致性分析的黑盒方法。此类方法简单易用，具有较好的模型通用性，但往往只能利用有限的输出信息，对模型内部表征的利用较为有限；并因常需要采样多次输出，通常有较高的计算资源开销。因此，在对时效、算力或性能要求较高场景下的检测能力仍然存在一定局限。事实上，大语言模型在推理过程中会产生大量隐藏状态（hidden state），这些内部表征在不同层次上反映了模型对输入语义、上下文信息以及知识结构的理解。如何有效挖掘并利用这些内部表征信息，为幻觉检测提供更加稳定和可靠的判别依据，成为当前值得深入研究的重要方向[20,21]。此外，在检索增强生成场景下，通过在模型内部表征空间分析内部参数化知识与外部检索知识之间的关系，也有望更准确地检测生成内容与检索知识之间的潜在冲突。

基于上述背景，研究基于内部表征的幻觉检测方法，对于提升生成式人工智能系统的安全性与可信度具有重要意义。一方面，通过充分分析模型内部表征结构，可以在不依赖大量标注数据的情况下实现更加通用的幻觉检测；另一方面，在 RAG 场景下，通过在内部表征空间对模型参数化知识与外部检索知识之间进行冲突消解，也能够进一步提高对输出检测结果的真实性与可靠性。因此，探索基于内部表征的大语言模型幻觉检测方法，对于推动大语言模型在复杂实际场景中的安全应用具有重要研究价值和应用意义。

1.2　研究现状及挑战

1.2.1　通用幻觉检测

大语言模型幻觉检测（Hallucination Detection）[16] 通常指识别模型生成内容中是否包含与事实不符、缺乏依据或与上下文知识不一致的信息。与传统自然语言处理任务不同，幻觉检测并不直接关注文本生成质量本身，而是侧重于判断生成内容的真实性与可靠性。随着大语言模型在问答系统、知识检索和对话系统中的广泛应用，如何自动识别生成文本中的潜在幻觉，已经成为当前大模型安全性与可信性研究中的重要问题。现有研究通常从不同角度对幻觉检测问题进行建模，主要可以分为两大类方法：一类是基于生成概率、不确定性或自一致性的检测方法，其特点是无需获取模型内部表征，因此亦称“黑盒方法”；另一类为基于内部隐藏状态、激活表示或探针的检测方法，其特点是需要访问模型内部表征信息以进行检测，因此亦称“白盒方法”。

基于生成概率、不确定性或自一致性的幻觉检测（黑盒方法）

在黑盒方法的设定下，模型被假设为不可观测内部参数的封闭系统，仅能通过输入输出接口进行交互。其基本思想是通过分析模型生成过程中的概率特征、生成稳定性或多次生成结果之间的一致性，判断当前输出是否存在潜在的不可靠信息。此类方法的理论基础源于“一致性假设”，即——因模型对参数化知识的概率拟合特性，同一幻觉内容的复现在多次随机采样条件下呈现显著的随机性特征。由于此类方法无需访问模型内部参数或隐藏状态，因此简单易用，具有较好的模型通用性，并且能够方便地应用于不同类型的大语言模型。然而，这类方法往往只能利用有限的输出信息，对模型内部知识表示的利用较为有限；并因常需要采样多次输出，通常有较高的计算资源开销。因此，在对时效、算力或性能要求较高场景下的检测能力仍然存在一定局限。

黑盒方法早期的一些工作采用较为简单的输出一致性度量作为幻觉检测信号。例如，Lexical Similarity 类方法通过比较同一问题在多次采样生成的答案之间的词汇相似度（如 Rouge-L[22] 等指标）来评估生成稳定性。如果多个输出之间在表述上存在较大差异，则可能意味着模型在生成过程中缺乏稳定的知识依据，从而具有较高的幻觉风险。尽管此类方法实现简单，但它们为后续基于一致性假设的检测方法奠定了基础，在许多后续文章[23] 中被作为比较基线。随后，方法 SelfCheckGPT[23] 利用相同或额外的黑盒大语言模型对被测大语言模型的多个输出计算幻觉风险。具体地，SelfCheckGPT 通过构造形如“< 片段 A> 是否支持 < 回复 1>”的问题，对来自不同采样结果中的片段与回复进行交叉验证，并统计回答“支持”的比例作为幻觉风险指标。若不同生成结果之间缺乏相互支持关系，则说明模型生成内容的一致性较弱，从而更可能包含幻觉信息。在此基础上，一些研究尝试利用概率结构或内部统计量对生成不确定性进行建模。例如，方法 LLM-Check[24] 利用大模型内部中间层的 token 级别输出，并结合注意力矩阵进行特征值分解，通过计算矩阵的对数行列式作为幻觉指标。当该指标较高时，说明各批次输出或

各 token 之间的相关性较弱，模型不确定度较高，从而更容易产生幻觉。尽管 LLM-Check 在计算过程中使用了模型的中间表示，但其特征提取过程可以在任意可访问内部状态的替代模型上完成，因此在实际应用中仍可视为一种黑盒检测策略。另一类方法进一步从语义层面刻画多次生成之间的一致性。例如，方法 [25] 通过对同一问题的多个生成结果提取语义嵌入向量，计算各输出之间的余弦相似度，并利用层次聚类将其划分为多个语义簇。在此基础上，研究者提出以“语义熵”（semantic entropy）作为衡量生成稳定性的指标：当输出被划分为多个语义差异较大的簇时，说明模型对该问题缺乏稳定的知识表达，从而具有更高的幻觉风险。值得注意的是，该方法中的嵌入向量可以通过外部编码器获得，因此无需访问被测模型的内部表示。除了直接进行检测之外，还有一些工作尝试通过利用多次生成结果来缓解或减少幻觉现象。例如，方法 Copy-Paste[26] 通过提示模型优先从给定上下文中复制相关信息来生成回答，从而得到质量更高、幻觉更少的响应。随后，这些高质量生成结果被用于对模型进行后训练（post-training），以进一步降低模型在开放域问答中的幻觉概率。尽管该方法的主要目标在于缓解幻觉问题，但其核心思想同样依赖于对模型生成一致性的分析，因此与黑盒检测方法在思想上具有一定关联。

除基于生成概率、不确定性或自一致性的幻觉检测方法之外，还存在一类简单直接的黑盒方法，即基于提示词的方法。此类方法通过提示工程（Prompt Engineering）设计特定指令或问题链引导大语言模型自我验证其生成内容的可靠性，其核心假设为：模型具备内生的事实性反思能力，可通过提示激发其对潜在矛盾的主动检测。例如，可以通过引导模型自主输出其对自身生成内容的不确定度等多种方式来检测幻觉。文献 [27] 提出通过微调 GPT-3 模型使其直接生成自然语言形式的置信度表达（如“90% 置信度”或“高置信度”），而非依赖传统模型对数概率。然而，此类方法极其依赖自我检查的框架流程设计和提示词设计的精细度，并且很大程度上受到模型自身理解和推理能力的制约；此外因需要多次多种提示词输入输出，计算开销显著高于常规推理。

基于内部隐藏状态、激活表示或探针的幻觉检测（白盒方法）

白盒方法通常假设大语言模型内部的所有中间参数在推理过程中均可见，如模型对所有 token 的输出概率分布，模型中间某层的注意力参数等等。此类方法的理论基础源于“不确定性假设”，即——类似人类说谎时一般，模型对生成幻觉内容的确定度较低，这种不确定性能够在模型内部参数中隐式表征出来。大语言模型在生成过程中会产生丰富的隐藏状态表示，这些内部表征在不同层次上反映了模型对语义结构、上下文信息以及知识关联的理解。通过分析这些内部表示的分布特性或结构特征，可以为幻觉检测提供更加细粒度的判别依据。与黑盒方法相比，这类方法通常能够更充分地利用模型内部信息，因此在检测能力方面具有一定优势，是当前学术界研究较为活跃的方向；同时，部分白盒方法直接依赖于内部表征构建的幻觉指标，不需要训练数据及额外的分类器，没有或少有额外的计算开销。鉴于白盒方法具有对大模型丰富的内部表征的优势，

以及学术界在此方向建立的坚实基础，本文提出的方法均建立在白盒方法的假设上。然而，这类方法通常需要访问模型内部参数或隐藏状态，因此在实际应用中可能受到模型架构、访问权限等因素的限制；同时，由于不同模型的内部表征结构存在差异，部分方法在不同模型或领域上的泛化能力可能较弱。

在具体方法方面，早期研究往往利用模型输出概率分布所隐含的不确定性信号作为幻觉指标。例如，一些工作通过计算生成序列的困惑度（Perplexity）、熵（Entropy）或平均负对数似然来衡量模型对当前输出的置信程度[23,24,28,29]；当模型对生成内容缺乏稳定概率支持时，其困惑度通常较高，从而可能指示潜在的幻觉风险。类似地，也有研究利用生成过程中每一步的熵值（Length-Normalized Entropy）[28,29] 来刻画模型的不确定性水平，通过对 token 级概率分布的熵进行归一化平均，从而得到整体生成稳定性的度量。

随着研究的深入，越来越多的工作开始尝试直接利用模型内部表示的一致性来进行幻觉检测。例如，Semantic Entropy[30] 类似于 [25] 的聚类方法，通过双向蕴含推理算法对语言模型的多个生成回答进行语义聚类，将语义等价的文本归并为同一语义簇，进而计算各语义簇的概率分布熵值作为不确定性指标；双向蕴含推理算法通过外接自然语言推理模型实现语义等价判断。INSIDE[28] 提出通过直接分析大语言模型内部隐藏状态的特征空间进行幻觉检测，创新性地构建基于协方差矩阵特征值的 EigenScore 指标，通过特征值对数行列式量化语义一致性。该法采用中间层末位 token 嵌入构建语义表征，并引入测试时激活值截断技术抑制过度自信生成。不同于以上两种方法在最终层以多次随机采样的方式引入噪声，方法 Noise Inject[29] 通过在大语言模型的中间层隐藏激活中注入随机噪声扰动，结合预测层采样生成多样化的输出响应，并计算答案熵等不确定性指标以检测幻觉。具体地，该方法在解码过程中对指定范围的 Transformer MLP 层输出叠加均匀分布噪声，通过扰动中间表征改变下一词分布，从而放大幻觉响应的不确定性差异；其噪声注入机制广泛应用于不同的大语言模型问题设定中。这三项工作均需要模型对同一问题进行多次回答采样，因此具有计算开销较大的局限性。

在此基础上，一些研究尝试通过更深入地分析模型内部表征来增强检测能力。例如，用于幻觉缓解的方法 ITI[31] 通过嵌入大模型各层各注意力头的线性“探测器”（即单层分类神经网络）识别出与模型输出真实性强相关的注意力头，以及在隐藏空间中指向“生成真实信息的方向”。随后通过在推理时将这些重要的注意力头的输出像“真实方向”偏移，即可增强输出内容真实性。另一项工作 SAPLMA[32] 通过大模型内部的隐藏激活值训练一个简单轻量的浅层神经网络，并发现在不同领域下用于判断幻觉的隐藏表征可以进行一定程度上的迁移。因此，可以事先训练此分类器，然后在任意的测试数据上进行推理。这两项工作均借由了大模型内部隐藏状态表征幻觉风险。方法 HaloScope[33] 提出了一种基于未标注大语言模型生成数据的幻觉检测框架。具体地，该方法通过对模型中间层激活向量构建的嵌入矩阵进行奇异值分解，识别出与幻觉文本强相关的潜在子空间，通过计算样本在子空间投影的加权范数作为归属评分，并基于该评分筛选伪标注数据训练二分类器。方法 CCS[34]（对比一致性搜索）提出了一种基于模型

内部激活状态的无监督知识探测方法，通过构建正反陈述对并施加逻辑一致性约束（如陈述与其否定真值相反），在隐藏空间中学习线性投影方向以分离潜在真实知识。该方法在无需标注数据和模型输出的条件下，通过中间层激活分析实现了跨任务知识迁移，并在对抗性提示干扰下保持鲁棒性。以上工作都利用了大模型内部空间的隐藏表征，但利用方式较为单一，如仅使用某一层的表征，且大多依赖于训练一个额外的分类器来进行幻觉检测，增加了方法的复杂度和计算开销。

除了基于单层表示的分析方法，近年来也有研究开始利用更加丰富的内部表示结构。例如，方法 CoE[35] 中将大模型各层的表征类比于人类思考推理过程中的“思维链”，将不同层的嵌入表示视为一条“embedding 链”，并通过分析相邻层嵌入之间的角度和模长变化来构造幻觉检测特征。ACT-ViT[36] 进一步将模型推理过程中产生的三维激活张量统一作为整体表示，并利用视觉 Transformer（Vision Transformer，ViT）类模型对该激活张量进行建模，以充分挖掘跨层与跨 token 的表示信息。此外，HaMI[37] 则从多实例学习（Multiple Instance Learning，MIL）的角度出发，将一次生成结果视为由多个 token 组成的“bag”，并通过自适应 token 选择机制定位最可能产生幻觉的 token，从而实现更加精细化的检测。通过对大模型内部表征的充分利用，此类方法在多种应用场景下取得了初步的成功。

综上所述，白盒方法通过各种方法直接分析模型内部表征，为幻觉检测提供了更加丰富和细粒度的信息来源。随着对大语言模型内部表示结构理解的不断深入，如何有效建模跨层、跨 token 的表示关系，以及如何在不增加过多计算开销的情况下充分利用这些内部表征信息进行高效检测，仍然是当前研究中的重要方向。

总体而言，现有幻觉检测研究已经从简单的黑盒输出概率分析逐渐发展到对白盒模型内部表征结构的深入挖掘，并在不同应用场景中提出了多种检测策略。然而，如何更加充分地利用大语言模型内部丰富的表征信息，以及如何在不引入过多计算开销、保证方法泛化性的同时提高检测准确性，仍然是当前研究中有待进一步探索的重要问题。

1.2.2 RAG 幻觉检测

在典型的 RAG 系统中，从外部知识库中检索得到，加入大模型输入中以便赋予大模型额外知识的信息，被称为“检索知识”（retrieved knowledge）或“外部知识”（external knowledge）。相对地，在大模型自身预训练过程中学习到的知识则被称为“参数化知识”（parametric knowledge）或“内部知识”（internal knowledge）。在上下文问答、文本摘要、图像理解等 RAG 常用的任务场景中，我们通常期待大模型生成与给定外部知识相符、相关的内容。然而，如 1.1 节所述，RAG 虽能显著提高生成内容的可验证性与时效性，但并未从根本上消除幻觉问题。在实际应用中，即使模型已经获得了与问题相关的外部文档，其生成结果仍可能出现偏差：即生成内容与输入的外部文档相矛盾或无

关。前者体现为对外部知识的误读、忽视或篡改，后者则体现为模型在检索增强场景下依旧过度依赖内部知识。针对这一问题，RAG 幻觉检测（RAG Hallucination Detection）的目标，正是在检索增强生成过程中识别这些与外部证据不一致、无依据或证据支撑不足的生成内容。

虽然通用的幻觉检测（见 1.2.1 小节）亦能一定程度上应用于 RAG 幻觉检测场景，但与其相比，RAG 幻觉检测具有其独特鲜明的任务特性。通用幻觉检测通常只关注“输出是否真实或可信”，而 RAG 幻觉检测更强调“输出是否真正由外部检索知识所支撑”。因此，它不仅需要判断生成结果本身是否可靠，还需要进一步刻画模型在生成过程中究竟依赖了外部知识，还是更多依赖了参数内部知识。也正因为如此，仅依赖输入输出对、生成概率或表层不确定性的黑盒方法，往往难以准确刻画 RAG 场景下幻觉产生的根源。特别是在外部文档已经被提供的情况下，单纯根据输出文本难以判断模型究竟是“正确利用了检索证据”，还是“表面相关但实则未使用证据”。基于上述原因，当前 RAG 幻觉检测研究主要沿白盒方法的思路展开，即通过挖掘模型内部的各类表征（如隐藏状态、注意力模式、中间层表示或特定功能模块），构造能够标识幻觉的数学表征。RAG 场景下这些幻觉表征通常不再仅仅反映“模型是否出错”，而更关注模型对外部知识与内部知识的利用程度、两类知识之间的竞争关系，以及这种关系如何影响最终生成结果。从现有研究来看，专门面向 RAG 幻觉检测的方法大致可以分为以下几类。

第一类是基于机制可解释性（mechanistic interpretability）的方法。这类方法尝试从模型内部识别与“未使用外部知识”相关的功能组件，并将其作为幻觉检测线索。典型工作如 ReDeEP[38]，其通过分析模型内部注意力头和前馈网络的功能，识别出更倾向于复制内部知识而非利用外部文档的复制型注意力头（copying head），以及存储较多参数知识的知识型前馈层（knowledge FFN），并据此检测 RAG 生成中的幻觉。该类方法属于“探针型”方法，类似于前文提及的 ITI[31] 方法，能够将幻觉现象与具体模块功能联系起来，从而揭示 RAG 模型“没有使用外部证据”。LRP4RAG[39] 方法将逐层相关传播（Layer-wise Relevance Propagation, LRP）引入 RAG 幻觉检测任务，通过回溯生成输出对输入上下文中各部分内容的相关性，提取相关性矩阵并进一步用于幻觉判别。该方法说明了从模型内部归因信息出发刻画“检索证据—生成结果”关系是可行的，也为后续基于内部机制与知识支持关系联合建模的 RAG 幻觉检测研究提供了启发。第二类是基于内外部知识利用信号建模的方法。这类方法不再局限于单一或某类“探针”模块，而是试图显式刻画模型对外部知识与内部知识的依赖强弱，并将这种依赖程度转化为可检测信号。代表性工作如 LUMINA[40]。该方法定义了外部知识利用率与内部知识利用率两类信号：前者通过替换支持文档前后的嵌入差异来衡量模型对检索文档的敏感程度，后者则通过中间层输出 logits 的深度演化来刻画内部知识对生成结果的支撑强度。与机制解释类方法相比，这一类方法更强调构建连续的、可量化的知识利用指标，因而更适合从整体动态过程分析 RAG 幻觉的产生机制。第三类是基于稀疏可解释表征的方法。这类方法借助稀疏自编码器（Sparse Autoencoder, SAE）[41–43] 技术，从中间层表示中分解

出更具语义可解释性的稀疏特征，再利用这些特征检测生成是否偏离外部证据。相关工作如 RAGLens[43]，指出 SAE 能够从中间嵌入中挖掘潜在稀疏特征，并为 RAG 幻觉检测提供更细粒度、更具解释性的表征基础。通过对 SAE 生成的特征的筛选和简单训练，即能够高效地检测模型的幻觉水平。这类方法的优势在于，它在保留白盒检测能力的同时，进一步增强了中间表示与语义行为之间的可解释性，为“哪些内部特征对应外部知识利用不足”提供了新的分析工具。

总体而言，RAG 幻觉检测仍处于相对早期的发展阶段，由于此场景下的幻觉判定更复杂，相关工作数量少于通用幻觉检测研究。现有研究总体呈现出两个明显趋势：其一，检测线索正从单纯的“输出异常”逐步转向 RAG 的“知识利用机制异常”；其二，研究重点正从粗粒度的结果判别转向更细粒度的模块级、表征级分析。尽管现有方法已在一定程度上揭示了 RAG 幻觉内外部知识利用失衡的联系，但仍面临若干不足。例如，如何在内部表征空间更充分地建模和利用外部知识信息，如何更简单高效地消解内外知识冲突，以及如何进一步提升方法的可解释性，仍然是当前研究中的重要挑战。

1.2.3 现有方法的不足

尽管现有研究已经围绕大语言模型幻觉检测提出了多种技术路线，并在一定程度上提升了生成内容可靠性的判别能力，但从整体上看，相关方法在通用幻觉检测与 RAG 幻觉检测两个方向上仍均存在进一步改进的空间。

- **通用幻觉检测方法大多未能充分利用大模型内部的表征信息。**一方面，许多性能较优的方法通常依赖人工标注的训练资源，需要预先构造带有“真实/幻觉”标签的数据集，并在此基础上训练额外的分类器、探针或浅层神经网络。这类方法在特定模型、特定任务或特定领域上往往能够取得较好的实验结果，但其判别边界通常较强地依赖于训练数据分布。当模型架构、参数规模、指令风格或应用场景发生变化时，已学习到的表征与新数据之间容易出现失配，从而导致方法在跨模型、跨任务和跨领域条件下的泛化能力受限。另一方面，无需训练的方法虽然避免了标注数据带来的高昂成本，具有更强的部署灵活性，但其大多主要依赖生成概率、不确定性或自一致性等局部统计量之类较为表层的信号，对大语言模型内部隐藏状态中蕴含的丰富语义信息利用仍不充分。尤其在复杂推理、长文本生成及知识密集型任务中，仅依赖单一输出信号往往难以稳定反映幻觉形成的内部机制，因此其检测结果容易受到采样策略、提示形式和任务复杂度的影响，表现出一定的不稳定性。由此可见，通用幻觉检测领域仍缺乏一种既不强依赖人工标注训练、又能够充分挖掘模型内部表征并兼顾跨场景泛化能力的检测方法。

- **RAG 幻觉检测方法在外部知识信号的利用方面仍存在明显不足。**一方面，许多方

法未能充分利用外部知识信号，难以准确刻画检索文档对生成结果的真实支撑作用；或者虽有尝试显式建模外部知识利用过程，但其建模方式往往较为复杂，依赖特定模块分析、额外特征构造或繁琐的中间过程设计，因而在方法的简洁性、可迁移性与实际应用效率上仍受到一定限制。在这种情况下，当模型内部参数知识与外部检索知识不一致时，现有方法往往难以以简单有效的方式消解二者之间的冲突，从而影响对生成内容真实性和可靠性的准确判断。另一方面，现有 RAG 幻觉检测方法的可解释性仍然不足。尽管部分方法能够从模型内部挖掘出与幻觉相关的检测信号或异常表征，但这些信号大多停留在数值统计、隐空间方向或模块响应层面，难以进一步说明其具体语义含义，即无法清晰解释“模型究竟因何而被判定为产生了幻觉”。因此，如何在充分利用外部知识信号的同时，以更简单的方式刻画并缓解内外知识冲突，并进一步赋予检测信号清晰、可自然语言表达的语义解释，仍是当前 RAG 幻觉检测研究中亟待解决的重要问题。

1.3　本文研究内容

围绕 1.2 节所述的大语言模型幻觉检测研究现状与挑战，本文分别从通用幻觉检测与 RAG 幻觉检测两个方向展开研究，旨在针对现有方法在内部表征利用、外部知识信号建模等方面的不足，提出更加有效、稳定且具有一定通用性的**基于内部表征的大模型幻觉检测方法**。

第一项研究内容面向通用幻觉检测任务。针对现有方法对大模型内部表征信息利用不充分，以及部分方法依赖标注训练、跨模型与跨领域泛化能力受限的问题，本文拟从大语言模型生成过程中的隐藏状态与激活表示出发，研究一种**基于多方向表征建模的幻觉检测方法**。其具体贡献如下：

- 提出一种基于多方向表征建模的幻觉检测方法 ATScore（Activation Tensor Score）。针对现有方法内部表征信息利用不充分的问题，提出在三维激活张量的统一视角下看待跨层和跨 token 方向的表征信息，从两个维度挖掘模型内部表征中蕴含的幻觉线索，最终实现对内部表征信息的充分利用。

- 利用多方向链式表征建模深入探索大语言模型内部表征的演化结构，从而高效地利用模型内部表征的动态变化特征，构建更稳定、有效且免于训练的幻觉检测信号，同时保证检测的低开销和良好的跨模型、跨领域泛化能力。

- 在多个开源大模型和公开幻觉检测数据集上进行全面评估，并针对多种算法变体进行多种消融实验，验证所提出方法在不同模型、不同任务和不同领域上的有效性与泛化能力。与现有主流方法进行对比分析，展示其在提升幻觉检测准确性、稳定性以及跨场景适用性方面的优势。

第二项研究内容面向 RAG 幻觉检测任务。针对现有 RAG 幻觉检测方法对外部检索知识信号利用不充分、内外知识冲突难以简单有效刻画，以及检测信号可解释性不足等问题，本文拟研究一种**基于检索知识冲突消解的幻觉检测方法**。其具体贡献如下：

- 提出一种基于检索知识冲突消解的 RAG 幻觉检测方法 SKID（Sparse Knowledge Inconsistency Detector）。针对现有方法对外部检索知识信号利用不充分的问题，提出在 SAE 高维度参数空间对外部知识和内部知识进行明确定义和消解，从而构建更准确、稳定、符合设定的 RAG 幻觉检测信号。
- 通过引入可解释的稀疏特征表征，进一步提升 RAG 幻觉检测方法的可解释性，使得检测不仅能够准确反映生成内容与外部知识之间的冲突程度，还能够以清晰的自然语言表达的方式解释“模型为何被判定为产生了幻觉”，从而增强方法在实际应用中的易用性和用户信任度。
- 在多个 RAG 数据集上进行系统性评估，并针对超参数、算法变体进行多种消融实验，验证所提出方法在准确检测 RAG 幻觉、刻画内外知识冲突以及提升检测可解释性方面的有效性。与现有 RAG 幻觉检测和通用幻觉检测方法进行对比分析，展示其在提升检测性能和可解释性方面的优势。

上述两项研究内容之间具有紧密的内在联系。首先，二者在研究领域有一定的相关性：均以大语言模型内部表征为核心研究对象，关注如何从模型生成过程中的隐藏状态与激活信息中提取稳定、有效的幻觉检测信号。其次，二者的侧重点各有不同：前者侧重于面向一般生成场景挖掘通用的内部判别表征，后者则进一步将这一思路扩展到检索增强场景，研究外部知识引入后内部表征所呈现出的新特征及其对应的幻觉模式。除此之外，两项研究在所处领域上具有递进关系：通用幻觉检测研究旨在建立对模型内部幻觉表征的基础认知与通用建模框架，而 RAG 幻觉检测研究则在此基础上进一步引入外部知识因素，关注内部知识与外部知识之间的交互、冲突及其消解机制。最后，二者共同服务于提升大语言模型生成内容真实性、可靠性与可解释性的总体目标。通过将通用场景下的内部表征分析与 RAG 场景下的知识冲突建模结合起来，力图形成一套从一般生成到检索增强生成、从基础检测到可解释分析逐步推进的研究体系，为构建更加安全可信的大语言模型应用提供方法支撑。

1.4 本文组织结构

本文共分为五个章节，组织结构如图 1-2 所示。各章内容安排如下：

第一章为绪论。首先介绍大语言模型幻觉问题的研究背景及意义，阐述幻觉问题在实际应用中的潜在风险；随后分别综述通用幻觉检测与 RAG 幻觉检测的研究现状，表明大模型的内部表征在各类幻觉检测问题中的重要作用；进一步分析现有方法在内部表征利用等方面存在的不足；在此基础上，给出本文的研究动机和研究内容。

第二章为相关工作。主要介绍本文研究主要涉及的基础概念和关键技术，为后续章节的方法设计与实验分析奠定理论基础。

第三章讨论一种基于多方向表征建模的幻觉检测方法。详细介绍本文的 ATScore 方法，从算法原理、实现流程、实验设置和结果分析等方面进行系统阐述，验证本方法在不同模型、不同任务和不同领域上的有效性与泛化能力。

第四章讨论一种基于检索知识冲突消解的幻觉检测方法。详细介绍本文的 SKID 方法，围绕其方法构建、冲突消解机制、可解释性分析以及实验评估等内容展开详细讨论，验证本方法在 RAG 幻觉检测任务中的性能与优势。

第五章为总结与展望。对全文的研究工作进行系统总结，归纳本文在通用幻觉检测与 RAG 幻觉检测两个方向上的主要研究成果，并结合当前大语言模型安全与可信研究的发展趋势，对后续可能的研究方向进行展望。

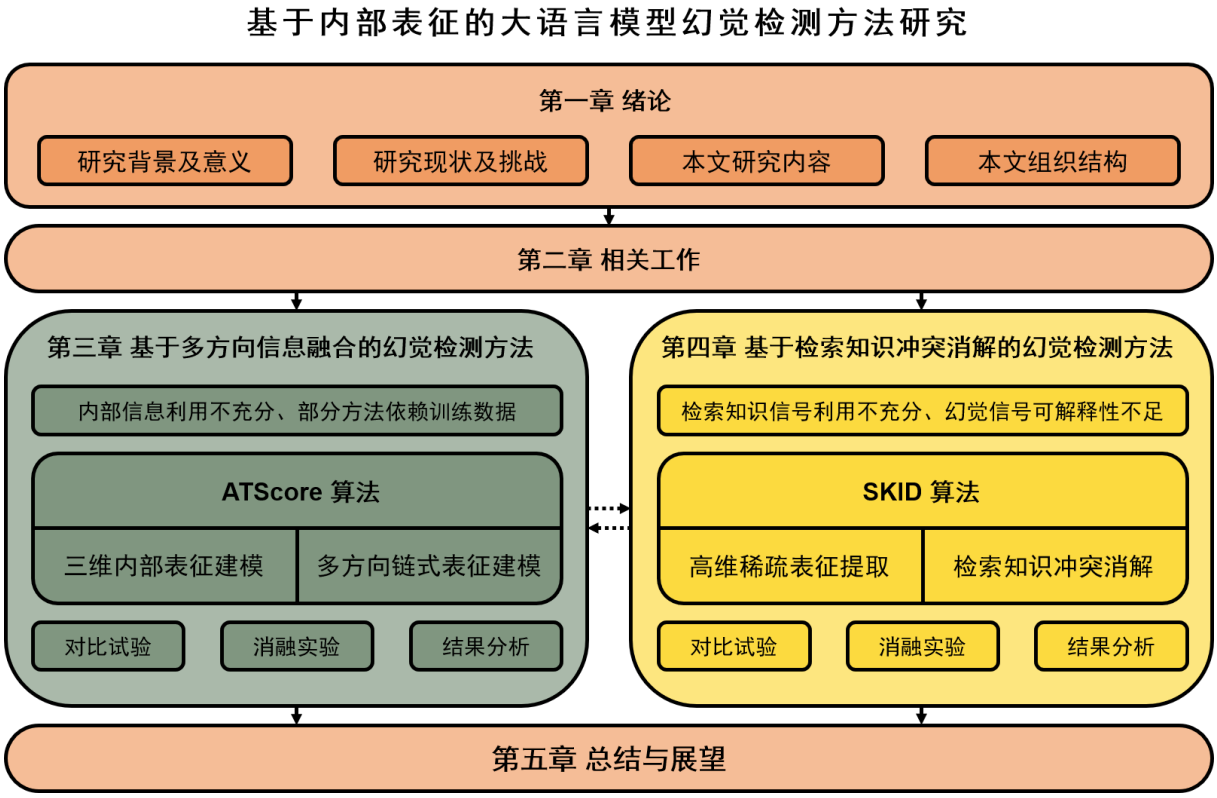

图 1-2 本文组织结构图

第二章 相关工作

本章主要介绍与本文研究内容密切相关的代表性工作与技术基础，为后续章节中方法的提出与分析提供必要的背景支撑。围绕基于内部表征的大语言模型幻觉检测这一主题，本文的研究内容主要涉及通用场景下基于模型内部表征的白盒幻觉检测，以及检索增强生成场景下围绕外部知识利用建模的 RAG 幻觉检测。本章将从以下三个方面对相关工作进行梳理。

2.1 基础概念与技术

本文围绕基于内部表征的大语言模型幻觉检测展开研究，其中第一项工作关注通用场景下大语言模型内部表征中的幻觉信号挖掘，第二项工作则进一步面向检索增强生成场景，研究模型内部知识与外部检索知识之间的冲突及其检测问题。因此，在展开后续方法介绍之前，有必要对大语言模型（Large Language Models, LLMs）、检索增强生成（Retrieval-Augmented Generation, RAG）以及稀疏自编码器（Sparse Autoencoder, SAE）的基本原理进行简要说明，以为后文方法设计提供统一的技术背景。

2.1.1 大语言模型基础

大语言模型通常是指基于大规模语料进行预训练、并具备通用语言理解与生成能力的一类深度神经网络模型[44,45,4]。当前主流的大语言模型大多建立在 Transformer[44] 架构之上，能够根据给定上下文预测后续文本内容，并以自回归方式逐步生成完整输出。

对于大语言模型而言，模型输入输出的最基本处理单位称为词元（token）。一个 token 可以是一个字、一个词、一个词的一部分，或是一个标点符号，其具体形式取决于模型所采用的分词器设计。大语言模型的输入、输出以及内部计算过程，本质上都是围绕 token 序列展开的。

从结构上看，一个典型的大语言模型通常可以分为输入嵌入层（embedding layer）、若干层堆叠的 Transformer 模块以及最终输出层三个部分。首先，输入文本在经过分词器切分为离散的 token 序列后，会被映射为连续向量表示，这一过程由 embedding 层完成。embedding 层的作用是将原本离散的符号编码为模型可以处理的稠密向量，并结合位置信息，使模型能够感知各 token 在序列中的先后关系。

随后，这些向量表示会进入多层堆叠的 Transformer 模块中进行逐层加工。每一层 Transformer 通常包含多头自注意力机制（Multi-Head Self-Attention）和前馈神经网络（Feed-Forward Network）等基本组成部分。自注意力机制负责建模序列中不同 token 之间的依赖关系，使模型能够根据上下文动态调整对不同位置的关注程度；前馈网络则进

一步对每个位置上的表示进行非线性变换和特征提炼。通过这种多层堆叠结构，模型可以逐步将浅层的词法、局部上下文信息，转化为更高层次的句法、语义乃至知识相关表示。公式 2.1 刻画了单层 Transformer 模块的基本计算流程。首先，自注意力模块对输入序列中的各位置表示进行上下文交互；随后，通过残差连接与层归一化得到中间表示；再经过前馈网络进行逐位置的非线性特征变换；最后再次通过残差连接与层归一化得到该层输出。这样的结构使模型能够同时建模 token 之间的依赖关系以及单个位置表示的深层语义变换。

$$
\begin{aligned}
\mathbf{H}_{\text{attn}}^{(l)} &= \text{Attention}\left(\mathbf{X}^{(l)}\right), \\
\widetilde{\mathbf{X}}^{(l)} &= \text{LayerNorm}\left(\mathbf{X}^{(l)} + \mathbf{H}_{\text{attn}}^{(l)}\right), \\
\mathbf{H}_{\text{mlp}}^{(l)} &= \text{MLP}\left(\widetilde{\mathbf{X}}^{(l)}\right), \\
\mathbf{X}^{(l+1)} &= \text{LayerNorm}\left(\widetilde{\mathbf{X}}^{(l)} + \mathbf{H}_{\text{mlp}}^{(l)}\right).
\end{aligned}
\tag{2.1}
$$

在最后一层，模型会将当前隐藏表示送入输出头（通常也称语言建模头、分类头或 LM head）进行线性映射，并得到对词表中各候选 token 的预测分数。经过 softmax 归一化后，模型即可得到下一个 token 的概率分布，并据此选择或采样出当前时刻的输出 token。重复这一过程，模型便能够逐 token 生成完整回答。形式化地，设大语言模型记为 M，则其生成过程可以表示为

$$
P_M(Y|X) = \prod_{t=1}^{m} P(y_t|X, y_{<t}), \tag{2.2}
$$

其中 $Y = \{y_1, y_2, \ldots, y_m\}$ 为模型输出序列，$y_{<t}$ 表示第 t 个位置之前已经生成的 token。该式表明，大语言模型本质上通过条件概率分解实现序列生成，即每一步预测都依赖于输入文本及此前已经生成的上下文。常见的大语言模型架构如图 2-1[46] 所示。

需要指出的是，在上述生成过程中，大语言模型不仅会输出最终的文本结果，同时还会在不同层、不同位置产生大量中间表示。广义上说，层间的 embedding 表示、Transformer 层内部的某些激活值、注意力输出以及前馈网络中的中间激活，都可以视为模型的内部表征（internal representations）。这些内部表征反映了模型对输入语义、上下文约束以及参数化知识的逐步加工过程，是理解模型行为的重要信息来源。当前大多数已有幻觉检测研究工作及本文工作均主要关注并使用各层输出位置上的隐藏向量表示，也可将其理解为经过层间演化后的 embedding 表征。

2.1.2 检索增强生成基本流程

尽管大语言模型具有较强的参数化知识记忆能力，但其知识更新速度有限，在开放域问答、事实核查、知识密集型生成等任务中，仍可能产生依据不足或与事实不符的内容。为缓解这一问题，研究者提出了检索增强生成框架[17–19]。该框架的核心思想是在模

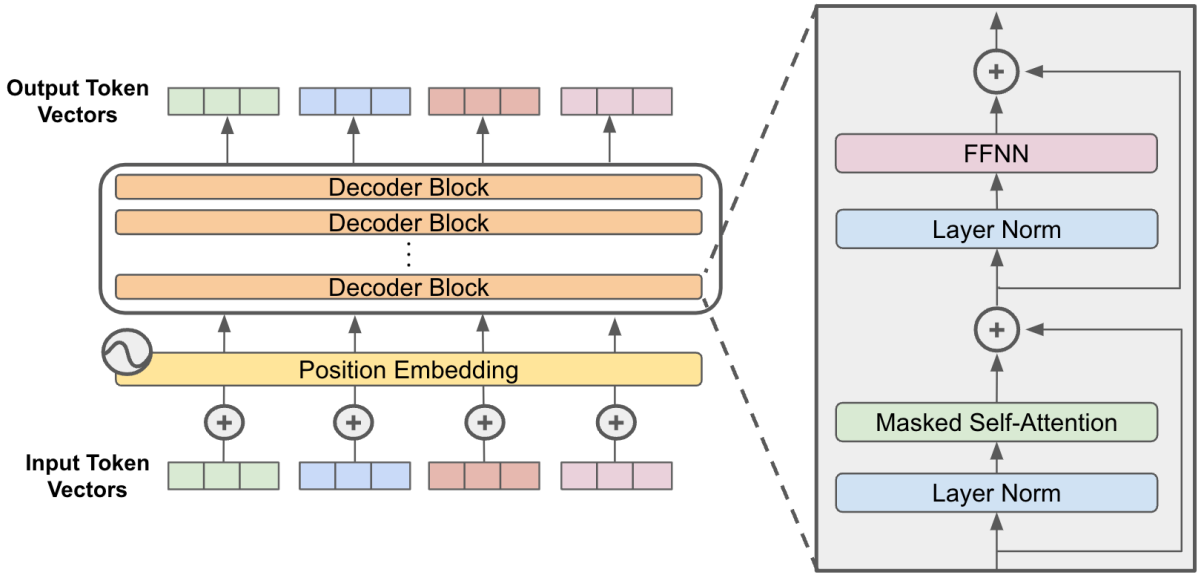

图 2-1 大语言模型架构图

型生成之前，先从外部知识库中检索与当前问题相关的参考材料，再将这些材料与原始问题一同提供给大语言模型，从而使生成过程不再仅依赖模型参数中固有的知识，而是能够显式参考外部证据。

从基本流程上看，RAG 通常可概括为“检索—增强—生成”三个阶段。首先，系统根据用户提出的问题，从文档库、网页库、数据库或其他外部知识源中召回若干相关文本片段；其次，将这些检索结果与原始问题按照预设模板进行组织和拼接，构造成增强后的上下文输入；最后，大语言模型基于这一增强后的输入生成最终回答。换言之，RAG 并不是直接让模型“凭记忆作答”，而是先“查资料”，再“结合资料作答”[47–49]。例如，在医疗问答场景中，用户询问某种疾病的常见治疗方案时，RAG 系统可以先检索最新的临床指南、医学百科条目或专业资料，再让模型基于这些检索证据进行归纳生成，从而降低模型直接凭借过时记忆作答的风险。典型的 RAG 流程如算法 2.1 所示。

算法 2.1 检索增强生成（RAG）基本流程

输入： 用户输入文本 X；外部知识库 $\mathcal{D}$；检索器 $\mathcal{R}$；大语言模型 M；返回文档数 N

输出： 模型生成响应 Y

1: 根据用户输入 X 生成检索查询 q
2: 利用检索器 $\mathcal{R}$ 在知识库 $\mathcal{D}$ 中召回与 q 最相关的前 N 个文档
3: 得到候选检索结果集合 $R = \{D_1, D_2, \ldots, D_N\}$
4: 对检索结果进行排序、截断或拼接，得到最终参考文档集合 $\widetilde{R}$
5: 将用户输入 X 与参考文档集合 $\widetilde{R}$ 按提示模板组织为增强上下文 $\widetilde{X}$
6: 将增强上下文 $\widetilde{X}$ 输入生成模型 M
7: 模型基于增强上下文 $\widetilde{X}$ 逐 token 生成输出序列 Y
8: **return** Y

相较于只依赖参数化知识的生成方式，RAG 的优势在于能够引入更实时、更外显、也更可追溯的知识来源，因此在许多知识密集型任务中能够提升回答的事实性和可解释性。然而，RAG 并不能从根本上消除幻觉现象。一方面，检索器本身可能召回不完整、不准确或相关性不足的文档；另一方面，即使外部检索结果已经提供了正确信息，生成模型也未必能够始终严格遵循这些证据。特别是在模型内部参数知识与外部检索知识不一致时，模型可能更倾向于依赖自身已有知识，忽略甚至误解检索内容，最终生成与检索证据不一致的回答。

也正因为如此，RAG 幻觉检测不再只是单纯判断“模型答得对不对”，而是需要进一步分析“模型是依据什么知识答出来的”“输出与检索证据之间是否一致”“模型内部知识是否压制了外部知识”等更复杂的问题。本文第四章的工作正是在这一背景下展开，试图通过分析模型内部表征与检索内容之间的关系，更直接地刻画 RAG 场景中的知识冲突现象，并据此进行幻觉检测。

2.1.3 稀疏自编码器基础

为了进一步挖掘大语言模型内部隐藏状态中的可解释判别信息，近年来研究者开始关注利用稀疏表示学习方法对原始隐藏状态进行重构与解耦。其中，稀疏自编码器（Sparse Autoencoder, SAE）[41,50–52] 是一类具有代表性的表征学习模型，其目标是在尽可能保留输入信息的同时，将原始稠密表示映射到更高维、但更加稀疏的特征空间中。

一般而言，自编码器由编码器和解码器两部分组成。给定输入向量 $\mathbf{h} \in \mathbb{R}^d$，编码器首先将其映射为潜在特征 $\mathbf{z} \in \mathbb{R}^D$，

$$\mathbf{z} = f_{\text{enc}}(\mathbf{h}), \tag{2.3}$$

其中通常有 $D > d$。随后，解码器再根据 $\mathbf{z}$ 重构输入

$$\hat{\mathbf{h}} = f_{\text{dec}}(\mathbf{z}). \tag{2.4}$$

模型训练的目标是在减小重构误差的同时，对潜在表示 $\mathbf{z}$ 施加稀疏约束，使得每个样本仅激活少量特征维度。对应的优化目标一般可写为

$$\mathcal{L} = \|\mathbf{h} - \hat{\mathbf{h}}\|_2^2 + \lambda\,\Omega(\mathbf{z}), \tag{2.5}$$

其中第一项为重构损失，第二项为稀疏正则项，λ 用于平衡二者，$\Omega(\mathbf{z})$ 可取 L_1 范数等形式，令 $\mathbf{z}$ 在大多数维度上为 0。

相较于原始隐藏状态，SAE 得到的稀疏特征通常具有两方面优势。其一，原始隐藏状态中的语义信息往往高度纠缠，不同维度混合承载多种语义因素，而稀疏映射有助于将这些纠缠信息分解为相对独立的特征单元，从而增强表示的可解释性。其二，稀疏特征在后续统计筛选和下游建模中通常更易处理。例如，可以在高维稀疏特征空间中计

算各特征维度与标签之间的关联程度，筛选出最具判别力的特征子集，并进一步利用简单、可解释的分类模型进行建模。

以上内容从整体上介绍了本文后续研究所主要依赖的三项基础技术。大语言模型为幻觉检测提供了研究对象及其内部表征来源；RAG 框架通过引入外部检索知识扩展了生成条件，也使幻觉检测从单纯的输出正确性判断进一步发展为对内外知识关系的建模；SAE 则为从复杂隐藏状态中提取高维、稀疏、可解释的判别特征提供了有效工具。三者共同构成了本文两项方法研究的技术基础：前者支撑 ATScore 对内部表征动态结构的建模，后两者则共同支撑 SKID 对 RAG 场景下知识冲突信号的提取与解释。

2.2　白盒幻觉检测

大语言模型幻觉通常指模型生成的内容虽然在语言形式上流畅自然，但在事实层面与真实世界知识、给定上下文或问题语义不一致的现象。围绕这一问题，幻觉检测任务旨在根据模型生成过程中的相关信号，对当前输出是否包含幻觉进行判断。根据可利用信息来源的不同，现有方法大致可分为黑盒方法与白盒方法两类。前者通常仅依赖输入文本、生成结果或外部辅助信息进行判别；后者则进一步利用模型推理与生成过程中的内部状态信息，如隐藏状态、激活值、logits 及中间层表征等，从模型内部挖掘能够反映生成真实性的判别信号。

从基本思路上看，白盒幻觉检测通常可概括为如下过程：首先，在模型生成阶段提取特定层、特定位置或特定类型的内部表征；随后，基于这些表征构造能够反映生成可靠性的特征或判别分数；最后，根据这些特征或分数对输出进行幻觉检测。按照是否需要额外训练检测模块，现有白盒方法又可进一步分为两类：一类方法不依赖额外训练，而是直接从内部状态中构造统计量、一致性指标或启发式分数；另一类方法则利用带标注数据对内部表征进行探测、分类或干预，以学习更具判别性的幻觉检测模型。

尽管白盒方法为幻觉检测提供了比黑盒方法更丰富的可用信息，但其仍面临若干关键挑战。一方面，大语言模型的内部状态维度高、层数深，包含大量冗余甚至噪声信息，如何从中定位真正与幻觉相关的判别特征并非易事；另一方面，不同层、不同 token 位置以及不同表示形式所蕴含的信息存在显著差异，如何设计有效的特征提取与利用方式，仍是当前白盒幻觉检测研究中的核心问题。基于此，现有工作围绕内部表征的利用方式提出了多种方案，以下将对其中具有代表性的白盒幻觉检测方法进行分类介绍与分析。

2.2.1　无需额外训练的方法

在白盒幻觉检测研究中，一类具有代表性的方法是不额外引入专门的检测器训练过程，而是直接基于大语言模型生成过程中的内部状态构造启发式判别依据。与依赖监督

信号学习分类边界的方法不同，这类方法通常通过分析隐藏状态、跨层表征或生成过程中的一致性特征，直接计算用于表征输出可靠性的分数或指标。其主要优势在于实现简单、部署成本较低，并且避免了额外标注数据和训练过程所带来的模型适配问题，因此在跨模型、跨任务和跨数据集场景下通常具有更好的迁移潜力。

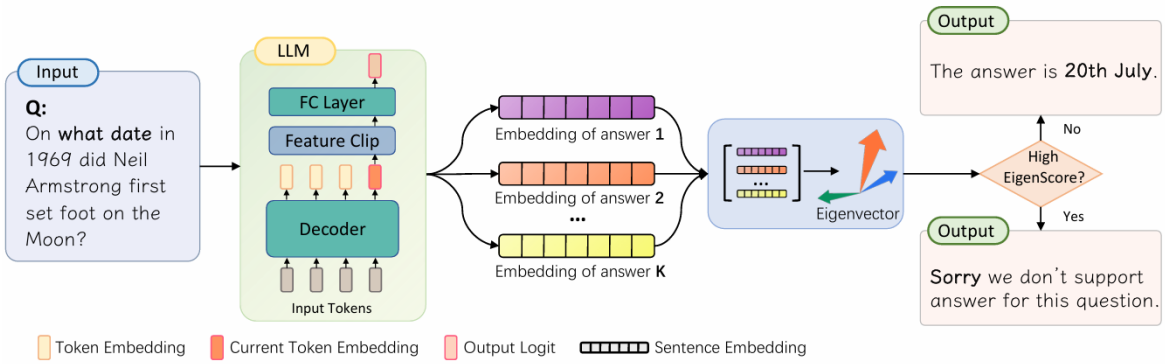

图 2-2 INSIDE 方法框架图

INSIDE[28] 是一种典型的不依赖额外训练的白盒幻觉检测框架，其方法框架图如图 2-2 所示。该方法的基本出发点在于：当模型对某一问题具有较为稳定和可靠的知识时，多次采样的生成结果在其语义空间中的嵌入表示通常表现出更强的一致性；相反，当模型可能生成幻觉内容时，其内部状态往往会呈现更大的波动性。因此，INSIDE 通过考察多次生成条件下中间层表示的一致程度，来衡量模型输出的可靠性，并据此实现幻觉检测。具体地，该方法提出表征幻觉水平的 EigenScore 指标，其计算过程大致如下：

令大模型对同一问题生成 K 次回答，取每次回答的最后一个 token 在第 l 层的隐藏状态 $h_k^l \in \mathbb{R}^d$ 作为整个句子的表征，构成一个表征矩阵 $\mathbf{Z}^l = \left[h_1^l, h_2^l, \ldots, h_K^l\right] \in \mathbb{R}^{d\times K}$。随后，计算协方差矩阵 $\mathbf{\Sigma}^l = \mathbf{Z}^{l\top}\mathbf{Z}^l \in \mathbb{R}^{K\times K}$。对此协方差矩阵作对数行列式计算，即得文章所定义的 EigenScore：

$$\text{EigenScore} = \frac{1}{K}\log\det\left(\mathbf{\Sigma}^l\right) = \frac{1}{K}\sum_{i}^{K}\log(\lambda_i). \tag{2.6}$$

其中 λ 为协方差矩阵 $\mathbf{\Sigma}^l$ 的 K 个特征值。该指标反映了多次生成结果在内部表征空间中的分布情况，协方差矩阵特征值/对数行列式越大表示生成结果在该层的表征空间中分布越分散，可能对应更高的幻觉风险；反之，较小的特征值则表明生成结果在该层的表征空间中更为集中，可能对应更低的幻觉风险。在实际实验中，层数 l 通常取模型中间层，即总层数之一半 $l = L/2$。

CoE[35] 则代表了另一类无需训练的白盒思路，即直接从模型内部表征中构造可解释的几何或统计特征，并以此作为幻觉检测依据。相较于仅关注单一层、单一 token 的方法，这类工作更强调从内部表征整体结构中提取能够反映生成真实性的判别线索，且无需对同一问题采样多条输出，显著降低了检测成本。按照本文研究设定，CoE 属于无

需训练的方法，其核心价值在于不依赖额外标注训练，而是通过对内部表征结构属性的直接刻画实现幻觉判断。该方法大致计算思路如下：

首先定义“embedding 链”为各层的 embedding 表征所组成的序列，即：

$$\mathbf{H} = h_0 \to h_1 \to \cdots \to h_L. \tag{2.7}$$

其中，$h_l = \frac{1}{T}\sum_{t=1}^{T} h_l^t \in \mathbb{R}^d$ 为第 l 层的隐藏状态，d 为隐藏维度，由各输出 token 平均而来。随后，CoE 通过分析 embedding 链中不同层的表征分布特征，构造了一组基于链式内部表征结构的幻觉检测指标：

$$\text{CoE-R} = \frac{1}{L}\sum_{l=0}^{L-1}\left(\frac{M(h_l, h_{l+1})}{M(h_0, h_L)} - \frac{A(h_l, h_{l+1})}{A(h_0, h_L)}\right) \tag{2.8}$$

$$\text{CoE-C} = \frac{1}{L}\sqrt{\left(\sum_{l=0}^{L-1} M(h_l, h_{l+1})\cos(A(h_l, h_{l+1}))\right)^2 + \left(\sum_{l=0}^{L-1} M(h_l, h_{l+1})\sin(A(h_l, h_{l+1}))\right)^2} \tag{2.9}$$

其中，$M(\cdot)$ 和 $A(\cdot)$ 分别为两层表征之间的欧氏距离和由余弦相似度及反三角函数定义的角度。CoE-R 指标反映了 embedding 链中相邻层之间的平均距离和角度之差；CoE-C 指标则通过将相邻层之间的距离与角度结合起来，构建了一个综合反映 embedding 链整体结构特征的指标。当 embedding 链整体越平整，CoE 指标越高，幻觉风险越高；链越卷曲，CoE 指标越低，幻觉风险也较低。通过分析这些指标在不同生成结果上的分布情况，CoE 能够在无需训练的前提下实现对幻觉输出的有效识别。

总体而言，无需训练的白盒幻觉检测方法验证了这样一个重要事实：大语言模型内部表征中确实蕴含着与幻觉高度相关的判别信息，即使不借助额外监督训练，也能够在一定程度上实现有效检测。INSIDE 通过表示一致性揭示了内部状态与幻觉之间的关联，CoE 则进一步体现了从内部表征结构属性中直接构造检测信号的可行性。与此同时，现有无需训练方法大多仍停留在较粗粒度的计算或启发式建模层面，对于内部表征中更细致、更关键的判别特征挖掘仍显不足，这也为后续研究提供了改进空间。

2.2.2　需要额外训练的方法

与无需训练的方法不同，另一类白盒幻觉检测方法通常利用带标注数据对模型内部表征进行进一步建模，通过训练额外的探测器、分类器或干预模块，从隐藏状态中学习更具判别性的幻觉相关信号。该类方法的基本假设是：大语言模型内部不仅隐含了与生成内容真实性相关的潜在信息，而且这些信息可以通过适当的监督学习过程被更有效地提取出来。相较于直接构造启发式统计量的方法，基于训练的白盒方法通常能够学习更

复杂的判别边界，从而在特定任务或数据集上取得更好的检测性能；但与此同时，这类方法也往往需要额外的标注样本、训练开销以及更强的模型适配过程，其泛化能力和可迁移性也可能受到训练分布的影响。

SAPLMA[32] 是典型的属于需要训练的白盒方法。与直接利用手工构造统计量不同，该类方法更强调通过监督学习的方式，从隐藏状态中训练专门的判别模块，以识别模型输出是否存在幻觉。其核心思路在于，将生成过程中提取到的内部表示视为与真实性判断相关的特征输入，再借助分类器学习幻觉与非幻觉之间的区分边界。具体地，SAPLMA 方法使用一个简单的三层前馈神经网络和 ReLU 激活函数作为判别器，使用训练数据在大模型特定层上的隐藏表征作为输入，预测其相应的幻觉/非幻觉标签。相比无需训练的方法，SAPLMA 能够利用训练数据中的标签信息，从而捕捉更具任务针对性的表征模式。因此，这类方法通常在特定数据集上能够获得较好的检测效果。

ITI（Inference-Time Intervention）[31] 是该类方法中的代表性工作之一。该方法的核心思想在于：大语言模型的内部表征空间中往往存在与“真实性”或“事实性”相关的方向，若能够利用少量标注样本识别出这些方向，便可以在推理阶段对模型内部状态进行干预，从而影响最终输出的真实性表现。从白盒幻觉检测的视角看，ITI 表明模型隐藏状态中并非仅包含分布式、难以解释的语义信息，还可能蕴含可被线性探针捕捉的真实性判别结构。

该方法基于一个简单的“探测器”模型：

$$p_\theta(x_l^h) = \text{sigmoid}(\langle \theta, x_l^h \rangle), \tag{2.10}$$

其中 x_l^h 为第 l 层第 h 个注意力头的激活值，$\langle \cdot, \cdot \rangle$ 表示余弦相似度，$\theta \in \mathbb{R}^d$ 是可训练参数。在训练集 $\{(x_l^h, y)_i\}_{i=1}^N$ 上，该方法对大模型每一层的每一注意力头均训练一个式 2.10 所示的探测器，训练目标是最大化预测概率 $p_\theta(x_l^h)$（表示当前输出是否包含幻觉）与真实标签 y 的交叉熵。训练完成后，得到的参数 θ 可视为是在该注意力头位置上指向“生成幻觉内容”的方向。既可根据在验证集上的性能选择有最佳判别力的层和注意力头位置，又可根据训练得到的 θ 参数，在推理阶段对模型内部状态进行干预，引导模型生成更可靠的输出。该方法的重要意义在于，它从更加细粒度（注意力头激活值）的层面探索了幻觉内容的表征信号。

ACT-ViT[36] 进一步体现了通过训练机制深度挖掘内部激活信息的思路。该方法不再满足于利用单一层、单一位置或简单统计量来刻画模型状态，而是尝试将更完整的内部激活张量组织为适于学习的表示形式，并借助视觉 Transformer 模型建模其中的空间关联与判别模式。该方法的框架图如图 2-3 所示。

具体地，该方法将大模型在一次前向传播过程中提取到的内部激活张量视作一个具有丰富结构信息的对象：

$$\mathbf{A} \in \mathbb{R}^{L \times T \times d}. \tag{2.11}$$

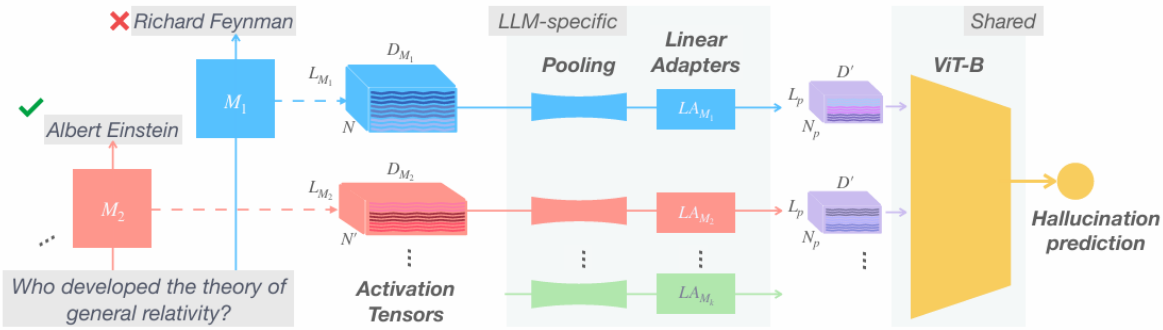

图 2-3 ACT-ViT 方法框架图

该张量具有三个维度，其中 L 为大模型层数，T 为 token 数量，d 为大模型内部隐藏维度。该张量涵盖了大模型各层、各位置的内部表征，可以视为是对生成过程的一个全局性建模。作者观察到，此三维张量相较于图像数据，具有类似于图像宽 × 高 × 通道的空间结构，因此借鉴视觉 Transformer（ViT）的设计思路，构建了一个基于 ViT 的轻量化判别模型来学习从内部激活到幻觉标签的映射关系。从方法设计上看，ACT-ViT 将内部激活视作具有丰富结构信息的对象，强调不同层、不同 token 位置之间的联合模式对于幻觉检测的重要性。这种思路相较于传统的探针式方法，充分挖掘了大模型所有的内部表征，有助于挖掘隐藏空间中更复杂的幻觉相关模式。与此同时，该方法也指出，既有白盒幻觉检测研究往往仅利用孤立的层或 token 位置，未能充分挖掘完整内部激活张量中所蕴含的丰富信息。

总体来看，需要训练的白盒幻觉检测方法相较于无需训练的方法，通常具备更强的特征学习能力，能够借助监督信号从高维内部表征中提取更具判别性的幻觉相关模式。SAPLMA 体现了基于监督分类器直接建模隐藏状态的可能性，ITI 验证了在注意力头表征空间中存在可供利用的真实性方向，而 ACT-ViT 则进一步说明，对完整内部激活结构进行联合建模有助于提升检测性能。然而，这类方法也普遍面临若干共同问题：其一，训练过程需要额外标注数据与计算开销；其二，基于训练的模型可能面临过拟合和泛化性能降低的风险。因此，围绕内部表征的有效表示、特征筛选与判别建模，仍是白盒幻觉检测领域的重要研究方向。

2.3　RAG 幻觉检测

检索增强生成（Retrieval-Augmented Generation, RAG）通过在生成前引入外部检索知识，为大语言模型提供与当前问题相关的补充信息，从而缓解仅依赖参数知识时可能出现的事实性错误。然而，外部知识的引入并不意味着幻觉问题被彻底消除。在实际应用中，即使给定了与问题相关的检索上下文，模型仍可能生成与检索内容不一致、未被

证据支持，甚至与外部知识相悖的回答。针对这一现象，RAG 幻觉检测旨在结合问题、检索文档与生成结果，判断当前输出是否真正得到了外部证据支持。与通用幻觉检测相比，RAG 幻觉检测的关键难点在于如何有效利用检索到的外部知识。一方面，检索文档通常包含冗余、噪声甚至相互冲突的信息，模型未必能够准确聚焦于与当前回答最相关的证据；另一方面，生成结果与检索内容之间的关系往往不是简单的词面重合，而涉及更复杂的语义对齐与证据支持关系。因此，如何刻画模型输出与外部知识之间的一致性，消解模型内外知识冲突，并据此识别 RAG 场景下的幻觉，是当前该方向研究的核心问题。

围绕这一目标，现有研究主要从证据一致性建模、证据支持强度分析以及检索知识利用过程刻画等角度展开探索。ReDeEP[38] 是较早关注 RAG 场景下外部知识利用与参数知识竞争关系的代表性工作之一。ReDeEP 认为幻觉的产生往往与两类因素有关：一是模型未能有效保留和利用检索得到的外部知识，二是模型在生成过程中对参数知识产生了过强依赖。为此，该方法分别定义了外部上下文分数（External Context Score, ECS）和参数知识分数（Parametric Knowledge Score, PKS），并将二者结合起来用于幻觉检测。

具体而言，ReDeEP 首先利用注意力头对检索文档的关注情况构造外部上下文分数。对于生成的最后一个 token，设某一层第 h 个注意力头选出的高注意力上下文 token 集合为 $I_n^{l,h}$，则其 token 级 ECS 定义为

$$E_n^{l,h} = \frac{e \cdot x_n^L}{\|e\| \, \|x_n^L\|}, \quad e = \frac{1}{|I_n^{l,h}|} \sum_{j \in I_n^{l,h}} x_j^L, \tag{2.12}$$

其中，x_n^L 表示最后一层中当前生成 token 的隐藏状态，e 表示被该注意力头重点关注的上下文 token 在最后一层隐藏状态上的平均表示。该分数本质上刻画了当前生成内容与其所关注外部证据之间的语义一致程度：分数越高，说明模型越可能有效利用了检索知识。

在此基础上，ReDeEP 进一步将参数知识分数与外部上下文分数进行线性组合，构造最终的幻觉检测分数。其 token 级检测函数写为

$$H_t(t) = \sum_{l \in F} \alpha P_t^l - \sum_{l,h \in A} \beta E_t^{l,h}, \tag{2.13}$$

其中，P_t^l 表示第 l 层 FFN 引入的参数知识分数（PKS），$E_t^{l,h}$ 表示对应注意力头的外部上下文分数（ECS），F 和 A 分别表示与参数知识和外部知识利用最相关的 FFN 层与注意力头集合，$\alpha, \beta > 0$ 为回归系数。由此可见，当模型对参数知识的依赖增强而对外部证据的利用减弱时，检测分数会增大，从而更倾向于判定为幻觉。ReDeEP 的意义在于，它不再仅从输出文本与检索文档的表层匹配关系出发，而是试图从模型内部机制层面直接地区分“外部知识利用不足”和“参数知识过度介入”这两种因素，从而为 RAG 幻觉检测提供了更具解释性的分析视角。

LUMINA[40] 同样从“外部上下文利用”与“内部知识利用”两个互补视角对 RAG 幻觉进行建模。LUMINA 分别定义外部上下文利用信号 E_{p_θ} 与内部知识利用信号 I_{p_θ}，并将二者组合为 token 级幻觉分数：

$$H_t(a_t \mid q, d, a_{<t}) = \lambda\, I_{p_\theta}(a_t \mid q, d, a_{<t}) - (1-\lambda)\, E_{p_\theta}(a_t \mid q, d, a_{<t}), \tag{2.14}$$

其中，q 表示输入问题，d 表示检索文档，$a_{<t}$ 表示当前 token 之前已生成的前缀，λ 为平衡内部知识与外部证据贡献的系数。由此可见，当内部知识利用更强而外部上下文利用更弱时，模型更倾向于被判定为产生幻觉。句子级幻觉分数则可由各 token 分数进一步求平均得到。

在外部上下文利用的刻画上，LUMINA 不再像 ReDeEP 那样依赖特定注意力头，而是直接比较模型在“相关检索文档”和“随机文档”条件下的下一 token 预测分布差异。设 $P(E_v) = p_\theta(v \mid q, d, a_{<t})$，$Q(E_v) = p_\theta(v \mid q, d', a_{<t})$，其中 d' 表示与问题无关的随机文档，E_v 表示词表中 token v 对应的嵌入表示，则 LUMINA 采用最大均值差异（Maximum Mean Discrepancy, MMD）来定义外部上下文利用分数：

$$\begin{aligned} E_{p_\theta}(a_t \mid q, d, a_{<t}) &:= \mathrm{MMD}_k^2(P, Q) \\ &= \mathbb{E}_{A,A'\sim P}[k(A, A')] + \mathbb{E}_{B,B'\sim Q}[k(B, B')] - 2\mathbb{E}_{A\sim P, B\sim Q}[k(A, B)], \end{aligned} \tag{2.15}$$

其中 $k(\cdot,\cdot)$ 为核函数，文中默认采用余弦核。该式反映了模型预测分布对文档语义变化的敏感程度：若将相关文档替换为随机文档后词表预测分布发生明显变化，则说明模型在生成当前 token 时更充分地利用了外部检索知识。与此同时，LUMINA 还通过跨层信息处理速率来定义内部知识利用信号，以刻画模型在生成过程中对内部参数知识的调用强度。整体而言，该方法以更少的超参数依赖，实现了对 RAG 场景下“上下文—知识”平衡关系的统一建模。

RAGLens[43] 则代表了另一类基于内部稀疏表征的 RAG 幻觉检测方法。与 ReDeEP 和 LUMINA 主要从外部上下文利用与参数知识竞争关系出发不同，RAGLens 借助稀疏自编码器（Sparse Autoencoder, SAE）对大语言模型内部激活进行解耦，显式挖掘与 RAG 幻觉相关的可解释稀疏特征。RAGLens 的核心思路是：先从冻结 LLM 的某一层隐藏状态中提取 SAE 稀疏特征，再通过最大池化将 token 级特征汇聚为实例级表示，随后用互信息筛选最有信息量的特征，最后通过广义加性模型完成幻觉判别。具体而言，设冻结大语言模型为 Φ，在第 L 层提取生成过程中第 t 个位置的隐藏状态 h_t，并通过对应的 SAE 编码器 E 映射为稀疏特征 z_t：

$$h_t = \Phi_L(y_{1:t}, q, C), \quad z_t = E(h_t), \quad z_t \in \mathbb{R}^K, \tag{2.16}$$

其中，q 表示用户问题，C 表示检索得到的上下文，$y_{1:t}$ 表示截至位置 t 的生成前缀，K 为 SAE 特征字典大小。该式表明，RAGLens 并非直接使用原始隐藏状态，而是先将

其转化为更稀疏、更具语义可解释性的特征表示，从而为后续幻觉检测提供更加紧凑的输入。由于 RAG 幻觉标签通常是实例级而非 token 级，RAGLens 进一步对所有位置上的稀疏激活进行通道级最大池化，并利用互信息筛选与幻觉标签最相关的特征，最终用广义加性模型完成预测。其实例级特征汇聚写为

$$\bar{z}_k = \max_{1 \le t \le T} z_{t,k}, \quad k = 1, \ldots, K, \tag{2.17}$$

其中，T 为生成序列长度，$\bar{z}_k$ 表示第 k 个稀疏特征在整个回答生成过程中的最大激活值。RAGLens 据此构造实例级特征向量 $\bar{z}$，并进一步结合互信息进行特征筛选，再用广义加性模型建模幻觉标签与所选特征之间的关系。该方法的特点在于，它利用经过 SAE 处理的 LLM 稀疏内部表征完成 RAG 幻觉检测，由于输入特征本身具有稀疏性与一定的语义单义性，因而在检测性能之外还提供了较强的可解释性。此方法的最大问题是，方法中来源于外部证据利用的特征并未得到充分挖掘，其对外部知识的利用仅为在模型生成过程中在文本级别引入检索上下文，仅在特征层面隐式地反映了外部知识利用的结果，但并未直接建模生成内容与检索文档之间的关系。

总体来看，现有基于外部证据建模的 RAG 幻觉检测方法已经形成了一个基本共识：在 RAG 场景下，幻觉检测不能仅依赖输出文本本身，而必须结合外部检索知识来判断生成内容是否得到外部知识支持。ReDeEP 和 LUMINA 方法显式地建模了外部证据利用和内部知识利用的程度，RAGLens 则从内部稀疏表征的角度提供了新的检测思路。这些工作为 RAG 幻觉检测研究提供了重要基础，但也表明如何充分利用外部检索知识信号，仍然是该方向有待解决的关键问题。

2.4 知识冲突消解

知识冲突通常指模型在生成过程中同时接收到来自不同知识来源的信号，而这些信号在同一问题上存在不一致甚至相互矛盾的情况[53–55]。对于大语言模型而言，常见的知识来源既包括预训练阶段所存储的参数知识，也包括推理阶段由输入上下文、外部检索文档或其他模态证据提供的显式信息。当这些知识来源在语义内容或事实判断上不一致时，模型需要在生成过程中对其进行选择、整合与权衡；若这一过程处理不当，便可能导致输出偏离外部证据或真实事实，从而产生幻觉。

在 RAG 场景中，知识冲突问题尤为突出。当参数知识与检索知识之间存在差异，或者检索文档内部本身包含噪声、冗余乃至相互冲突的信息时，模型仍可能依赖已有参数记忆生成回答，而忽视外部证据的约束。因此，许多 RAG 幻觉并非简单源于“缺乏知识”，而更可能源于“多种知识并存时未能正确完成选择与整合”。在知识冲突消解相关研究中，一类工作直接关注参数知识与上下文知识之间的竞争关系。大部分工作将模

型内部参数（如注意力头）简单划分为储存内部参数化知识的“记忆型”和阅读外部提供上下文知识的“上下文”型。与此不同，JuICE[54] 进一步发现，模型中一些关键注意力头往往同时承载参数知识与上下文信息，即存在所谓的“上下文信息与参数知识的叠加”现象。这表明，知识冲突并非仅仅体现为两类知识源在输出层面的竞争，更可能在模型内部的注意力机制中以叠加和耦合的方式存在。基于这一观察，作者提出了 JuICE 方法，通过测试时注意力干预，在无需微调的条件下将模型输出朝向参数知识或上下文知识一侧进行引导，从而缓解知识冲突带来的错误生成。首先，通过特制的数据集观察模型在不同输入时的输出概率分布，从而辨别出“记忆型”与“上下文型”注意力头；随后，在推理阶段进行两次前向传播推理：第一次推理时，记录下各注意力头的激活值；第二次推理时，对之前记录的激活值进行干预，将需要的相应类型注意力头激活值进行放大或抑制，从而引导模型更倾向于利用参数知识或上下文知识。

该工作的启发在于，它将知识冲突明确刻画为模型内部参数记忆与外部上下文证据之间的竞争过程，而不是简单地将错误回答归因为“缺乏知识”或“检索失败”。对于 RAG 幻觉检测而言，这意味着仅判断输出文本是否与检索文档一致仍然不够，还需要进一步明确、显式地区分内部与外部知识，以便更好地缓解其冲突带来的幻觉风险。

除直接定义和研究知识冲突消解的工作外，近年来一些相关领域的研究，也开始从知识编辑、多模态幻觉等角度，对知识冲突的识别与缓解进行探索。这些工作虽然面向的任务各不相同，但其关于“冲突如何定义”“冲突如何影响生成”“冲突如何被缓解”的分析，对理解 RAG 幻觉的形成机制具有重要启发。下面将从几个相关方向对知识冲突消解领域的代表性工作进行介绍。

知识编辑从另一角度揭示了知识冲突在模型内部表示空间中的另一种表现形式。知识编辑旨在不大幅微调更新模型参数的前提下，向模型注入新知识或删除旧知识[56,57]。类似于 RAG 幻觉问题的内外知识，知识编辑中，向模型输入的知识与模型原有的内部知识存在存在冲突；模型可能不能充分学习到新输入的知识，或虽能在新问题上表现良好，却对原有知识造成干扰。从这一意义上说，知识冲突并不只体现为不同知识源在输出层面的答案不一致，也可能体现为模型内部参数空间或表示空间中不同知识子空间之间的相互干扰。

为缓解这一问题，AlphaEdit[57] 在模型编辑过程中显式引入零空间约束（null-space constraint），其核心思想是：将知识编辑所施加的参数更新限制在尽可能不影响原有知识表示的子空间上，从而在写入新知识的同时保留已有知识。该方法表明，不同知识之间并非天然彼此独立，而往往共享部分表示空间；若编辑方向与保留知识所在子空间发生重叠，便容易引发知识干扰甚至连带遗忘。具体地，该方法在注入新知识前，首先对模型内部参数进行主成分分析；为新知识更新参数时，仅限在模型参数空间除主成分外的余子空间内进行。因此，对知识冲突的理解不应停留在文本输出层面，还应进一步关注冲突在内部表示空间中的几何结构。这一视角对 RAG 幻觉检测同样具有启发意义。在 RAG 场景中，模型生成回答时也需要在参数知识与外部检索知识之间进行动态

整合。若二者在内部表示空间中存在竞争、重叠或方向性偏移，那么最终产生的幻觉便可能对应于模型内部状态偏离了“由外部证据支持”的表示区域。由此可见，使内/外知识、新/旧知识在表示空间中得到更好的区分与整合，可能是缓解 RAG 幻觉的一个重要方向。

除 RAG 场景外，知识冲突的现象在多模态场景中同样存在。在多模态大模型中，**多模态幻觉**通常体现为模型生成的文本内容未能忠实反映视觉输入，而是受到语言先验的内部生成惯性的影响，从而产生幻觉[58–62]。尽管这类工作并非等同于 RAG 场景，但其核心关注点与 RAG 幻觉检测具有相似之处，即模型虽然已经获得了外部证据，却未能在生成过程中正确依赖这些证据。因此，这些关于输入证据与生成倾向冲突的研究，同样能够为 RAG 幻觉检测提供有价值的启发。

Self-Introspective Decoding（SID）[59] 从解码阶段出发研究大视觉语言模型中的幻觉缓解问题。该方法指出，已有基于对比式解码的工作通过构造受扰动的视觉或文本输入来放大模型幻觉行为，再利用正常输入与扰动输入之间的差异抑制错误生成；然而，这类粗粒度扰动往往会引入额外噪声，难以精确刻画视觉证据与语言生成之间真正的冲突来源。为此，SID 进一步利用模型自身的注意力分布，对视觉 token 的重要性进行自省式评估，并据此保留低重要性的视觉 token 来构造更加细粒度的幻觉型对比分支，从而在推理阶段增强模型对视觉证据的敏感性，抑制由语言先验主导的幻觉输出。具体而言，该方法在推理时进行两支并行的前向传播：一支为正常的推理计算；另一支为对比分支，将删除注意力显著性最高的前 $k\%$ 个视觉 token，引导模型生成不依赖视觉语义的幻觉型分布。最后，在每一 token 生成前，将正常分支与对比分支的 logits 以一定比例相减，即得到幻觉含量较低的视觉忠实输出。这一思路的关键启发在于：幻觉程度和外部知识利用程度的建模可以基于注意力机制进行内省式估计。因此，在 RAG 幻觉检测中，除了考察输出与检索文档是否一致之外，类似于视觉 token，也可利用内省式策略关注到文档中最核心的关键信息。

Visual and Textual Intervention（VTI）[60] 则从潜在表示空间的角度解释并缓解多模态幻觉。该方法认为，大视觉语言模型的幻觉生成在很大程度上源于视觉输入特征不稳定以及视觉信息与文本解码过程之间的失配，这种失配本质上也是输入证据与生成倾向之间的一种冲突。基于这一观察，作者提出在推理阶段对模型潜在表示进行调整，通过预先估计有助于忠实生成的视觉方向与文本方向，对中间表示施加引导，从而使生成过程更加依赖稳定且可信的输入证据。具体地，该方法利用在视觉端对多张图像作多次随机扰动，得到利用视觉信息所在的调整向量；同理，通过文本端的扰动得到文本模态的调整向量。最后，在推理时，在原始 embedding 空间中接入这些记录下来的各层各 token 处的调整向量，便可得到忠实度更高的输出。与直接在输出层面进行后处理不同，这类方法强调幻觉的形成与缓解都可以在隐藏表示空间中得到刻画。对 RAG 幻觉检测而言，这一观点同样具有重要意义：当模型内部状态逐渐偏离“由外部检索知识支持”的表示方向时，便更有可能生成与证据不一致的内容。因此，从潜在空间偏移的角度理解外部

知识利用不足，也为 RAG 场景下知识冲突的分析提供了新的视角。

以上两类多模态幻觉缓解方法都使用了随机扰动 + 平均 + 对比调整的方法。虽是面向视觉语言的生成任务，但它们都共同表明：模型生成错误内容的根本原因之一，在于外部输入证据未能在生成过程中有效约束内部生成倾向。从知识冲突的角度来理解，不论是视觉信息还是检索文本，充分挖掘输入证据的表征、刻画外部信息的利用程度，都是检测和缓解 RAG 幻觉的关键所在。

总体而言，知识冲突的问题存在于包含 RAG 幻觉检测的多个领域内。无论是直接研究知识冲突消解的工作，还是从知识编辑、多模态幻觉等角度间接涉及知识冲突的研究，都表明了与 2.3 节相似的结论：要真正理解和缓解 RAG 幻觉，必须深入模型内部参数空间，从内部表征合理建模不同的知识来源；同时必须在如不同模型部件、参数空间向量等层面上明确显式区分不同知识来源，以便更好地消解其间的冲突。

2.5　本章小结

本章主要介绍了与本文研究内容密切相关的代表性工作与技术基础。

首先，在 2.1 节中，本文介绍了大语言模型、RAG 框架以及稀疏自编码器的基本概念和相关技术。其次，在 2.2 节中，本文系统回顾了当前通用幻觉检测领域中基于大模型内部表征的白盒方法，重点介绍其如何从隐藏状态、激活模式或内部语义特征中挖掘可用于识别幻觉的判别信号，并分析现有方法在特征利用方式或检测能力方面的特点与不足。随后，在 2.3 节中，本文进一步介绍了 RAG 幻觉检测领域的代表性工作，重点关注现有方法如何利用检索得到的外部上下文来判断生成内容是否与证据一致。最后，在 2.4 节中，本文从更一般的知识冲突视角出发，梳理知识冲突的定义方式及其相关建模与消解方法，分析其对 RAG 幻觉检测任务的启发。

上述内容将为后续章节中提出的两种幻觉检测方法奠定理论基础，也为理解本文的技术创新提供了必要的背景知识。

第三章　基于多方向表征建模的幻觉检测方法

如何充分利用大语言模型的内部表征来提升幻觉检测性能，是当前研究的一个重要方向。现有方法对大模型内部表征利用的不充分体现常在两方面：一是**单方向建模局限**，多数方法仅沿 layer 或 token 单一方向分析表示，忽略了二者之间的耦合结构；二是**静态表示局限**，仅关注局部或单点表示，缺乏对表示随生成过程演化的整体建模。上述局限使得模型难以充分刻画隐藏状态中的动态异常模式，从而限制了幻觉检测性能。

本章针对现有方法内部表征信息利用不充分的问题，提出 ATScore（Activation Tensor Score）算法，在三维激活张量的统一视角下看待跨层和跨 token 方向的表征信息，从两个维度挖掘模型内部链式表征中蕴含的幻觉线索，最终实现对内部表征信息的充分利用。

3.1　问题设定

本文采用当前较为主流且实现简便的大模型幻觉检测问题定义。给定一个大模型 M、一段用户输入文本的 token 序列 $X = \{x_1, x_2, \ldots, x_n\}$ 及其对应的标准答案 $Z = \{z_1, z_2, \ldots, z_k\}$，以及模型生成的输出文本 token 序列 $Y = \{y_1, y_2, \ldots, y_m\}$，其中 n、k 和 m 分别表示对应序列中的 token 数量。幻觉检测任务的目标是判断模型生成的输出文本 Y 中是否包含幻觉内容，即判断其是否与标准答案 Z 在语义上保持一致。

从形式上看，幻觉检测可以建模为一个二分类问题，其目标是学习如下判别函数：

$$f(M, X, Y) \rightarrow \{0, 1\}, \tag{3.1}$$

其中，f 表示幻觉检测模型。当输出为 1 时，表示模型输出中存在幻觉内容；当输出为 0 时，表示模型输出中不存在幻觉内容。换言之，该任务关注的是模型输出的事实正确性或语义一致性，而非仅仅关注其语言表达是否流畅自然。

在白盒设定下，除了模型生成的输出文本 Y 之外，大模型在生成过程中产生的一系列内部隐藏状态同样是可获取的。此时，幻觉检测问题可以建模为：

$$f(M, X, Y, H) \rightarrow \{0, 1\}, \tag{3.2}$$

其中 H 表示模型在生成过程中得到的内部表征集合。这些内部表征包含了模型在不同层、不同 token 位置上的中间语义信息，因此也可以作为额外输入提供给幻觉检测模型，以辅助判断模型输出的幻觉程度。相比仅依赖最终输出文本的黑盒设定，白盒设定能够更加充分地利用模型内部信息，为幻觉检测提供更丰富的判别依据。

进一步地，关于“模型输出是否与标准答案一致”的判定方式，需要结合具体数据集的任务形式来确定。在封闭式问题设定中，例如选择题、判断题等任务，模型输出通常具有较为明确的标准形式。此时，可以先利用正则表达式等工具对模型输出进行解析，再将解析结果与标准答案进行直接比较，从而判断模型是否回答正确。由于此类任务答案空间相对有限，因此判定标准通常较为直接。

而在开放式问题设定中，例如问答任务、开放生成任务等，模型输出往往具有较强的表达多样性。即使模型输出与标准答案在语义上相符，其表面形式也可能存在较大差异。因此，在这类场景下，通常需要采用更复杂的评判标准，以避免仅依据字面匹配造成误判。常见的评判方式包括基于文本相似度的自动评判方法，如 BLEU[63]、ROUGE[22]、BERTScore[64] 等；此外，也可以采用基于人工标注或更强大模型评判的方式。例如，可将标准答案与模型输出按照预设模板进行拼接，并输入到具有较高知识能力的大模型中，由其给出“相符”或“不相符”的判断结果。

综上所述，幻觉检测任务的核心在于建立从模型、输入与输出到幻觉标签之间的映射关系，而具体的一致性判定方式则依赖于任务形式与数据集特征。在本章实验中，本文将根据不同数据集的具体特点，选取与其任务形式相适应的评判标准，以保证幻觉检测任务定义的合理性与实验结论的有效性。

3.2 ATScore 算法

本方法属于无需训练的白盒幻觉检测方法，核心思想是从大语言模型内部表征中构建三维激活张量，并在该统一视角下挖掘跨层和跨 token 方向的幻觉线索，最终构建一个稳定、有效且免于训练的幻觉检测信号。本方法的框架结构图如图 3-1 所示。后续章节将按步骤详细介绍 ATScore 算法的设计与实现。

3.2.1 三维内部表征建模

在大语言模型的生成过程中，隐藏状态不仅在层间逐步演化，同时也随着生成序列在时间维度上不断展开。因此，如何从多维度刻画内部表征的动态变化，对于识别潜在的幻觉信号具有重要意义。模型在生成过程中产生的不稳定或异常表征，往往可以通过隐藏状态的结构性变化体现出来。为系统刻画这一过程，本文采用与已有工作[36] 一致的内部表征提取方式，并在此基础上进行统一建模。具体而言，类似于式 2.11 ，我们定义“激活张量”（Activation Tensor）为 $A \in \mathbb{R}^{L\times T\times d}$，其中 L 表示 Transformer 的层数，T 表示生成输出文本的 token 数量，d 表示每层隐藏状态的维度。

具体地，对于生成输出序列中的每一个 token y_t（$t = 1, 2, \ldots, T$），我们提取模型在生成该 token 时各层 Transformer 模块的隐藏状态，即

$$A_{:,t,:} = \{\mathbf{a}_{1,t}, \mathbf{a}_{2,t}, \ldots, \mathbf{a}_{L,t}\}. \tag{3.3}$$

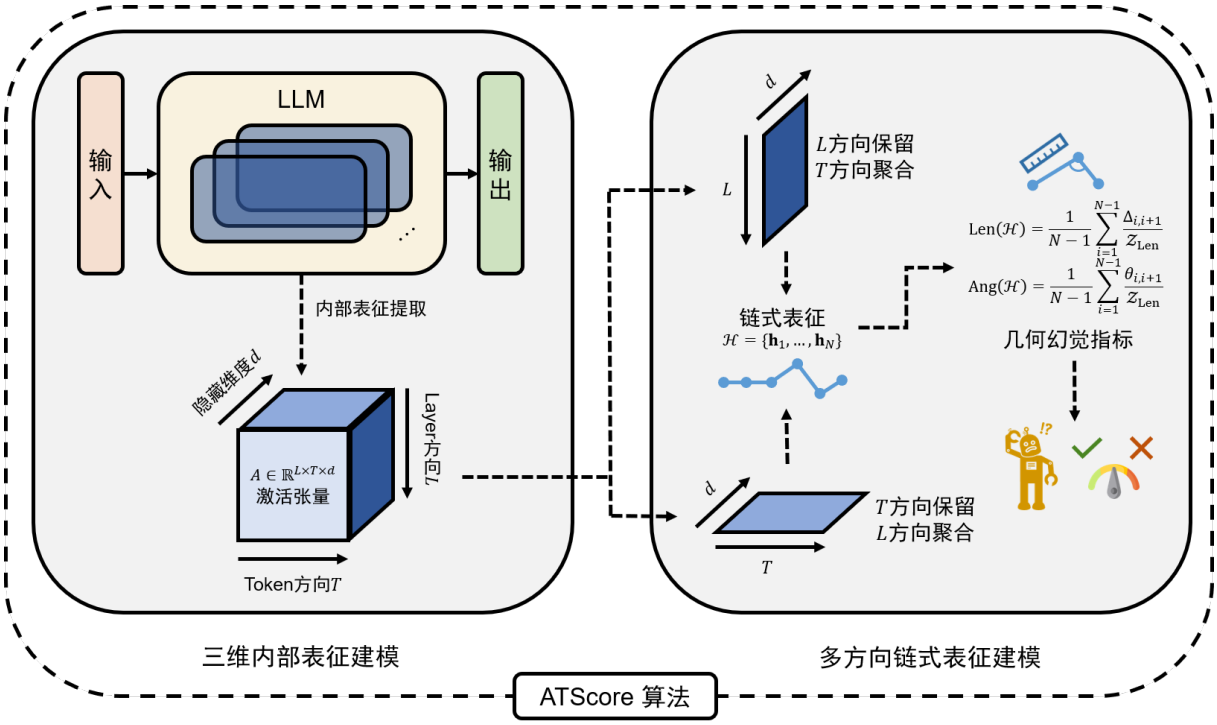

图 3-1 ATScore 算法框架图

其中 $\mathbf{a}_{\ell,t} \in \mathbb{R}^d$ 表示第 ℓ 层在生成第 t 个 token 时的隐藏状态向量。通过对所有 token 重复该过程，可以构建完整的三维激活张量 A，从而同时保留跨层（layer-wise）与跨 token（token-wise）的表征信息。

与仅关注单层或单 token 位置的局部表示不同，该三维张量提供了一种更加结构化的视角，使得我们能够从不同维度刻画模型内部表征的变化模式。例如，沿 layer 维度可以刻画信息在网络深度方向上的传播过程，而沿 token 维度则反映生成序列随时间展开的语义演化轨迹。这种多维结构为后续挖掘幻觉相关信号提供了更丰富的信息基础。

在此基础上，本文进一步引入“链式表示”（Chain Representation）的概念，将高维激活张量在特定方向上展开为一系列有序的向量序列，从而将复杂的三维表征结构转化为可分析的表示演化轨迹。具体的链式构建方式将在下一小节中进行详细介绍。

3.2.2　多方向链式表征建模

现有研究已经表明，将隐藏状态在某一方向上组织为有序向量序列，有助于刻画大语言模型在推理过程中的潜在表示变化轨迹[35]。受此启发，本文进一步提出多方向链式表征建模方法，即在激活张量的两个正交方向上分别构造链式表示，从不同视角刻画内部表征的演化模式。与仅关注单一层、单一 token 位置的静态探测方式不同，该建模方式能够将三维内部表征转化为可分析的表示轨迹，从而更充分地利用大模型内部状态中与幻觉相关的动态信息。

链式表征的基本定义

设 $\mathbf{a}_{\ell,t} \in \mathbb{R}^d$ 表示激活张量中第 ℓ 层、第 t 个 token 对应的隐藏状态向量，其中 $\ell = 1, 2, \ldots, L$，$t = 1, 2, \ldots, T$。链式表征的目标是将原始的三维张量映射为一条由若干 embedding 组成的有序链；为此，在保留某一主方向顺序结构的同时，需对另一辅助方向进行压缩聚合。从而形式上，若链中共有 N 个状态点，则可表示为

$$\mathcal{H} = \{\mathbf{h}_1, \mathbf{h}_2, \ldots, \mathbf{h}_N\}, \qquad \mathbf{h}_i \in \mathbb{R}^d. \tag{3.4}$$

这里，$\mathcal{H}$ 中的每一个状态向量 $\mathbf{h}_i$ 可视为三维激活张量 A 在某一主方向位置上、融合另一辅助方向信息后得到的表征摘要。由于这些状态向量具有天然的顺序关系，因此可以进一步视为潜在表示空间中的一条离散轨迹。类似于人类大脑思考问题时的逻辑链，这些状态向量同样可以在某种程度上视为是大模型的“思维链”。本文的基本假设是：当模型生成事实一致、语义可靠的内容时，其内部表示轨迹通常更平滑、更稳定，并呈现出不同于幻觉生成样本的几何特征；相反，当模型生成幻觉内容时，内部状态往往会出现异常的跳变、偏折或不一致性，这些差异可以通过链式表征的几何统计量加以刻画。

基于“主方向–辅助方向”的建模思想，本文考虑如下两类互补的链式构造方式。

基于 layer 主方向的链式表征

第一类链式表征以 layer 为主方向，即保持网络深度方向上的顺序结构，同时对 token 方向的信息进行聚合。该方式与已有工作[35] 中从层间表示演化角度刻画模型内部状态的思路一致，其关注的是：对于同一段生成文本，模型的整体句子级表示如何随着网络层数逐步变化。

具体而言，对于第 ℓ 层的所有 token 隐藏状态 $\{\mathbf{a}_{\ell,1}, \mathbf{a}_{\ell,2}, \ldots, \mathbf{a}_{\ell,T}\}$，本文在 token 方向采用聚合算子 $\phi_t(\cdot)$，得到该层对应的链状态

$$\mathbf{h}_\ell^{(\text{layer})} = \phi_t\big(\mathbf{a}_{\ell,1}, \mathbf{a}_{\ell,2}, \ldots, \mathbf{a}_{\ell,T}\big), \quad \ell = 1, 2, \ldots, L. \tag{3.5}$$

于是可得到一条长度为 L 的 layer 链

$$\mathcal{H}^{(\text{layer})} = \left\{\mathbf{h}_1^{(\text{layer})}, \mathbf{h}_2^{(\text{layer})}, \ldots, \mathbf{h}_L^{(\text{layer})}\right\}. \tag{3.6}$$

其中，token 方向的聚合算子 $\phi_t(\cdot)$ 可以有多种实现方式。本文重点考虑如下两种简单而有效的无参数聚合方式：

$$\phi_t^{\text{avg}} = \frac{1}{T}\sum_{t=1}^{T} \mathbf{a}_{\ell,t}, \tag{3.7}$$

即对该层所有 token 隐藏状态取平均，以获得句子级全局表示；以及

$$\phi_t^{\text{last}} = \mathbf{a}_{\ell,T}, \tag{3.8}$$

即取最后一个输出 token 对应的隐藏状态，以强调生成末端的决策信息。前者更关注整体语义摘要，后者则更接近许多语言模型中常用的末位置表征方式。因大模型的逐 token 输出特性，末 token 通常能够携带更多的上下文信息，适于用作句子级表征。通过比较不同聚合方式，能够考察辅助方向压缩策略对链式几何特征的影响。

基于 token 主方向的链式表征

与上述方法不同，本文更关注另一种对偶但尚未被充分研究的建模视角，即以 token 为主方向构建链式表征，同时对 layer 方向进行聚合。该方式保留了生成序列随时间展开的顺序结构，关注的是：在整个生成过程中，每个位置上的表示在融合多层信息后如何形成一条沿输出序列推进的潜在语义轨迹。

具体而言，对于第 t 个 token 在所有层上的隐藏状态 $\{\mathbf{a}_{1,t}, \mathbf{a}_{2,t}, \ldots, \mathbf{a}_{L,t}\}$，本文在 layer 方向采用聚合算子 $\phi_\ell(\cdot)$，得到该 token 对应的链状态

$$\mathbf{h}_t^{(\text{token})} = \phi_\ell\big(\mathbf{a}_{1,t}, \mathbf{a}_{2,t}, \ldots, \mathbf{a}_{L,t}\big), \qquad t = 1, 2, \ldots, T, \tag{3.9}$$

从而构造出一条长度为 T 的 token 链

$$\mathcal{H}^{(\text{token})} = \left\{\mathbf{h}_1^{(\text{token})}, \mathbf{h}_2^{(\text{token})}, \ldots, \mathbf{h}_T^{(\text{token})}\right\}. \tag{3.10}$$

类似地，layer 方向的聚合算子 $\phi_\ell(\cdot)$ 也可采用无参数聚合方式实现，例如

$$\phi_\ell^{\text{avg}} = \frac{1}{L}\sum_{\ell=1}^{L} \mathbf{a}_{\ell,t}, \tag{3.11}$$

以及

$$\phi_\ell^{\text{last}} = \mathbf{a}_{L,t}. \tag{3.12}$$

其中，式 3.11 通过聚合多层信息获得更加平滑、全面的 token 级表示；式 3.12 则突出最高层对当前 token 的最终语义编码。类似于人类大脑中语言思维发展的方向，与沿 layer 方向构链相比，沿 token 方向构链能够更直接地刻画生成过程中的逐步语义推进与局部状态变化，因此对于识别“模型在何处开始偏离事实约束”这一问题具有更强的刻画能力。这也是本文相较于已有链式表征方法的重要区别之一。

辅助方向聚合的可能变体

除了上述 avg 与 last 两类基础聚合方式外，辅助方向的压缩还可以扩展为更多变体。例如，可以仅对中间若干层进行平均，以突出模型内部较稳定的语义表征；也可以对前

后若干 token 进行局部窗口聚合，以降低极端位置噪声对链式表征的影响；还可以引入加权平均形式，使不同层或不同 token 在聚合时具有不同贡献。若记辅助方向上的若干隐藏状态为 $\{\mathbf{v}_1, \mathbf{v}_2, \ldots, \mathbf{v}_m\}$，则更一般的聚合形式可写为

$$\phi(\mathbf{v}_1, \ldots, \mathbf{v}_m) = \sum_{i=1}^{m} w_i \mathbf{v}_i, \quad \sum_{i=1}^{m} w_i = 1. \tag{3.13}$$

其中 w_i 为预先设定或数据驱动得到的权重。本文主要采用无参数的 last 与 avg 两类聚合方式，一方面是因为其形式简单、计算代价低；另一方面也有助于避免额外训练参数带来的模型依赖性，从而更好地体现无需训练（training-free）方法在跨模型、跨领域设定下的泛化优势。本文以下实验部分若无特殊说明，默认采用 last 方式进行辅助方向聚合。我们将在 3.3.3 小节中探讨辅助方向聚合方式的选择。

链式表征的几何指标构造

链式表征 $\mathcal{H}$ 可视为嵌入空间 $\mathbb{R}^d$ 中的一条离散轨迹（discrete trajectory），其沿序列维度刻画了隐藏状态的演化过程。从这一视角出发，轨迹的几何性质（如路径长度与方向变化）能够反映表示的稳定性与一致性，从而为刻画生成过程中的潜在异常提供依据。为刻画链式表征的几何特性，本文关注两类统计量：路径长度用于衡量表示变化的幅度，转折角度用于刻画表示变化的方向稳定性。直观而言，语义一致的生成过程通常对应于平滑且稳定的表示轨迹，而幻觉生成过程则更可能表现为幅度波动或方向突变，因此上述几何指标能够有效区分两类生成模式。设链式表征为式 3.4 所示，则第 i 个相邻状态对之间的位移长度可表示为

$$\Delta_{i,i+1} = \|\mathbf{h}_{i+1} - \mathbf{h}_i\|_2, \quad i = 1, 2, \ldots, N-1. \tag{3.14}$$

首先，本文考虑链节点间的平均长度（chain length），用于衡量整条表示轨迹在潜在空间中的累计变化幅度：

$$\mathrm{Len}(\mathcal{H}) = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{\Delta_{i,i+1}}{\mathcal{Z}_{\mathrm{Len}}} = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{\|\mathbf{h}_{i+1} - \mathbf{h}_i\|_2}{\mathcal{Z}_{\mathrm{Len}}}. \tag{3.15}$$

其中 $\mathcal{Z}_{\mathrm{Len}}$ 为归一化因子，定义为 $\mathcal{Z}_{\mathrm{Len}} = \Delta_{1,N} = \|\mathbf{h}_N - \mathbf{h}_1\|_2$，即链的端到端距离。该指标越大，表示链在相邻状态之间的累计变化越剧烈，模型内部表征演化越不平稳。

进一步地，为刻画链式表征在方向上的折转程度，本文定义相邻位表征向量之间的夹角。对于第 i 个内部节点，其对应的局部转角由余弦相似度的反三角函数得到，可写为

$$\theta_{i,i+1} = \arccos\left(\frac{\mathbf{h}_{i+1}^\top \mathbf{h}_i}{\|\mathbf{h}_{i+1}\|_2 \, \|\mathbf{h}_i\|_2}\right), \quad i = 1, 2, \ldots, N-1. \tag{3.16}$$

在此基础上，可定义链的平均转折角度（turning angle）为

$$\mathrm{Ang}(\mathcal{H}) = \frac{1}{N-1}\sum_{i=1}^{N-1}\frac{\theta_{i,i+1}}{\mathcal{Z}_{\mathrm{Ang}}}. \tag{3.17}$$

其中 $\mathcal{Z}_{\mathrm{Ang}} = \theta_{1,N}$ 为归一化因子，即链两端间的转折角，用于将角度变化标准化。该类指标反映了表示轨迹在局部方向上的频繁偏折程度。通常而言，若模型生成过程更加一致、连贯，其内部轨迹往往更平滑，对应较小的局部角度变化；而在生成幻觉内容时，模型可能在内部空间中出现更频繁的方向突变，从而表现出更大的弯曲度。

我们将以上 ATScore 算法步骤总结在算法 3.1 中，以便清晰地展示 ATScore 算法的整体流程。其中，当主方向为 layer 时，辅助方向聚合算子 $\phi_t(\cdot)$ 可取 token 方向平均池化或末 token 池化；当主方向为 token 时，辅助方向聚合算子 $\phi_\ell(\cdot)$ 可取 layer 方向平均池化或末层池化。其具体定义分别见式 3.7 、式 3.8 、式 3.11 与式 3.12 。

综上，本文通过在 layer 与 token 两个方向上构造互补的链式表征，并进一步提取链长、弯曲度、端到端位移及曲折程度等几何统计量。上述指标共同从幅值变化、方向变化和整体路径形态等多个方面刻画链式表征的几何属性，实现了从三维激活张量到低复杂度、可解释幻觉信号的映射。该建模方式不仅继承了链式表征对内部状态动态变化的刻画能力，还进一步扩展到 token 主方向建模视角，从而能够更系统地利用大语言模型内部表征中的多方向结构信息，为后续的幻觉检测打下基础。值得注意的是，本方法无需额外训练，直接从大模型内部参数中提取幻觉信号，其有效性基于如下观察：大语言模型在生成过程中，其隐藏状态已隐式编码了语义一致性与知识可靠性信息。通过对表示演化轨迹进行几何分析，可以直接从这些内部信号中提取与幻觉相关的判别特征，从而避免对额外监督数据的依赖，提升了可用性与泛化性。

3.3 实验分析

在本小节中，我们将通过一系列实验来验证 ATScore 算法在幻觉检测任务中的有效性与泛化能力，并通过消融实验分析不同设计选择对检测性能的影响。具体而言，我们将首先介绍实验设置，包括数据集、评测指标和对比方法；随后展示主要实验结果，并与现有主流方法进行对比分析；最后通过消融实验探讨链式表征构建方式、输出结果评价方式等设计因素对检测性能的贡献。

3.3.1 实验设置

本文在多个常用幻觉检测数据集上与现有主流方法进行对比评测，以验证 ATScore 算法在不同任务和不同领域上的有效性与泛化能力。参考现有主流工作[35,31]，在实验中，我们采用五个公开数据集，涵盖了数学问题、常识问答、定理证明、事实性问答等

算法 3.1 ATScore 算法

输入: 激活张量 $A \in \mathbb{R}^{L\times T\times d}$，其中 $\mathbf{a}_{\ell,t} \in \mathbb{R}^d$；主方向 $m \in \{\text{layer}, \text{token}\}$；辅助方向聚合方式 $\phi \in \{\text{avg}, \text{last}\}$；几何指标类型 $g \in \{\text{Len}, \text{Ang}\}$

输出: 幻觉分数 s

if $m = \text{layer}$ **then**
  $\mathbf{h}_\ell \leftarrow \phi_t(\mathbf{a}_{\ell,1}, \mathbf{a}_{\ell,2}, \ldots, \mathbf{a}_{\ell,T}),\ \ell = 1, 2, \ldots, L$
  $\mathcal{H} \leftarrow \{\mathbf{h}_1, \mathbf{h}_2, \ldots, \mathbf{h}_L\}, \quad N \leftarrow L$
else
  $\mathbf{h}_t \leftarrow \phi_\ell(\mathbf{a}_{1,t}, \mathbf{a}_{2,t}, \ldots, \mathbf{a}_{L,t}),\ t = 1, 2, \ldots, T$
  $\mathcal{H} \leftarrow \{\mathbf{h}_1, \mathbf{h}_2, \ldots, \mathbf{h}_T\}, \quad N \leftarrow T$
end if
for $i = 1, 2, \ldots, N-1$ **do**
  $\Delta_{i,i+1} \leftarrow \|\mathbf{h}_{i+1} - \mathbf{h}_i\|_2$
  $\theta_{i,i+1} \leftarrow \arccos\left(\dfrac{\mathbf{h}_{i+1}^\top \mathbf{h}_i}{\|\mathbf{h}_{i+1}\|_2\, \|\mathbf{h}_i\|_2}\right)$
end for
$\mathcal{Z}_{\text{Len}} \leftarrow \|\mathbf{h}_N - \mathbf{h}_1\|_2$
$\mathcal{Z}_{\text{Ang}} \leftarrow \arccos\left(\dfrac{\mathbf{h}_N^\top \mathbf{h}_1}{\|\mathbf{h}_N\|_2\, \|\mathbf{h}_1\|_2}\right)$
if $g = \text{Len}$ **then**
  $s \leftarrow \dfrac{1}{N-1} \sum_{i=1}^{N-1} \dfrac{\Delta_{i,i+1}}{\mathcal{Z}_{\text{Len}}}$
else
  $s \leftarrow \dfrac{1}{N-1} \sum_{i=1}^{N-1} \dfrac{\theta_{i,i+1}}{\mathcal{Z}_{\text{Ang}}}$
end if
return s

多种任务类型和领域背景；采用幻觉检测领域最常见的三个评价指标来衡量比较算法性能；并与多种当前的主流方法进行性能对比。

数据集

GSM8K[65]。GSM8K（Grade School Math 8K）是一个包含 8500 个高质量、语言多样化的中小学数学文字题的数据集。该数据集旨在支持解决基本数学问题的任务，这些问题需要多步骤推理。解决该问题需涉及执行一系列基础计算，可使用基本算术运算来达到最终答案。每条数据包含以自然语言描述的问题，问题的数值解及相应的包含思路步骤的答案字符串。为简便起见，我们使用 GSM8K 的一个子数据集 MGSM（Multilingual Grade School Math Benchmark）[66]，其中包含了从 GSM8K 中抽取的 250 个问题，并通过人工注释者翻译成了 10 种语言。在实验中，我们使用 MGSM 的英文版本进行评测。

CommonsenseQA[67]。CommonsenseQA（CSQA）是一个包含 12102 个问题的常识问答数据集，旨在评测模型的常识推理能力。每个问题由一个问题文本和 5 个候选答案组成，其中只有一个是正确的。问题涵盖了广泛的常识领域，如物理、社会、心理等，要求模型能够理解和应用常识知识来选择正确答案。我们使用其 validation 集进行评测，包含 1221 条数据。

TheoremQA[68]。TheoremQA 数据集包含 800 个问答对，覆盖了超过 350 条定理，这些定理跨越数学、电子与计算机科学、物理和金融领域，难度为大学本科专业水平。该数据集由人类专家以非常高的质量收集而成，可用于测试大型语言模型在解决具有挑战性的大学级别问题时应用定理的能力。其中包含选择题、判断题与开放式问题。每条数据包含以自然语言描述的问题文本，答案类型（文本、数值整型、数值浮点型）及答案字符串。我们使用全部 800 条数据进行评测。

TruthfulQA[69]。TruthfulQA 是一个专门用于评估语言模型在回答真实世界问题时真实性的开放式问答数据集。其设计目标是测试模型是否能够避免生成基于人类误解或错误认知的虚假答案，同时确保答案的准确性和信息性。该数据集包含 817 条问题，每条问题都配有一个或多个正确答案以及一些常见的错误答案，这些错误答案常基于人类的常识性误解或错误认知。我们使用全部 817 条数据进行评测。

Belebele[70]。Belebele 数据集是一个多语言、多任务、多领域的阅读理解数据集，涵盖了 122 种语言变体，包括英语、中文、西班牙语、阿拉伯语、法语等。这个数据集旨在推动多语言阅读理解技术的发展，并为跨语言、跨文化的人工智能应用提供支持。Belebele 数据集由 900 个问题组成，每个问题有包含一篇短文和问题的输入文本及四个多项选择答案，其中只有一个是正确的。我们使用全部 900 条数据进行评测。

我们将以上数据集总结如表 3.1 所示。

评价指标

对于模型输出本身的正确性判断，根据数据集类型的不同分为两类：

表 3.1 ATScore 实验数据集概览

数据集	样本数	任务类型	领域背景
GSM8K（MGSM）	250	开放式	中小学数学题
CommonsenseQA	1,221	封闭式	社会生活常识题
TheoremQA	800	开放式 + 封闭式	理工、金融领域专业题
TruthfulQA	817	开放式	常识性易错题
Belebele	900	封闭式	短文阅读理解题

- 封闭式问题。这类问题通常有确切的答案，如选项（A、B、C 等）或正误（True、False 等）。见于数据集 CommonsenseQA、Belebele。这类问题的回答可通过简单的比较得到准确的正确性判断。例如，使用正则表达式等工具对回答文本进行解析后，进行字符串比较。

- 开放式问题。这类问题的回答通常没有确定的范围，如自然语言文本或数值（2025、3.1 等）。对于数值型（见于数据集 GSM8K、TheoremQA）回答，可通过正则表达式提取答案字符串后，转换为给定数值变量类型（如 float、int 型等），后进行数值级别的比较。对于自然语言文本型（见 TruthfulQA）回答，本文通过基于字符级别相似度的简单匹配法（ROUGE-L 算法）和基于模板提示词 + 大模型裁判的方法（LLM judge）转为“真实/幻觉”标签。

通过以上方法得到每 QA 对的“真实/幻觉”参考标签后，即可与算法输出的幻觉程度指标计算一致程度。在本实验中，由于大模型裁判方法对语义理解的能力强于字符级别匹配的方法，对 TruthfulQA 数据集的正确性判断默认采用大模型裁判方法。进一步地，为区分各幻觉检测算法的性能，本文采用现有幻觉检测与不确定性估计研究中常用的三类评价指标，即 AUROC、FPR95 和 AUPR，以从不同角度衡量各方法对幻觉样本与事实性样本的区分能力。下面分别进行介绍。

AUROC。AUROC（Area Under the Receiver Operating Characteristic Curve）表示接收者操作特征曲线（ROC 曲线）下的面积。其中，ROC 曲线以假正例率（False Positive Rate, FPR）为横轴，以真正例率（True Positive Rate, TPR）为纵轴，描述分类阈值变化时检测器在不同工作点下的整体表现。AUROC 本质上衡量的是检测器对正负样本的排序能力，即随机取一个正样本和一个负样本时，模型将正样本赋予更高风险分数的概率。其取值范围为 $[0, 1]$，数值越大表示方法的整体区分能力越强；当 AUROC 为 0.5 时，说明检测效果与随机猜测相当。由于 AUROC 不依赖于某一个固定阈值，能够较为全面地反映模型在不同判别标准下的总体性能，因此本文将其作为主要评价指标。

FPR95。FPR95 表示当真正例率达到 95% 时对应的假正例率，即

$$\mathrm{FPR95} = \mathrm{FPR}\big|_{\mathrm{TPR}=95\%}. \tag{3.18}$$

该指标主要衡量检测器在保证较高召回能力时的误报水平。在幻觉检测任务中，较高的 TPR 意味着大部分幻觉样本能够被成功识别，而较低的 FPR95 则说明在此条件下，事实性样本被错误判定为幻觉的比例较低。因此，FPR95 越小，表明方法在高召回场景下越具有实用价值。与 AUROC 相比，FPR95 更关注特定工作点下的检测性能，是对整体排序能力的重要补充。

AUPR。AUPR（Area Under the Precision-Recall Curve）表示精确率–召回率曲线（PR 曲线）下的面积。其中，精确率（Precision）表示被判定为正类的样本中真实为正类的比例，召回率（Recall）表示所有正类样本中被正确识别出来的比例。AUPR 能够反映模型在不同阈值下对正类样本的识别质量，尤其适用于类别分布不平衡的场景。在幻觉检测任务中，若将幻觉样本视为正类，则 AUPR 越高，说明模型越能够在保持较高召回的同时减少误报。相较于 AUROC，AUPR 对正类样本的检测质量更为敏感，因此也常被作为补充指标进行报告。

综上，AUROC、FPR95 和 AUPR 分别从整体排序能力、高召回条件下的误报水平以及正类检测质量三个方面评估幻觉检测方法的性能。

模型配置

在本实验中，本文统一采用 Llama-3-8B-Instruct[1]作为基础大语言模型进行评估。该模型属于当前主流的开源指令微调模型之一，在多项生成与推理任务中表现出较强的能力，因而被广泛应用于幻觉检测与不确定性估计相关研究中。为保证实验设置与已有工作的可比性，本文在模型选择上遵循相关研究中的标准配置，统一在同一模型上对不同方法进行评测；与模型生成过程有关的超参数均保持默认值。

此外，本文方法无需对模型进行额外训练或参数微调，所有实验均基于冻结的预训练模型完成。这一设置不仅降低了计算开销，也有助于体现所提出方法在无需训练场景下的实际应用价值与可迁移性。本实验中的所有环节均可在一张 NVIDIA RTX A6000（48GB 显存）显卡上运行。

对比方法

为全面评估本文方法的有效性，本文选取了以下具有代表性的幻觉检测与不确定性估计方法作为对比。

- 基于概率分布的方法。此类方法直接利用模型输出层的概率信息构造不确定性指标，主要包括最大输出概率（Max Probability）、困惑度（Perplexity）和熵（Entropy）。其中，最大输出概率通过考察生成 token 的最大概率来反映模型置信度；困惑度

[1] https://huggingface.co/meta-llama/Meta-Llama-3-8B-Instruct[10]

衡量模型对生成序列的整体拟合难度；熵则用于描述输出概率分布的不确定程度。该类方法实现简单、适用范围广，是幻觉检测任务中最常见的基线之一。

- 基于内部表征的方法。此类方法利用模型内部隐藏状态的结构特征进行幻觉检测，主要包括 EigenScore[28]、R-MHP[71] 和 EffectiveRank[72]。其中，EigenScore 和 EffectiveRank 分别从表征谱特性角度刻画隐藏状态的结构信息，R-MHP 则将激活张量视为 $L \times T$ 个数据点，对这些数据点的分布离散型进行建模。该类方法与本文工作关系更为紧密，也是验证本文方法有效性的主要对比对象。

- 本文提出的多方向链式表征 ATScore 系列方法。根据链式表征主方向的不同，本文考虑两种实现形式，即沿 layer 方向构建链式表征的 $\text{ATScore}_{\text{layer}}$（见式 3.15 ），以及沿 token 方向构建链式表征的 $\text{ATScore}_{\text{token}}$（见式 3.17 ）。其中，$\text{ATScore}_{\text{layer}}$ 在建模思路上与 Chain of Embedding（CoE）[35] 一致，可视为其在本文实验框架下的对应实现；ATScore-token 则是本文重点关注的方法，通过沿 token 方向构建表征链，以捕捉生成序列推进过程中的动态表示变化。基于链式表征，本文进一步提取相应的几何统计量，并据此构造幻觉检测分数。

总体而言，上述对比方法涵盖了从输出概率信息到内部表征结构信息、再到本文所提出的多方向链式建模方法的不同技术路线，有助于从多个层面验证本文方法的有效性与相对优势。

3.3.2 结果分析

本文 ATScore 及对比方法的主实验结果如表 3.2 、表 3.3 、表 3.4 、表 3.5 及表 3.6 所示，各项评价指标中的最佳结果以**粗体**展示。

据表格中的实验结果，我们将得出的结论分析总结如下：

- **总体性能优越。**从实验结果来看，本文提出的 ATScore 系列方法在各项数据集和各项评价指标上均表现出较强的竞争力，整体性能优于传统黑盒不确定性方法，并能够超过现有基于内部表征的白盒检测方法。在数据集 × 评价指标共计 15 种不同设定上，ATScore 系列方法在其中 13 种设定上取得了最优性能，其中以 token 为主方向计算链节点平均长度的 $\text{ATScore}_{\text{token}}$-Len 方法更是在其中 12 种设定下均最优。尤其是在作为主指标的 AUROC 上，本文方法均能够取得更优的结果，说明所提出的多方向链式表征建模方式能够更有效地区分幻觉样本与非幻觉样本。相较于仅依赖输出概率分布的 Max Probability、Perplexity 和 Entropy 等方法，ATScore 能够进一步挖掘模型内部隐藏状态中的结构化信号，因此在整体排序能力上更具优势。与此同时，与 EigenScore、R-MHP、EffectiveRank 等基于内部表征的白盒方法相比，本文方法仍表现出一定提升，这表明，将内部表征视为三维激活张量，并将其组织为链式轨迹并从几何角度进行刻画，能够补充甚至强化传统静态表征统计量所难以捕捉的动态异常信息。

表 3.2 ATScore 在 GSM8K（MGSM）数据集上的实验结果（模型幻觉率：17.6%）

方法	AUROC ↑（%）	FPR95 ↓（%）	AUPR ↑（%）
Max Probability	65.85	89.55	88.28
Perplexity	65.26	89.55	87.95
Entropy	68.50	89.55	89.39
EigenScore	43.80	97.10	44.17
R-MHP	65.68	88.82	89.57
EffectiveRank	61.67	88.64	86.85
$\text{ATScore}_{\text{layer}}$-Len	62.46	84.09	**91.89**
$\text{ATScore}_{\text{layer}}$-Ang	68.74	84.09	90.37
$\text{ATScore}_{\text{token}}$-Len	**69.22**	**81.82**	90.27
$\text{ATScore}_{\text{token}}$-Ang	62.31	86.36	86.71

表 3.3 ATScore 在 CommonenseQA 数据集上的实验结果（模型幻觉率：27.1%）

方法	AUROC ↑（%）	FPR95 ↓（%）	AUPR ↑（%）
Max Probability	53.43	92.15	73.90
Perplexity	53.65	93.05	73.87
Entropy	53.78	92.45	74.01
EigenScore	54.50	93.94	73.21
R-MHP	55.71	**89.73**	74.53
EffectiveRank	56.09	93.05	74.12
$\text{ATScore}_{\text{layer}}$-Len	50.57	93.35	71.00
$\text{ATScore}_{\text{layer}}$-Ang	57.93	91.24	74.54
$\text{ATScore}_{\text{token}}$-Len	**58.82**	90.03	**74.79**
$\text{ATScore}_{\text{token}}$-Ang	53.35	90.94	73.33

表 3.4 ATScore 在 Belebele 数据集上的实验结果（模型幻觉率：11.6%）

方法	AUROC ↑（%）	FPR95 ↓（%）	AUPR ↑（%）
Max Probability	56.63	95.19	90.42
Perplexity	56.63	94.23	90.44
Entropy	56.78	92.31	90.43
EigenScore	60.81	89.66	91.27
R-MHP	59.98	90.38	90.86
EffectiveRank	61.37	87.50	91.96
$\text{ATScore}_{\text{layer}}$-Len	59.87	89.42	90.95
$\text{ATScore}_{\text{layer}}$-Ang	64.27	86.54	92.71
$\text{ATScore}_{\text{token}}$-Len	**65.12**	**85.58**	**92.87**
$\text{ATScore}_{\text{token}}$-Ang	43.04	98.08	86.40

表 3.5 ATScore 在 TheoremQA 数据集上的实验结果（模型幻觉率：83.2%）

方法	AUROC ↑（%）	FPR95 ↓（%）	AUPR ↑（%）
Max Probability	42.86	98.05	14.96
Perplexity	43.15	98.20	15.20
Entropy	43.34	98.65	15.28
EigenScore	61.22	94.25	26.58
R-MHP	58.68	97.15	20.81
EffectiveRank	64.25	90.99	29.56
$\text{ATScore}_{\text{layer}}$-Len	62.57	86.34	29.58
$\text{ATScore}_{\text{layer}}$-Ang	67.38	91.89	33.90
$\text{ATScore}_{\text{token}}$-Len	**69.86**	**85.59**	**35.53**
$\text{ATScore}_{\text{token}}$-Ang	45.68	97.75	15.31

表 3.6 ATScore 在 TruthfulQA 数据集上的实验结果（模型幻觉率：65.2%）

方法	AUROC ↑（%）	FPR95 ↓（%）	AUPR ↑（%）
Max Probability	45.22	94.56	33.97
Perplexity	45.17	93.62	34.00
Entropy	45.56	93.81	34.29
EigenScore	47.14	92.05	35.03
R-MHP	47.84	94.93	32.96
EffectiveRank	50.18	91.99	**35.54**
$\text{ATScore}_{\text{layer}}$-Len	49.03	96.62	34.93
$\text{ATScore}_{\text{layer}}$-Ang	48.88	95.12	34.39
$\text{ATScore}_{\text{token}}$-Len	**50.90**	**91.18**	35.30
$\text{ATScore}_{\text{token}}$-Ang	49.33	93.43	33.36

- **泛化性与稳定性高。**从跨数据集比较的角度来看，本文方法在不同领域背景与不同任务类型的数据集上均保持了稳定的检测性能，体现出较高的泛化能力和鲁棒性。尽管不同数据集在文本风格和作答难度上存在差异，ATScore 仍能在多数场景下保持竞争性结果，说明其所利用的链式几何特征并非仅对特定数据分布或幻觉分布有效，而具有一定的普适性。此外，各数据集作答难度亦不尽相同，导致大模型在各数据集中生成答案的幻觉率亦各不相同；在这些不同幻觉率数据集上的评价指标均能保持稳定，说明 ATScore 受到数据类别不平衡影响的程度较低。进一步地，与部分基线方法（如 EigenScore）在不同数据集之间表现波动较大的现象相比，本文方法的结果更加平稳，这表明基于内部表征演化轨迹所提取的幻觉信号具有较好的稳定性。换言之，本文方法并不依赖某一特定数据集中的表面统计规律，而更可能捕捉到了与幻觉生成过程本身相关的内部表示模式。

- **以 token 为主方向的算法性能更优。**从不同变体之间的比较结果可以看出，链式表征的构造方向以及构造几何指标的选取都会对最终检测效果产生影响。总体而言，$\text{ATScore}_{\text{token}}$ 与 $\text{ATScore}_{\text{layer}}$ 均能够取得较好的结果，说明无论沿 layer 方向还是沿 token 方向构建链式表征，内部激活张量的不同维度中都蕴含着与幻觉相关的有效信息；这一点从侧面验证了本文提出的多方向链式表征建模思路的合理性，并为内部表征建模提供了一种新的、可行的对偶视角。进一步地，$\text{ATScore}_{\text{token}}$ 在多数情况下优于 $\text{ATScore}_{\text{layer}}$，说明沿 token 方向构建表示链能够更直接、精确地刻画生成序列逐步展开过程中的动态语义偏移，从而更有利于识别幻觉样本。

- **几何指标的选取与链式表征方向有关。**对于考虑链节点间的平均长度或平均转折

角度两种集合构建方式的变体，可观察得到：在以 layer 为主方向的方法中，平均转折角度（$\text{ATScore}_{\text{layer}}$-Ang）通常性能更优，而在以 token 为主方向的方法中，平均长度 $\text{ATScore}_{\text{token}}$-Len 通常性能更优。这一现象可能源于不同主方向下表征演化模式的差异：在 layer 主方向中，隐藏状态主要刻画信息在网络深度上的逐层变换，其幅值变化相对平滑，而方向上的偏折更能反映语义空间中的结构调整，因此转折角度（Ang）对异常变化更为敏感；相对地，在 token 主方向中，链式表征沿生成序列展开，不同 token 之间的表示差异往往表现为更明显的幅值变化，从而使得链长度（Len）能够更直接地刻画生成过程中潜在的语义偏移。该结果表明，不同几何指标的选取策略对性能存在一定影响，这也进一步说明几何指标选取并非无关紧要，而是链式表征建模中的一个重要组成部分。

为更直观地分析不同幻觉检测分数对真实样本与幻觉样本的区分能力，除上述结果外，本文额外在两个数据集上，将测试集样本按照参考标签划分为“真实回答”与“幻觉回答”两组，并分别统计各方法在两组样本上的分数分布，如图 3-2 、图 3-3 所示。具体地，本文对每种方法得到的样本级分数采用核密度估计（Kernel Density Estimation, KDE）进行平滑，从而绘制概率密度曲线。图中横轴表示对应方法的检测分数，纵轴表示该分数的概率密度，蓝色曲线与红色曲线分别对应两类样本；两条曲线的相对位置、峰值偏移程度以及重叠面积，能够直观反映该方法对两类样本的可分性。一般而言，若两组样本的分布峰值分离更明显、重叠区域更小，则说明该分数更能够刻画真实与幻觉输出之间的内部表征差异，因而具备更强的判别能力。

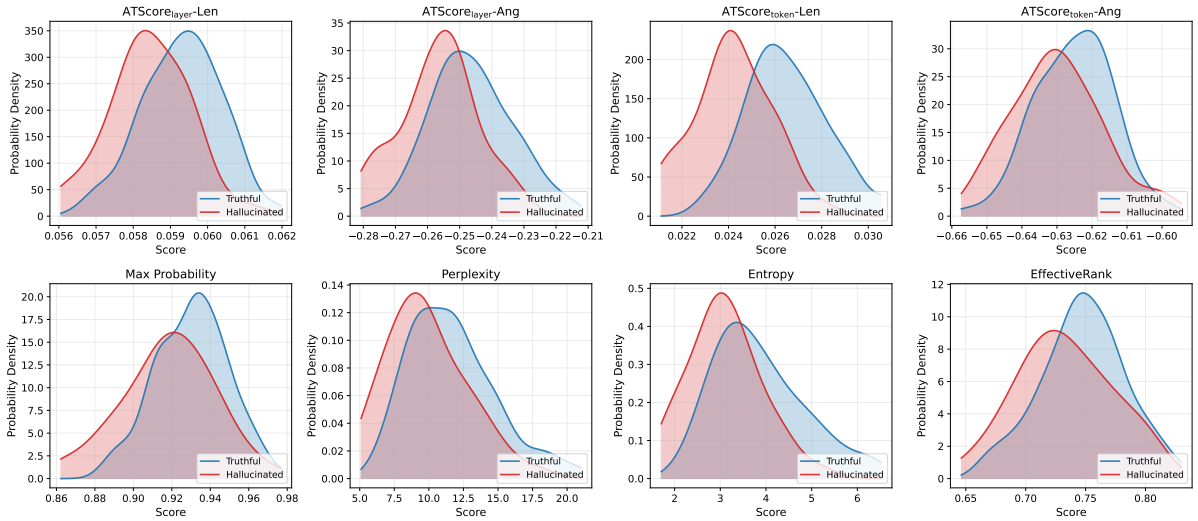

图 3-2 ATScore 和对比方法在 GSM8K（MGSM）上的幻觉分数分布

从图中可以看出，ATScore 系列方法整体上较黑盒统计量方法与传统白盒表征统计方法展现出更清晰的双峰分离趋势，其中 $\text{ATScore}_{\text{token}}$-Len 在两个数据集上表现尤为突出：其真实回答与幻觉回答两组样本的密度峰位置偏移更明显，重叠区域相对更小，说

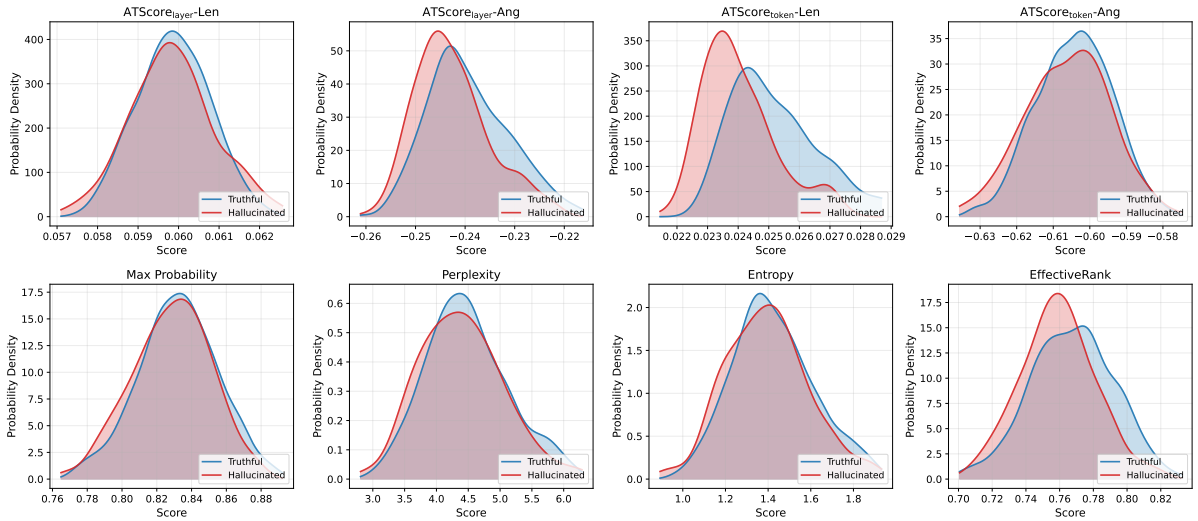

图 3-3 ATScore 和对比方法在 CommonsenseQA 上的幻觉分数分布

明该方法能够更稳定地捕捉幻觉生成过程中内部表征轨迹的异常变化。这一现象与主实验结果是一致的，即 ATScore 系列在多数数据集及指标设定下取得最优，而 ATScore$_{token}$-Len 则是整体表现最稳定、最优次数最多的变体。综合来看，这些分布图从可视化角度进一步验证了本文方法的有效性，也说明 ATScore$_{token}$-Len 能够更充分地利用内部表征中的多方向结构信息，是本文最具代表性的主推方法。

从机制层面看，本文方法之所以能够取得较好的检测效果，主要源于其对大语言模型内部表征动态结构的更充分利用。传统黑盒方法主要依赖输出层概率或序列级似然信息，这类信号虽然计算简单，但往往只能反映最终输出的不确定性，难以深入揭示模型内部生成机制。幻觉的产生并不一定只在最终输出阶段才显现，其对应的异常模式往往会提前体现在隐藏状态的演化过程中。

本文方法通过构建链式表征，将原本分散在激活张量中的高维状态组织为具有顺序结构的表示轨迹，从而保留了内部状态随深度或随生成过程推进的动态变化信息。另一方面，链平均长度长、平均转折角度等几何指标具有较强的可解释性，能够分别从累计变化幅度、局部方向偏折和整体路径形态等角度刻画内部表征的异常程度。这种从“几何轨迹”视角出发的检测方式，不仅能够补充传统静态谱特征方法的信息不足，也使得所得到的幻觉分数具备更清晰的结构含义。综合来看，本文方法在无需额外训练或参数微调的前提下，仅通过对内部表征进行轻量级的方向聚合与几何统计即可实现有效检测，因而兼具较好的检测性能、可解释性与实际应用价值。

3.3.3　消融实验

在本小节，我们将进一步对 ATScore 的各种变体，以及开放式问题的“真实/幻觉”标签判断方式进行详细的消融分析。

辅助方向的聚合方式

在 3.2.2 小节中，我们讨论了将激活张量分为两个正交的“主-次”方向：其中主方向保留链式顺序结构，另一辅助方向进行压缩聚合。对辅助方向的聚合方式有取辅助方向各元素之平均（avg，见式 3.7 与式 3.11 ）与取末位置元素（last，见式 3.8 与式 3.12 ）两种。表3.7 与表 3.8 展示了在不同数据集上两种聚合方式的相对优劣。

表 3.7 ATScore 在 GSM8K（MGSM）数据集上不同辅助方向聚合方式的性能

方法及辅助方向聚合方式	AUROC ↑（%）	FPR95 ↓（%）	AUPR ↑（%）
$\text{ATScore}_{\text{token}}$-Len（last）	**69.22**	**81.82**	90.27
$\text{ATScore}_{\text{token}}$-Ang（last）	62.31	86.36	86.71
$\text{ATScore}_{\text{token}}$-Len（avg）	69.00	**81.82**	**90.30**
$\text{ATScore}_{\text{token}}$-Ang（avg）	51.24	100.00	82.54

表 3.8 ATScore 在 TruthfulQA 数据集上不同辅助方向聚合方式的性能

方法及辅助方向聚合方式	AUROC ↑（%）	FPR95 ↓（%）	AUPR ↑（%）
$\text{ATScore}_{\text{token}}$-Len（last）	**50.90**	**91.18**	**35.30**
$\text{ATScore}_{\text{token}}$-Ang（last）	49.33	93.43	33.36
$\text{ATScore}_{\text{token}}$-Len（avg）	49.89	91.56	34.66
$\text{ATScore}_{\text{token}}$-Ang（avg）	48.32	94.00	33.06

从表 3.7 与表 3.8 可以看出，在不同数据集上，采用末位置聚合（last）的整体性能通常优于平均聚合（avg），这一趋势在 AUROC 与 FPR95 等主要指标上表现得较为一致。特别是在链平均长度（Len）指标下，last 与 avg 在部分情况下数值接近，但 last 往往仍能取得更优或更稳定的结果；而在链平均转折角度（Ang）指标下，last 的优势更加明显，说明辅助方向聚合方式对链式表征的几何特性具有一定影响。

这一现象可以从内部表征的信息分布角度进行解释。在大语言模型的生成过程中，不同层或不同 token 位置的隐藏状态并非同等重要，末位置的表征通常更直接地参与当前 token 的生成决策，因而包含了更强的语义与置信信息。因大语言模型的自回归（auto-regressive）式生成本质，末位置的 token 理论上可与所有输入及已生成的 token 计算自注意力，因而更可能完整地包含句子级信息。相比之下，简单的平均聚合会在一定程度上引入无关或噪声信息，从而削弱链式表征中与幻觉相关的判别信号。

此外，链式建模依赖于相邻状态之间的变化来刻画表示轨迹的几何特性，而末位置聚合能够更突出该关键位置的状态差异，使得链长、角度等指标对异常变化更加敏感。

因此，采用 last 作为辅助方向的聚合方式，能够在保留主要判别信息的同时减少信息稀释，从而在整体上取得更优的检测效果。

开放式问题的“真实/幻觉”标签判定方式

在 3.3.1 小节中，我们讨论了对于模型输出的“真实/幻觉”标签的判定方式，此标签将被进一步应用于计算各幻觉检测算法的评价指标。由于自然语言的多义性和表达多样性，对于开放式问题，判定模型输出与参考答案是否相符（即是否是幻觉），存在一定模糊空间。本文采取了基于字符级别匹配的 ROUGE-L 和基于大模型裁判（LLM judge）的两种判定方法，在 TruthfulQA 这一开放式问答数据集上，本文所提出的方法的性能如表 3.9 所示。

表 3.9 ATScore 在 TruthfulQA 数据集上基于不同判定幻觉标签方法的性能

判定标签方式	方法	AUROC ↑（%）	FPR95 ↓（%）	AUPR ↑（%）
LLM Judge（幻觉率：65.2%）	R-MHP	47.84	94.93	32.96
	EffectiveRank	50.18	91.99	**35.54**
	$\text{ATScore}_{\text{layer}}$-Len	49.03	96.62	34.93
	$\text{ATScore}_{\text{layer}}$-Ang	48.88	95.12	34.39
	$\text{ATScore}_{\text{token}}$-Len	**50.90**	**91.18**	35.30
	$\text{ATScore}_{\text{token}}$-Ang	49.33	93.43	33.36
ROUGE-L（幻觉率：53.7%）	R-MHP	44.83	96.36	42.18
	EffectiveRank	49.22	95.22	46.59
	$\text{ATScore}_{\text{layer}}$-Len	49.69	**92.71**	44.74
	$\text{ATScore}_{\text{layer}}$-Ang	46.34	99.09	44.65
	$\text{ATScore}_{\text{token}}$-Len	49.73	96.58	46.46
	$\text{ATScore}_{\text{token}}$-Ang	**53.02**	96.13	**47.57**

从表 3.9 中可以看出：不论采用何种方式构建用于计算评价指标的“真实/幻觉”标签，ATScore 系列方法仍能在大多数情境下保持更高的性能。鉴于大模型更强的语义级别理解能力，基于大模型裁判判断的方法通常能够更准确地判断模型输出是否为幻觉，因此本文默认采用基于大模型裁判的判定方法。

3.4　本章小结

本章围绕大语言模型幻觉检测问题，在明确任务设定的基础上，提出了基于多方向表征建模的 ATScore 方法。该方法以大模型生成过程中的内部激活为切入点，构建三维

激活张量，并分别从 layer 和 token 两个方向对其进行链式建模，再结合链长度、转折角度等几何指标实现对幻觉的有效检测。

实验结果表明，ATScore 在多个数据集和多种评价指标上均具有良好的竞争力，整体优于多种黑盒与白盒基线方法，其中以 token 为主方向的变体表现更为突出。消融实验则进一步验证了辅助方向聚合方式以及标签判定策略对性能的影响。综合来看，本章方法在无需额外训练的条件下，充分利用了大模型内部表征中与幻觉相关的动态信号，为后续研究提供了方法基础。

第四章　基于检索知识冲突消解的幻觉检测方法

检索增强生成（Retrieval-Augmented Generation，RAG）通过引入外部检索文档，为大语言模型生成过程提供额外知识支撑，在一定程度上缓解了封闭参数知识带来的事实性错误问题。然而，RAG 并未从根本上消除幻觉现象。当检索内容与模型内部参数知识存在偏差、冲突或对齐不充分时，模型仍可能生成与检索证据不一致、与事实不符甚至凭空编造的内容。现有 RAG 幻觉检测方法虽然已经关注到检索文档在判别中的作用，但总体上仍存在两类主要问题：其一是**对外部检索知识信号的利用仍不充分**，难以对“模型内部知识—外部检索知识”之间的冲突关系进行简洁而有效的刻画；同时，许多方法给出的检测分数**缺乏清晰的语义-幻觉对应关系**，导致其可解释性不足，难以回答“模型为何被判定为产生幻觉”这一关键问题。

针对上述不足，本章提出一种基于检索知识冲突消解的 RAG 幻觉检测方法 SKID（Sparse Knowledge Inconsistency Detector）。该方法从大语言模型内部表征出发，借助稀疏自编码器（Sparse Autoencoder，SAE）将生成过程中的隐状态映射为具有语义可解释性的稀疏特征，并通过互信息筛选得到与正确性最相关的判别维度；在此基础上，进一步结合检索文档对生成内容进行过滤，重点关注未被外部知识支持的生成片段，从而更直接地刻画模型内部知识与外部检索知识之间的冲突程度。随后，SKID 利用可解释的广义加性模型对上述冲突信号进行建模，实现对 RAG 幻觉的有效检测。该方法不仅强化了对外部检索知识信号的直接利用，而且能够以自然语言形式揭示关键稀疏特征对判别结果的贡献，从而兼顾检测性能与结果可解释性，为 RAG 场景下的幻觉检测提供了一种新的技术路径。

4.1　问题设定

检索增强生成（Retrieval-Augmented Generation, RAG）是一类通过引入外部知识以辅助大语言模型生成的典型框架。与仅依赖参数化知识的传统生成方式不同，RAG 在接收到用户输入后，会首先从外部知识库中检索与当前问题相关的参考文档，再将检索结果与用户输入共同提供给大语言模型，从而生成最终输出。该过程通常可划分为“检索—增强—生成”三个阶段：首先，检索器根据用户输入从知识库中召回若干相关文档；随后，将检索得到的文档与原始输入按照预定义模板进行拼接或组织，形成增强后的上下文；最后，生成模型基于该增强上下文生成响应。

形式化地，设用户输入文本的 token 序列为 $X = \{x_1, x_2, \ldots, x_n\}$，其中 n 表示输入序列长度。给定外部知识库 $\mathcal{D}$，检索模块根据输入 X 返回 N 个与之相关的文档，记为 $R = \{D_1, D_2, \ldots, D_N\}$，其中 D_j 表示第 j 个检索文档。进一步地，将输入 X 与检索结

果 R 进行组合，得到增强后的模型条件输入

$$\widetilde{X} = \Phi(X, R), \tag{4.1}$$

其中 $\Phi(\cdot)$ 表示用于组织输入问题与检索文档的提示模板或上下文构造函数。在此基础上，生成模型 M 输出响应文本 token 序列 $Y = \{y_1, y_2, \ldots, y_m\}$，其中 m 表示输出序列长度，则 RAG 场景下的生成过程可概括为

$$Y = M(\widetilde{X}) = M(\Phi(X, R)). \tag{4.2}$$

在此基础上，RAG 幻觉检测任务的目标是判断模型输出 Y 是否存在幻觉，即判断其内容是否与外部检索知识 R 保持一致。与一般生成场景相比，RAG 模型的输出不仅应满足任务语义上的正确性，还应尽可能受到检索证据的支持。因此，RAG 幻觉检测可以形式化为如下二分类问题：

$$f(M, X, R, Y) \to \{0, 1\}, \tag{4.3}$$

其中 f 表示 RAG 幻觉检测模型。当输出为 1 时，表示生成结果中存在幻觉内容；当输出为 0 时，表示生成结果中不存在幻觉内容。若在白盒设定下，还可进一步利用模型在生成 Y 过程中产生的内部隐藏状态作为额外输入，从而将判别函数写为

$$f(M, X, R, Y, H) \to \{0, 1\}, \tag{4.4}$$

其中 H 表示模型在生成过程中得到的内部表征集合。由于这些内部表征刻画了模型在不同层、不同位置上的中间语义状态，因此能够为 RAG 幻觉检测提供比最终文本更丰富的判别信息。

需要指出的是，RAG 场景下“幻觉”的含义与一般大模型幻觉检测问题存在一定区别。在一般幻觉检测任务中，通常只关注模型输出 Y 是否与标准答案在语义上保持一致，即更强调输出结果本身的事实正确性。然而，在 RAG 场景中，模型生成建立在外部检索知识的基础之上，因此除了考察输出与标准答案是否一致之外，还需要进一步关注输出内容是否能够被检索证据 R，亦即外部知识所支持。换言之，RAG 幻觉不仅表现为“回答错误”，还可能表现为“回答虽然看似合理，但其关键信息无法从检索文档中得到支持”，或者“输出内容与外部输入知识发生冲突”。

基于上述特点，RAG 幻觉检测相较于一般幻觉检测至少具有以下两方面差异。其一，输入信息更加丰富。一般幻觉检测主要围绕输入 X 与输出 Y 展开，而 RAG 幻觉检测还需显式建模检索结果 R 对生成行为的影响。其二，判别依据更加复杂。一般幻觉检测主要考察输出与标准答案之间的一致性；而在 RAG 场景中，还需要进一步分析输出内容与检索知识之间的支持关系、一致关系或冲突关系。因此，RAG 幻觉检测本质上是一个同时涉及“输入—检索知识—模型输出”三者关系建模的问题。

4.2　SKID 算法

本方法属于基于检索知识冲突消解的 RAG 幻觉检测方法，该方法以大语言模型的稀疏可解释特征表征为基础，核心思想是从大模型输出中查找并滤除在检索知识中所包含的 token，明确区分内外部知识信号，重点关注未被外部知识支持的生成片段；并在高维稀疏空间基于互信息筛选特征维度，最终构建一个有效、可解释的 RAG 幻觉检测信号。本方法的框架结构图如图 4-1 所示。后续章节将按步骤详细介绍 SKID 算法的设计与实现。

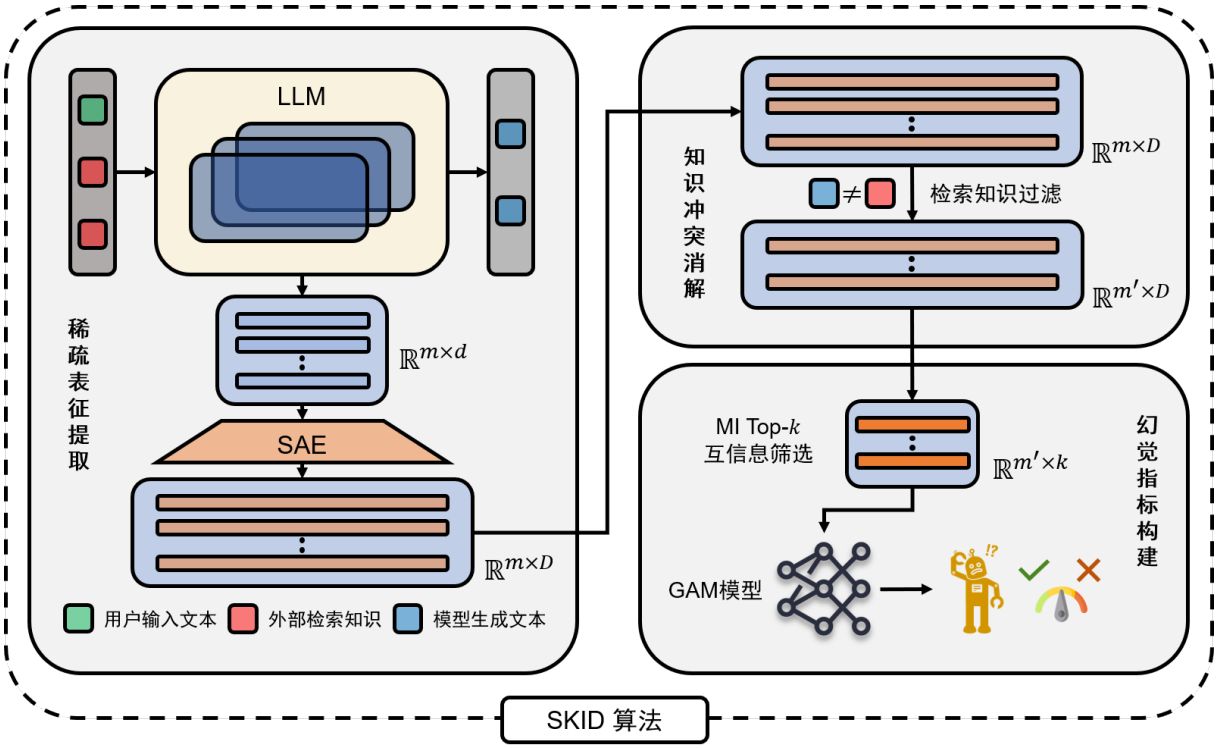

图 4-1 SKID 算法框架图

4.2.1　稀疏表征提取

为刻画大语言模型在生成过程中的内部知识表征，本文首先从模型生成输出序列时的隐藏状态中提取输出 token 的中间层表示，并进一步借助稀疏自编码器（Sparse Autoencoder，SAE）将其映射到高维稀疏特征空间中。具体而言，设大语言模型为 M，对于输入样本，模型生成输出序列 $Y=\{y_1,y_2,\ldots,y_m\}$。记第 l 层对第 i 个输出 token y_i 的隐藏表示为 $\mathbf{h}_i^{(l)}\in\mathbb{R}^d$，其中 d 为原始隐空间维度。对于每个输出 token，本文选取指定层的隐藏表示作为其内部语义状态的表征，并将其输入预训练好的 SAE 编码器，得到对应的高维稀疏表征

$$\mathbf{z}_i=f_{\text{SAE}}\left(\mathbf{h}_i^{(l)}\right)\in\mathbb{R}^D, \tag{4.5}$$

其中 D 为 SAE 的特征维度，满足 $D \gg d$，且 $\mathbf{z}_i$ 具有显著稀疏性，即仅有少量维度被激活。对整个输出序列进行处理后，可得到该样本对应的稀疏特征矩阵

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}_1^\top \\ \mathbf{z}_2^\top \\ \vdots \\ \mathbf{z}_m^\top \end{bmatrix} \in \mathbb{R}^{m \times D}, \tag{4.6}$$

其中第 i 行对应第 i 个输出 token 的稀疏语义特征表示。

引入高维稀疏表征的核心目的，在于将原始隐藏状态中高度纠缠的语义信息解耦为更具可解释性的特征单元。原始隐表示通常呈现明显的多义性与混合性，即单个神经元或局部子空间往往同时承载多种语义因素，难以直接对应某一明确知识概念；而 SAE 通过过完备表示与稀疏约束，能够将这种“多义”表征转化为更接近“单义”的稀疏特征激活，使不同维度更倾向于响应相对独立、可解释的语义模式【】。从方法设计上看，这样的特征表示有两方面优势：其一是便于后续对特征空间的互信息筛选和广义加性模型训练，因稀疏式特征便于机器学习建模；其二是有助于提升模型可解释性，可通过分析得知高维空间的具体含义，能够建模何种幻觉，实现从“判定幻觉”到“解释为何被判定为幻觉”的体验提升。

4.2.2 知识冲突消解

在获得输出序列的稀疏特征表示之后，本文进一步考虑如何从中分离出更能反映模型内部知识偏差的判别信号。对于 RAG 任务而言，模型最终生成的输出通常同时混合了两类知识来源：一类是由外部检索文档直接提供或显式支持的知识，另一类则是模型依赖其参数内部所存储知识进行补全、推断甚至臆造时所引入的知识。基于此，本文设计知识冲突消解步骤，在 token 级别对输出内容进行筛选，以尽可能除去受外部检索知识直接支撑的生成成分，仅保留更可能体现模型内部知识主导作用的部分。

具体而言，设模型输出序列为 $Y = \{y_1, y_2, \ldots, y_m\}$，检索到的外部知识文本拼接后构成检索内容序列 $R = \{r_1, r_2, \ldots, r_n\}$。本文首先在 token 级别判断输出 token 是否在检索内容中出现。对于第 i 个输出 token y_i，定义其对应的指示变量为

$$\delta_i = \begin{cases} 0, & y_i \in R, \\ 1, & y_i \notin R, \end{cases} \tag{4.7}$$

其中 $\delta_i = 0$ 表示该 token 已经在检索内容中出现，可视为受到外部知识的直接支持；$\delta_i = 1$ 表示该 token 未在检索内容中出现，更可能反映模型在生成过程中调用内部参数知识后产生的补充或偏移。基于该指示变量，本文对前述 token 级稀疏表征 $\mathbf{z}_i \in \mathbb{R}^D$ 进行筛选，仅保留未在检索内容中出现的输出 token 所对应的特征，即构造过滤后的稀疏表征

$$\widetilde{\mathbf{Z}} = \mathbf{Z}\left[\mathbb{I}\left(\delta_i = 1\right), :\right] \in \mathbb{R}^{m' \times D}, \quad i = 1, 2, \ldots, m. \tag{4.8}$$

其中 $\mathbb{I}(\cdot)$ 为指示函数，表示对 $\delta_i = 1$ 的行予以保留，对于 $\delta_i = 0$ 的行予以舍弃。于是，对于单个样本，可得到经过知识冲突消解后的 token 级特征集合 $\{\tilde{\mathbf{z}}_1, \ldots, \tilde{\mathbf{z}}_{m'}\}$。

在此基础上，为进一步从 token 级表示汇聚为样本级判别向量，本文沿 token 维度对过滤后的稀疏特征执行最大池化操作，从而提取每个稀疏维度在当前样本中最显著的激活强度。设单个样本过滤后的稀疏特征矩阵为 $\widetilde{\mathbf{Z}} \in \mathbb{R}^{m' \times D}$，则其对应的样本级冲突表征向量定义为

$$\mathbf{s} = \max_{1 \le i \le m'} \tilde{\mathbf{z}}_i \in \mathbb{R}^D, \tag{4.9}$$

其中 max 操作逐维进行，即

$$s_j = \max_{1 \le i \le m'} \tilde{z}_{i,j}, \quad j = 1, 2, \ldots, D. \tag{4.10}$$

之所以在 token 维度采用逐维最大池化，而非均值池化或求和聚合，是因为 SAE 得到的表征通常经过 ReLU 等非线性激活后呈现出显著的稀疏性，其大多数维度取值为 0，而非零正值则表示相应语义特征在当前 token 处被激活。对于同一输出序列而言，某一稀疏特征是否在任意位置被显著触发，往往比其在所有 token 上的平均响应强度更具有判别意义。逐维最大池化能够有效保留每个特征在样本范围内最强的激活信号，避免池化操作被稀释，从而更有利于后续模型捕捉与幻觉相关的关键知识冲突模式。

之所以滤除在检索数据中已经出现过的输出 token，核心原因在于这些 token 所对应的高维稀疏表征信息在很大程度上已经由外部检索知识显式提供，其激活更可能反映模型对检索内容的复述、复制或局部重组，而非模型对内部知识的利用。若将这些成分保留在检测特征中，则模型可能更多学习到“哪些内容被检索文档支持”，而不是“哪些内容脱离了检索支持却仍被模型生成”，从而弱化对 RAG 幻觉本质的刻画。相较之下，那些出现在输出中、却未在检索知识中出现的 token，更有可能承载模型内部知识外溢、过度推断或错误补全所形成的幻觉信号。因此，通过在 token 级别去除被外部知识直接覆盖的生成成分，本文实现了对内外知识混合信号的初步解耦，将检测重点集中于更具判别价值的内部知识残差信号之上。

从方法机理上看，这一过程即为一种面向 RAG 场景的知识冲突消解操作。经过检索增强后，模型输出中的一部分内容与外部知识是一致的、受支持的，这部分内容本身并不构成幻觉；真正需要关注的是那些未被检索证据覆盖、但仍在输出中被激活和表达出来的内容，因为它们更可能来源于模型内部参数知识，并在外部证据约束不足或内外知识不一致时表现为事实性偏差。本文通过简单而直接的 token 滤除策略，在 token 层级将输出中包含的外部知识成分尽可能去除，从而保留下更纯净的内部知识信号，也即更接近幻觉本质的检测信号。这样的设计不仅与 RAG 场景下“外部知识约束生成”的

任务设定更加一致，也为后续基于稀疏特征维度分析模型为何产生幻觉提供了更加清晰的表示基础。

4.2.3 幻觉指标构建

在完成知识冲突消解后，本文已经为每个样本获得了样本级稀疏冲突表征 $\mathbf{s} \in \mathbb{R}^D$。然而，并非所有稀疏特征维度都与 RAG 幻觉判别具有同等关联：部分维度可能主要反映一般性的语言模式或无关语义因素，另一些维度则更可能直接刻画模型内部知识与外部检索知识之间的冲突强度。因此，本文进一步在特征维度上进行判别性筛选，从中选取与幻觉标签最相关的关键稀疏特征，并基于这些特征构建最终的幻觉检测指标。

具体而言，设训练集共有 N 个样本，经过前述步骤后可得到样本级特征矩阵

$$\mathbf{S}_{\text{train}} \in \mathbb{R}^{N \times D}, \tag{4.11}$$

其中第 i 个样本的幻觉标签记为 $c_i \in \{0, 1\}$，$c_i = 1$ 表示该样本存在幻觉，$c_i = 0$ 表示该样本不存在幻觉。对于第 j 个稀疏特征维度，记其在全部训练样本上的取值为随机变量 S_j，对应的标签随机变量记为 C，则本文计算该维度与幻觉标签之间的互信息

$$I(S_j; C), \quad j = 1, 2, \ldots, D. \tag{4.12}$$

互信息可用于度量某一特征维度与标签变量之间的统计相关程度。与仅刻画线性相关性的指标相比，互信息能够更一般地反映特征对标签判别所提供的信息量，因此适合作为高维稀疏特征筛选的依据。基于此，本文按照 $I(S_j; C)$ 从高到低对全部 D 个特征维度进行排序，并选取其中互信息最高的 k 个维度构成关键特征集合

$$\mathcal{K} = \{j_1, j_2, \ldots, j_k\}, \quad |\mathcal{K}| = k. \tag{4.13}$$

据此，可从原始特征矩阵 $\mathbf{S}_{\text{train}}$ 中抽取对应的低维判别特征，得到

$$\mathbf{F}_{\text{train}} = \mathbf{S}_{\text{train}}[:, \mathcal{K}] \in \mathbb{R}^{N \times k}. \tag{4.14}$$

上述过程的核心作用，在于从高维稀疏冲突表征中进一步提炼出与幻觉最相关的少量特征维度。一方面，SAE 诱导的特征空间通常具有较高维数，若直接使用全部维度进行建模，容易引入冗余信息与噪声信号，削弱检测器对关键冲突模式的敏感性；另一方面，互信息筛选能够保留那些对幻觉判别最具信息贡献的稀疏维度，使最终检测指标更加集中地反映“哪些内部知识特征的激活与幻觉出现最为相关”。因此，这一步不仅实现了特征降维，也进一步增强了检测信号的判别性与可解释性。

在获得 $\mathbf{F}_{\text{train}}$ 之后，本文采用广义可加模型（Generalized Additive Model，GAM）作为最终的幻觉检测器，对幻觉标签进行拟合。GAM 的基本思想是将模型输出表示为若干单变量或低阶交互项的可加和，从而在保持一定非线性拟合能力的同时，维持较好的

可解释性。对于本文任务，设输入样本的 k 维特征向量为 $\mathbf{f} = (f_1, f_2, \ldots, f_k)$，则分类器的判别函数可表示为

$$g(\mathbf{f}) = \beta_0 + \sum_{t=1}^{k} \alpha_t(f_t), \tag{4.15}$$

其中 β_0 为偏置项，$\alpha_t(\cdot)$ 表示第 t 个特征维度对应的单变量响应函数。在二分类设置下，模型输出样本存在幻觉的概率为

$$P\left(C = 1|\mathbf{f}\right) = \sigma(g(\mathbf{f})), \tag{4.16}$$

其中 $\sigma(\cdot)$ 表示 Sigmoid 函数。

本文选择简单 GAM 而非更复杂的黑盒分类器，主要出于轻量化需要考虑。作为需要训练的模型，经过前述知识冲突消解与互信息筛选后，输入特征已经被压缩为一组参数量较少且具有明确判别意义的关键稀疏维度，此时使用结构简单的可加模型即可较好地拟合幻觉与特征之间的关系，无需额外引入过强的模型复杂度。

综上，本文结合 SAE 稀疏特征和内外知识冲突消解，构建面向 RAG 幻觉检测的最终指标，其生成流程如下：首先在训练集上取大模型某层输出隐藏表征，通过 SAE 模型升维为高维稀疏特征。随后，从输出中筛去在检索知识中出现过的 token，以消解知识冲突。其次，计算每个 SAE 特征维度与幻觉标签之间的互信息，选取最具判别力的 k 个关键维度。最后以这些关键维度构成的 $N \times k$ 特征矩阵为输入，训练 GAM 分类器拟合幻觉标签，从而得到从稀疏冲突特征到幻觉概率的映射关系。其流程中数据形状的变化如下所示：

$$\mathbf{h}^{(l)} \in \mathbb{R}^{m\times d} \xrightarrow[\text{编码}]{\text{SAE}} \mathbf{Z} \in \mathbb{R}^{m\times D} \xrightarrow[\text{冲突消解}]{\text{检索知识}} \widetilde{\mathbf{Z}} \in \mathbb{R}^{m'\times D} \xrightarrow[\text{最大池化}]{\text{token}} \mathbf{s} \in \mathbb{R}^{D} \xrightarrow[\text{特征筛选}]{\text{互信息}} \mathbf{f} \in \mathbb{R}^{k} \xrightarrow{\text{GAM}} \mathbb{R}. \tag{4.17}$$

对于测试阶段，本方法遵循与训练阶段完全一致的处理流程：首先从模型输出中提取稀疏表征，并经由知识冲突消解得到样本级特征向量；然后仅保留训练阶段确定的关键维度集合 $\mathcal{K}$，构造测试特征矩阵

$$\mathbf{F}_{\text{test}} \in \mathbb{R}^{N_{\text{test}}\times k}; \tag{4.18}$$

最后将其输入训练阶段得到的 GAM 分类器，输出对应样本的幻觉预测结果与幻觉概率分数。由此，本文完成了从高维稀疏知识冲突表征到最终 RAG 幻觉检测指标的构建。我们将以上 SKID 算法的步骤清晰地总结于算法 4.1 及算法 4.2 中。

算法 4.1 SKID 算法（训练阶段）

输入： 训练集 $\mathcal{D}_{\text{train}} = \{(X^{(u)}, R^{(u)}, Y^{(u)}, c^{(u)})\}_{u=1}^{N}$；大语言模型 M；指定层索引 l；稀疏自编码器 $f_{\text{SAE}}(\cdot)$；保留特征维数 k

输出： 关键特征集合 $\mathcal{K}$；训练好的 GAM 分类器 $\mathcal{G}$

for $u = 1, 2, \ldots, N$ **do**
  提取样本 $(X^{(u)}, R^{(u)}, Y^{(u)})$ 中输出序列 $Y^{(u)} = \{y_1^{(u)}, \ldots, y_{m_u}^{(u)}\}$ 在第 l 层的隐藏状态 $\mathbf{h}_i^{(l,u)}$
  $\mathbf{z}_i^{(u)} \leftarrow f_{\text{SAE}}(\mathbf{h}_i^{(l,u)}), \quad i = 1, 2, \ldots, m_u$
  构造稀疏特征矩阵 $\mathbf{Z}^{(u)} = [(\mathbf{z}_1^{(u)})^\top; (\mathbf{z}_2^{(u)})^\top; \ldots; (\mathbf{z}_{m_u}^{(u)})^\top] \in \mathbb{R}^{m_u \times D}$
  依据 $y_i^{(u)} \notin R^{(u)}$ 保留未被检索内容覆盖的输出 token，得到过滤后的稀疏特征矩阵 $\widetilde{\mathbf{Z}}^{(u)} \in \mathbb{R}^{m'_u \times D}$
  逐维最大池化：$\mathbf{s}^{(u)} \leftarrow \max_{1 \le i \le m'_u} \widetilde{\mathbf{z}}_i^{(u)} \in \mathbb{R}^D$
end for
构造训练特征矩阵 $\mathbf{S}_{\text{train}} = [(\mathbf{s}^{(1)})^\top; (\mathbf{s}^{(2)})^\top; \ldots; (\mathbf{s}^{(N)})^\top] \in \mathbb{R}^{N \times D}$
for $j = 1, 2, \ldots, D$ **do**
  计算第 j 维特征与幻觉标签之间的互信息 $I(S_j; C)$
end for
选取互信息最高的前 k 个维度，构成关键特征集合 $\mathcal{K} = \{j_1, j_2, \ldots, j_k\}$
得到降维后的训练特征矩阵 $\mathbf{S}_{\text{train}}^{(\mathcal{K})} \in \mathbb{R}^{N \times k}$
用 $\mathbf{S}_{\text{train}}^{(\mathcal{K})}$ 及标签 $\{c^{(u)}\}_{u=1}^{N}$ 训练 GAM 分类器 $\mathcal{G}$
return $\mathcal{K}, \mathcal{G}$

算法 4.2 SKID 算法（测试阶段）

输入： 测试样本 (X, R, Y)；大语言模型 M；指定层索引 l；稀疏自编码器 $f_{\text{SAE}}(\cdot)$；关键特征集合 $\mathcal{K}$；训练好的 GAM 分类器 $\mathcal{G}$

输出： 幻觉预测标签 $\hat{c} \in \{0, 1\}$

提取输出序列 $Y = \{y_1, y_2, \ldots, y_m\}$ 在第 l 层的隐藏状态 $\mathbf{h}_i^{(l)}$
$\mathbf{z}_i \leftarrow f_{\text{SAE}}(\mathbf{h}_i^{(l)}), \quad i = 1, 2, \ldots, m$
构造稀疏特征矩阵 $\mathbf{Z} = [\mathbf{z}_1^\top; \mathbf{z}_2^\top; \ldots; \mathbf{z}_m^\top] \in \mathbb{R}^{m \times D}$
依据 $y_i \notin R$ 保留未被检索内容覆盖的输出 token，得到过滤后的稀疏特征矩阵 $\widetilde{\mathbf{Z}} \in \mathbb{R}^{m' \times D}$
逐维最大池化：$\mathbf{s} \leftarrow \max_{1 \le i \le m'} \widetilde{\mathbf{z}}_i \in \mathbb{R}^D$
按关键特征集合 $\mathcal{K}$ 抽取判别特征，得到 $\mathbf{s}^{(\mathcal{K})} \in \mathbb{R}^k$
$\hat{c} \leftarrow \mathcal{G}(\mathbf{s}^{(\mathcal{K})})$
return $\hat{c}$

4.3 实验分析

在本小节中，我们将通过一系列实验来验证 SKID 算法在 RAG 幻觉检测任务中的有效性与泛化能力，并通过消融实验分析不同参数选择、变体构造对检测性能的影响。具体而言，我们将首先介绍实验设置，包括数据集、评测指标和对比方法；随后展示主要实验结果，并与现有主流方法进行对比分析；最后通过消融实验探讨超参数、数据集变体、SAE 模块等设计因素对检测性能的影响。

4.3.1 实验设置

本文在多个常用 RAG 幻觉检测数据集上与现有主流方法进行对比评测，以验证 SKID 算法在不同任务和不同领域上的有效性与泛化能力。参考现有主流工作[43]，在实验中，我们采用四个公开数据集，涵盖了数学问题、常识问答、定理证明、事实性问答等多种任务类型和领域背景；采用幻觉检测领域最常见的三个评价指标来衡量比较算法性能；并与多种当前的主流方法进行性能对比。

数据集

RAGTruth[73]。RAGTruth 是近年来 RAG 幻觉检测领域中具有代表性的数据集之一，专门面向检索增强生成场景下的幻觉分析与检测任务构建。该数据包含近 18,000 条在标准 RAG 流程下由多种大语言模型自然生成的响应样本，并提供了人工标注的幻觉信息。每条数据包含输入、输出及“是否包含幻觉”的标签。该数据集分为三个子集，分别为：

- **Data2txt**：该子集任务为将社区商户点评类 JSON 格式数据转为文字总结。
- **QA**：该子集任务为根据提供的短文回答阅读理解类问题，覆盖百科、事实、常识性问题。
- **Summary**：该子集任务为根据检索到的新闻文本生成摘要。

Dolly（Accurate Context）[74,75]。该数据集为 RefCheck[74] 基于开源大规模 LLM 数据集 Dolly[75] 构建，同样包含检索文本的输入及来自大模型的输出，以及幻觉标签，适用于 RAG 幻觉检测任务。该数据集以开放域事实性问答为主，领域涵盖广泛，如地理、历史、政治、体育等。该数据集没有原生定义的训练与测试集；在实验中，我们参考已有方法的做法，将其随机平均分为两份以供训练及测试。

除上述数据集外，以下两个数据集也将在 4.3.3 小节消融实验中使用到，以更全面地体现 SKID 算法的泛化性能：

AggreFact[76]。专为总结型任务中的事实一致性错误收集的数据集，同样包含检索文本的输入及来自大模型的输出，以及幻觉标签，适用于 RAG 幻觉检测任务。该数据集输出为对新闻文本的事实性总结。

TofuEval。与上述数据集不同，TofuEval 专门用于聚焦评估大模型在主题对话摘要任务中的事实一致性。输入数据中包含多说话人的会议对话，大模型生成的对话总结即幻觉标签。

以上数据集的相关信息总结如表 4.1 所示。

表 4.1 SKID 实验数据集概览

数据集	子集	样本数（训练/测试）	幻觉率%（训练/测试）	任务类型	领域背景
RAGTruth		15,090/2700	44.54/34.93		
|	Data2txt	5,298/900	69.37/64.33	JSON 转文本	社区商户点评
|	QA	5,034/900	31.07/17.78	阅读理解	百科常识
|	Summary	4,758/900	31.15/22.67	文本摘要	新闻
Dolly	-	148/149	50.68/52.35	阅读理解	开放事实问答
AggreFact	-	1,236/1,117	35.76/29.54	文本摘要	新闻
TofuEval	-	617/267	34.20/36.70	文本摘要	会议对话

评价指标

为全面评估所提方法在 RAG 幻觉检测任务中的性能表现，本文在主实验中采用与参考工作一致的三个评价指标，即 AUROC、ACC 和 F1。同时，为进一步考察模型在多种阈值设定下的性能，本文额外引入 FPR95 和 AUPR 作为补充评价指标。其中，AUROC、FPR95 和 AUPR 已在 3.3.1 小节中进行介绍，在本章节中沿用相同定义进行评估。

对于准确率（Accuracy，ACC），其用于衡量分类器在全部测试样本上的整体判别正确比例。在本实验中，用于判别正负例的阈值设定为 0.5，即最终的 GAM 模型输出高于 0.5 记为 1（幻觉回答样本），否则记为 0（忠实回答样本）。设测试集中共有 N 个样本，其中真正例、真负例、假正例和假负例的数量分别记为 TP、TN、FP 和 FN，则 ACC 定义为

$$\mathrm{ACC} = \frac{\mathrm{TP} + \mathrm{TN}}{\mathrm{TP} + \mathrm{TN} + \mathrm{FP} + \mathrm{FN}}. \tag{4.19}$$

该指标能够直接反映模型整体分类结果的正确程度，但在类别分布不均衡时，可能不足以充分体现模型对少数类样本的识别能力。对于 F1 值，其综合考虑了分类器的精确率（Precision）与召回率（Recall），能够更平衡地评价模型对正类样本的检测效果。首先，精确率与召回率分别定义为

$$\mathrm{Precision} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FP}}, \quad \mathrm{Recall} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}. \tag{4.20}$$

在此基础上，F1 值定义为 Precision 与 Recall 的调和平均，即

$$\mathrm{F1} = \frac{2 \cdot \mathrm{Precision} \cdot \mathrm{Recall}}{\mathrm{Precision} + \mathrm{Recall}}. \tag{4.21}$$

相较于仅考察某一单独指标，F1 能够更有效地反映分类器在“减少误报”与“避免漏检”之间的综合表现，因此也是二分类检测任务中常用的重要评价指标。

综上，本文最终采用 AUROC、ACC、F1、FPR95 和 AUPR 五项指标对各方法进行系统评估。其中，AUROC、FPR95 和 AUPR 主要用于衡量模型在不同判别阈值下的整体检测能力与排序能力；ACC 和 F1 则在固定阈值分类决策下，分别从总体正确率与正类识别效果两个角度补充评价模型性能。与 3.3.1 小节相同，本实验中同样以 AUROC 为主指标。通过结合多种指标，能够更全面地分析不同方法在 RAG 幻觉检测任务中的实际表现。

模型配置

与第三章中的幻觉检测数据集不同，本方法中使用的针对 RAG 幻觉检测的数据集均预置“输出”部分，而不依赖特定大模型实时输出。因此，在检测过程中，大模型仅用于编码“输入-输出”文本，用于提取内部表征，并不实际进行数据集所示任务输出。

在本实验中，为便于对比，我们采用与参考方法一致的 Llama-2-7B[1]模型。该大模型属于当前主流的开源指令微调模型之一，性能及参数量较为合适，在保证了一定语义理解力及编码质量的同时，维持了较低的计算开销。对于使用的 SAE 模型，我们采取了与大模型相对应的开源预训练 SAE[2]，并采用默认的模型第 15 层的输出隐藏表征计算稀疏表示。该模型将 Llama-2-7B 原始的隐藏表征维度从 4,096 维放大 32 倍至 131,072 维。本实验中的所有环节均可在一张 NVIDIA RTX A6000（48GB 显存）显卡上运行。

对比方法

为全面评估本文方法的有效性，本文选取了以下具有代表性的 RAG 幻觉检测与不确定性估计方法作为对比。

- RAG 幻觉检测方法，包括 ReDeEP[38]、RAGLens[43]。该类方法面向检索增强生成场景进行专门设计，重点关注生成内容与检索证据之间的支持关系及其失配现象，与本文所研究的场景完全一致。

- 通用幻觉检测方法，包括 ITI[31]、SAPLMA[32] 和 EigenScore[28]。这类方法虽适配于 第三章所示场景，但也可应用于本章的 RAG 设定。这类方法通常不显式依赖 RAG 中的外部检索信息，而是从模型内部表征、隐藏状态或统计几何特征中挖掘可用于判别幻觉的信号。

[1]https://huggingface.co/meta-llama/Llama-2-7b[9]

[2]https://huggingface.co/yuzhaouoe/Llama2-7b-SAE[77]

- 基于文本引导的大模型自评估方法，包括 P(True)[78] 和 SelfCheckGPT[23]。前者通过提示模型直接估计其输出内容为真的概率，后者则通过多次采样并比较不同生成结果之间的一致性来判断幻觉风险。SelfCheckGPT 是该类方法中的代表性工作。

- 黑盒统计特征方法，包括 LN-Entropy[79]。该类方法不依赖对模型内部机制的显式干预，而是根据生成分布或输出统计量构造检测指标；其中 LN-Entropy 是一种具有代表性的基于统计不确定性的黑盒特征，应用 token 长度作归一化，是黑盒方法中性能较好的方法。

总体而言，上述基线方法覆盖了从 RAG 专用检测、通用内部状态分析，到文本自评估与黑盒统计建模等多种技术路线，因此能够为本文方法的性能评估提供较为充分且具有代表性的参照。

4.3.2 结果分析

本文 SKID 及对比方法在 RAGTruth 与 Dolly 数据集上的实验结果如表 4.2 所示，各项评价指标为百分数，其中的最佳结果以**粗体**展示。

表 4.2 SKID 在 RAGTruth 与 Dolly 数据集上的实验结果

方法	RAGTruth			Dolly		
	AUROC ↑	ACC ↑	F1 ↑	AUROC ↑	ACC ↑	F1 ↑
LN-Entropy	59.12	56.20	68.50	60.74	56.56	62.61
P(True)	70.93	56.48	65.49	61.91	53.44	50.95
SelfCheckGPT	–	58.44	46.42	–	53.00	31.88
EigenScore	60.45	54.22	66,82	67.86	65.96	**72.41**
SAPLMA	71.07	51.55	65.02	65.00	60.84	66.53
ITI	67.14	56.67	64.96	54.94	58.00	62.81
ReDeEP	74.58	68.22	71.90	70.55	67.23	68.03
RAGLens	82.03	71.62	72.45	72.68	69.64	69.66
SKID	**82.21**	**71.68**	**72.48**	**76.00**	**69.70**	69.71

由表 4.2 总体来看，所提方法在两个数据集上均取得了具有竞争力甚至最优的性能，验证了其在 RAG 幻觉检测任务中的有效性。我们将表中数据分析如下：

- 从纵向对比角度分析，与现有各类方法相比，SKID 在核心指标 AUROC 上均取得了最优结果，在 RAGTruth 和 Dolly 数据集上分别达到 82.21% 和 76.00%，相较于当前表现较强的 RAG 专用方法（如 ReDeEP 与 RAGLens）仍有进一步提升。这表明本文方法在不同判别阈值下均具备更稳定、更准确的排序能力，能够更有效

地区分幻觉样本与非幻觉样本。在 ACC 与 F1 指标上，SKID 同样表现出较强竞争力：在 RAGTruth 数据集上取得三项指标的全面最优，在 Dolly 数据集上也基本达到最优水平，与最佳结果差距极小，整体性能保持领先。相比之下，部分通用幻觉检测方法（如 ITI、SAPLMA）以及基于统计特征的方法（如 LN-Entropy）整体表现相对较弱，说明仅依赖模型内部信号或黑盒统计特征，难以充分刻画 RAG 场景下“内外知识冲突”这一关键因素。

- 进一步分析不同类别方法的表现，可以发现 RAG 专用方法（如 ReDeEP 与 RAGLens）整体优于通用幻觉检测方法与黑盒方法，验证了显式建模检索知识的重要性。在此基础上，本文方法通过在稀疏特征空间中进行知识冲突消解建模，相较于 RAGLens 进一步提升了检测性能，说明在高维可解释表征上进行更精细的特征筛选与冲突建模能够带来额外收益。值得注意的是，EigenScore 在 Dolly 数据集上的 F1 指标达到 72.41%，表现突出，但其在 AUROC 与 ACC 指标上相对不稳定，说明其判别能力在不同阈值或不同数据分布下存在一定波动；而本文方法在多个指标上均保持较为均衡的表现，体现出更好的整体稳定性。

- 从横向对比角度来看，SKID 在两个数据集上均取得一致性的优良表现，说明该方法具有较好的跨数据集泛化能力。无论是在以 RAGTruth 为代表的多来源多任务数据集，还是在 Dolly 开放式阅读理解问答的数据分布下，SKID 均能够稳定提升 AUROC 等关键指标，表明其所构建的“稀疏特征 + 知识冲突消解”框架能够有效捕捉 RAG 幻觉的本质特征，而不依赖于特定数据集的分布特性。4.3.3 小节进一步从更多数据集和更多评价指标上验证 SKID 的这一性能特点。

综上所述，实验结果充分表明，本文提出的 SKID 方法在 RAG 幻觉检测任务中相较于现有方法具有更优的检测性能和更稳定的表现，尤其在核心指标 AUROC 上取得了显著提升。同时，其在不同数据集上的一致性优势，也进一步验证了方法设计的合理性与泛化能力。

4.3.3　消融实验

在本小节，我们将进一步在更多评价指标上衡量 SKID 算法的性能；对 RAGTruth 数据集、SKID 算法的各种变体，以及 SKID 方法中的各模块进行详细的消融分析；还将从可解释性分析的角度评价 SKID 算法额外带来的易用性与用户信任度。

更多评价指标与数据集

如 4.3.1 小节中所述，除需在设定阈值下评价分类器性能的 ACC、F1 评价指标外；还有不依赖特定阈值，通过滑动阈值更全面地评价分类器综合表现的 AUROC、FPR95 和 AUPR 评价指标。同时，我们也在额外两个数据集 AggreFact 和 TofuEval 上衡量了

SKID 我们方法的性能。表 4.3 展示了 SKID 方法与对比方法在更多评价指标和数据集上的性能。此外，为更直观地分析不同算法在 RAG 幻觉检测任务中的区分能力，本文额外在两个数据集上，将测试集样本按照参考标签划分为“真实回答”与“幻觉回答”两组，并分别统计各方法在两组样本上的分数分布，如图 4-2 所示，绘制方法与 3.3.2 小节中所述保持一致。

表 4.3 SKID 在更多评价指标与数据集上的实验结果

数据集	方法	AUROC ↑	FPR95 ↓	AUPR ↑	ACC ↑	F1 ↑
RAGTruth	RAGLens	82.03	66.67	68.80	71.62	72.45
	SKID	**82.21**	**63.00**	**69.41**	**71.68**	**72.48**
Dolly	RAGLens	72.68	80.28	73.63	69.64	69.66
	SKID	**76.00**	**63.38**	**76.60**	**69.70**	**69.71**
AggreFact	RAGLens	80.14	**60.10**	58.18	69.45	69.33
	SKID	**82.01**	63.41	**63.75**	**70.33**	**71.65**
TofuEval	RAGLens	73.15	**88.17**	66.35	62.53	62.60
	SKID	**76.09**	89.94	**68.36**	**69.73**	**70.50**

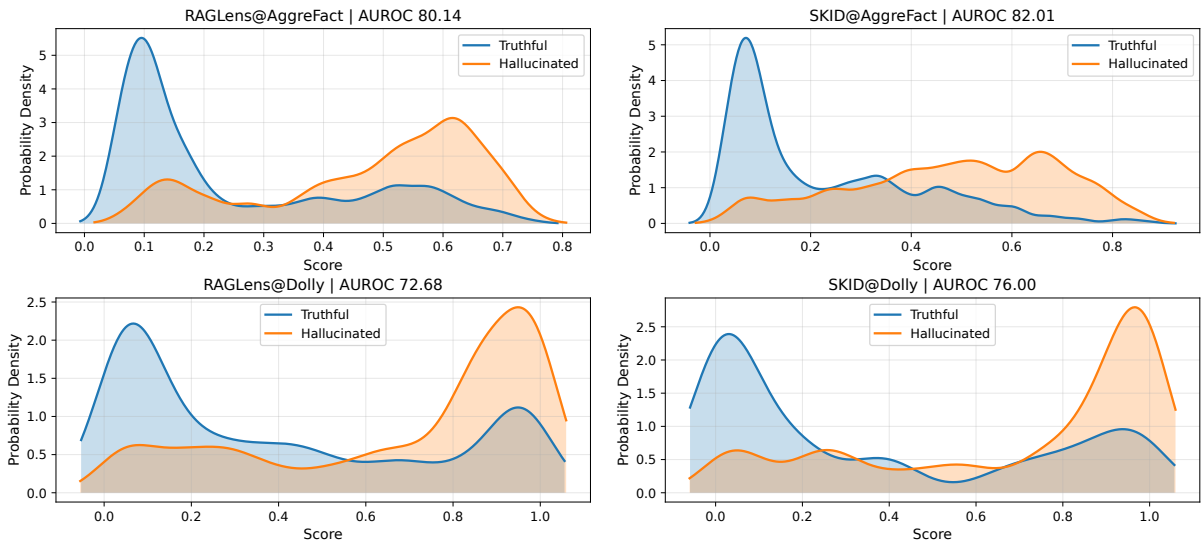

图 4-2 SKID 与 RAGLens 在 AggreFact 与 Dolly 数据集上的幻觉分数分布

从表 4.3 可以看出，在引入更多评价指标与数据集后，SKID 方法依然保持了稳定且优越的整体性能。首先，在 RAGTruth 与 Dolly 两个数据集上，SKID 在 AUROC、AUPR 以及 ACC、F1 等多个指标上均优于 RAGLens，尤其在 FPR95 指标上取得了明显下降，

表明在保证高召回率的同时，误报率得到了有效控制，从而在阈值无关的检测能力上进一步提升。其次，在额外引入的 AggreFact 与 TofuEval 数据集上，SKID 同样在大多数指标上取得最优结果，特别是在 AUROC 与 AUPR 等综合性指标上表现突出，说明本文方法在不同数据分布与任务设置下均具有良好的泛化能力。尽管在 FPR95 指标下的个别情况下未取得最优，但整体趋势依然表明 SKID 在综合性能上优于现有方法。从图 4-2 可以看出，在所示数据集上，SKID 方法在“真实回答”样本上的分数分布明显偏向于较低的分数区间，而在“幻觉回答”样本上的分数分布则明显偏向于较高的分数区间，显示出较好的区分能力，因此在分类任务中获得了更高的 AUROC 得分。相比之下，RAGLens 方法在两类样本上的分数分布重叠区域较多，占据总数据量的比例较大，说明其在所示数据集上的判别能力相对较弱。综上，实验结果进一步验证了本文方法在多指标、多数据集场景下的稳健性与有效性，亦从可视化的角度验证了 SKID 在不同数据集上的稳定优越性能，能够更全面地刻画 RAG 幻觉检测任务中的判别能力。

数据集变体

如 4.3.1 小节中所述，数据集 RAGTruth 包含三个互不包含的子集，其任务类型、涉及领域各不相同。表 4.4 展示了 SKID 方法与对比方法在这三个子集上的具体提升。

表 4.4 SKID 在 RAGTruth 的三个子数据集上的实验结果

数据集	方法	AUROC ↑	FPR95 ↓	AUPR ↑	ACC ↑	F1 ↑
Data2txt	RAGLens	**82.03**	**69.78**	**88.26**	**73.64**	**74.56**
	SKID	80.62	70.40	86.04	73.33	74.37
QA	RAGLens	86.26	57.03	62.99	75.72	75.41
	SKID	**86.49**	**55.68**	**64.88**	**75.87**	**76.18**
Summary	RAGLens	77.55	73.42	53.29	65.04	**66.98**
	SKID	**79.46**	**62.50**	**55.67**	**65.41**	66.45

从表 4.4 可以看出，SKID 在不同子任务上的表现存在一定差异。在 QA 与 Summary 两个子数据集上，SKID 在绝大多数评价指标上均优于 RAGLens，特别是在 AUROC、FPR95 与 AUPR 等关键指标上取得稳定提升，表明本文方法在这两类任务中能够更有效地刻画模型内部知识与外部检索知识之间的冲突关系，从而提升幻觉检测性能。相比之下，在 Data2txt 子数据集上，SKID 整体略逊于 RAGLens，各项指标均出现一定程度下降。

我们猜测，造成上述差异的一个可能原因在于不同子数据集中检索内容与生成输出的表示形式存在显著差异。在 QA 与 Summary 任务中，检索知识与模型输出均以自然语言形式呈现，两者在 token 层面具有较高的一致性与可对齐性。因此，本文在知识冲突

消解步骤中，通过滤除输出中在检索知识中出现过的 token，可以较为准确地去除外部知识成分，从而保留更纯净的内部知识信号（即潜在的幻觉信号），使得后续基于稀疏特征的判别更加有效。然而，在 Data2txt 任务中，检索知识以结构化的 JSON 格式给出，其中包含大量非自然语言符号（如花括号、键值对结构等），且表格内容表达相对简洁，与最终生成的自然语言输出在表面形式上存在较大差异。在这种情况下，基于 token 级匹配的筛除策略难以充分覆盖检索知识对应的语义内容，即使某些信息已经在检索知识中出现，其在 output 中的自然语言表达形式往往不同，导致这些 token 无法被有效删除，从而在保留的特征中仍混入较多外部知识信号成分。换言之，知识冲突消解步骤在该子数据集上存在“删除不干净”的问题，使得后续构建的检测信号不够纯粹，从而影响整体性能表现。

综上所述，实验结果表明，SKID 在自然语言形式一致的 RAG 场景中能够充分发挥其优势，但在检索内容与生成输出存在显著表达差异（如结构化数据到文本生成）的任务中，其基于 token 匹配的冲突消解策略仍存在一定局限性。这一现象也为后续工作提供了改进方向，即探索更加语义层面或结构感知的知识对齐与消解方法，以进一步提升方法在复杂 RAG 场景下的适用性与鲁棒性。

k 值

在 4.2.3 小节中，我们讨论了幻觉指标构建方法，其中包括从高维稀疏特征中选取其中互信息最高的 k 个维度构成关键特征集合。在本实验中，k 值的选取与 SKID 算法的性能存在密切的关系。SKID 算法与对比算法在 RAGTruth 的两个子数据集上的 AUROC 性能随 k 值变化的趋势如图 4-3 所示。

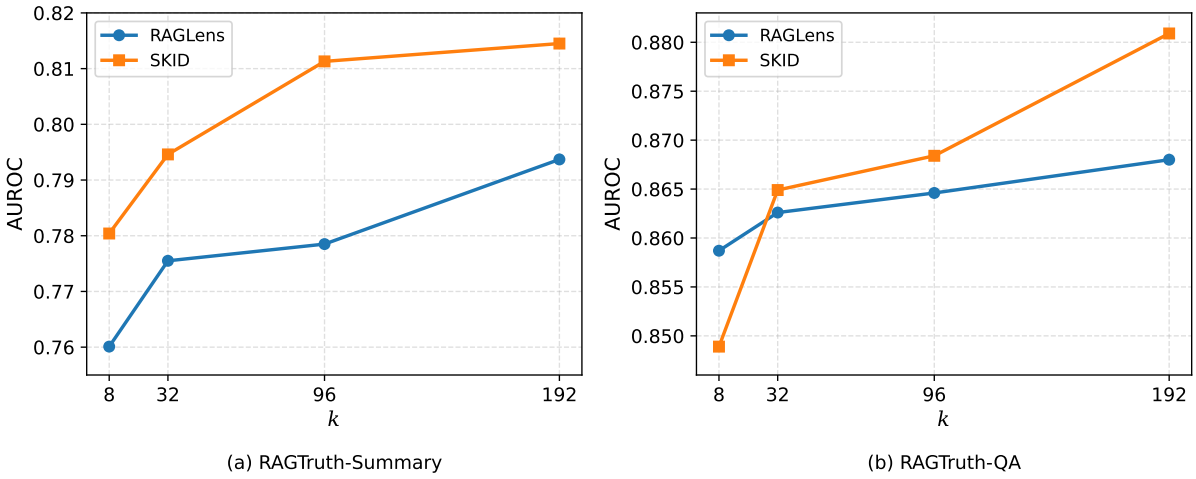

图 4-3 SKID 与对比算法在 RAGTruth 数据集上的 AUROC 性能随 k 值变化图

实验结果表明，在不同 k 值设定下，SKID 算法在 RAGTruth 数据集上的性能会随关键特征维度选择而发生明显变化。随着互信息筛选特征维度数 k 的增大，方法在两个数据集上的 AUROC 整体均呈上升趋势。这与我们的直观感受一致：保留更多高判别性

稀疏特征有助于提升 RAG 幻觉检测性能。过小的 k 值会限制模型对关键知识冲突信号的表征能力，而适当增大 k 能够引入更丰富的判别信息，从而提高检测效果。与此同时，SKID 在大多数 k 取值下均优于 RAGLens，且这种优势在较大 k 时更加明显，表明所提出的检索知识过滤与稀疏特征建模机制能够更充分地挖掘高维判别特征中的有效信息。总体而言，该实验说明方法对 k 具有一定敏感性，但在合理范围内呈现出较稳定的“随 k 增大而持续受益”的趋势，验证了互信息筛选特征维度在 SKID 中的重要作用。

SAE 编码模块与知识冲突消解模块

在 4.2.1 小节中，我们讨论了引入高维稀疏表征的核心目的，在于将原始隐藏状态中高度纠缠的语义信息解耦为更具可解释性的特征单元，也便于后续对特征空间的互信息筛选和广义加性模型训练。在 4.2.2 小节中，我们讨论了知识冲突消解方法的构建，其能显式完成内外知识混合信号的初步解耦，将检测重点集中于更具判别价值的内部知识残差信号之上。表 4.5 直接展示了去除 SAE 编码模块和知识冲突消解模块前后模型的性能变化。其中不使用 SAE 编码模块的实验中，我们直接在对应层的隐藏状态表征（而非经由 SAE 编码的高维稀疏表征）上进行后续步骤，如特征筛选、冲突消解、GAM 训练等。

表 4.5 SKID 的不同模块变体在 TofuEval 数据集上的实验结果

模块变体		AUROC ↑	FPR95 ↓	AUPR ↑	ACC ↑	F1 ↑
SAE 编码	知识冲突消解					
×	×	63.12	88.67	47.86	61.07	61.33
✓	×	73.15	88.17	66.35	62.53	62.60
×	✓	73.93	**84.02**	66.67	65.16	65.65
✓	✓	**76.09**	89.94	**68.36**	**69.73**	**70.50**

从表 4.5 的结果可以看出，引入 SAE 编码模块或知识冲突消解模块均能够在不同程度上提升模型的整体检测性能，二者结合时效果最为显著。

具体而言，在不使用任何模块的基线设置下，模型整体表现最弱，说明直接在原始隐藏状态上进行建模难以有效刻画 RAG 场景下的幻觉信号。当仅引入 SAE 编码模块时，AUROC 与 AUPR 均有显著提升，表明高维稀疏表征能够有效解耦原始隐状态中的纠缠语义信息，从而为后续判别模型提供更加结构化且可分离的特征空间。当仅引入知识冲突消解模块时，模型同样取得明显提升，说明通过显式去除与检索内容重合的 token，可以有效削弱外部知识干扰，使得剩余信号更集中地反映模型内部生成偏差，从而提升幻觉检测的敏感性。

当 SAE 编码与知识冲突消解同时使用时，模型在大多数指标上取得最优结果，整体性能优于任一单独模块。这表明两者之间具有良好的叠加性：SAE 负责提供可解释的

稀疏特征空间，而知识冲突消解则进一步净化该空间中的外部知识干扰，从而共同构建出更加稳定且具有判别性的幻觉检测信号。综上，实验结果验证了本文模块设计的合理性，即稀疏表征学习与知识冲突消解对于提升 RAG 幻觉检测性能均具有关键作用，并且二者的结合能够带来最优的整体效果。

可解释性

如 4.2.3 小节中所述，依据互信息值的大小，我们可以筛选出与幻觉标签相关性最高的 k 个维度。借由 SAE 的表征能力，这些高维表征空间的具体维度，可能具有一定的单义性和可解释性。如下的实验中，我们在 TofuEval 数据集中进一步发掘这 k 维数据，借助大模型强大的文本理解和归纳总结能力，尽可能地探索这些表征幻觉的维度的真实语义。

具体而言，我们设计了一种基于高互信息维度的语义归纳实验流程，以探索 SAE 表征空间中与幻觉行为相关的潜在语义结构。实验流程如下：

- 首先，在通过互信息分析筛选得到的 k 个高相关维度基础上，我们针对每一个维度，选取该维度激活值最高的 d 个样本。这一步确保了所选样本在该维度上具有最显著的表征响应，有助于增强后续语义分析的信号强度。

- 随后，对于每一个高互信息维度，我们将对应筛选出的 d 个样本回溯至其原始输入与模型输出文本，构建得到 k 组样本集合，每组包含 d 个“高响应”实例。通过这种方式，我们将抽象的神经表征维度映射为具体的文本行为集合，从而建立“表征维度—模型行为”的对应关系。

- 在此基础上，我们在线利用 GPT-5.4[3]——当前性能最强的主流商业大模型之一，作为语义归纳器，对每一组包含 d 个样本的文本集合进行统一分析。具体地，我们将同一维度下的 d 个输入-输出对作为整体输入提示给大模型，并要求其总结这些回答是否存在共性特征，例如是否倾向于产生事实性错误、是否表现出过度推测、是否存在知识幻觉倾向等。通过这种方式，我们能够从数据驱动的角度，对每个高互信息维度所编码的行为模式进行归纳式解释。

通过上述实验，我们对 k 个维度分别获得其对应的语义总结结果，从而构建“维度—幻觉行为描述”的映射表。该映射关系有助于我们进一步理解 SAE 中不同稀疏特征在幻觉检测任务中的功能分工，并为后续基于可解释特征的检测方法设计提供依据。实验结果如表 4.6 所示。在实验中，我们选取 $k = 5$，$d = 10$ 进行实验，其他设定与表 4.3 所示的实验设置一致。

从表 4.6 可以看出，基于 SAE 提取的高互信息稀疏维度并非仅仅对应某种模糊的“高分辨信号”，而是能够稳定地指向若干具有明确语义边界的幻觉模式，这充分体现

[3]https://openai.com/zh-Hans-CN/index/introducing-gpt-5-4/

表 4.6 SKID 在 TofuEval 上的可解释性分析

维度序号	互信息	幻觉类型	具体解释
119,691	0.1095	解释性补全	将原文里模糊、残缺、未言尽的内容，自动补成完整的因果链、后果链和价值判断
127,083	0.1082	细节性补全	在原文只提到“申请/讨论/审议”时，补出具体条款、限制条件、实施细节、作用效果
94,462	0.1068	具体事实补写	将未提及的具体人名、地点、投票结果、身份、条件直接写为确定事实
10,418	0.1002	议题混入	仍然围绕当前主议题，但混入其他相近政策、法案、提案或背景内容
79,300	0.0983	整体议题错配	未围绕当前议题，输出几乎全文与输入所讨论议题完全无关

了 SAE 表征在可解释性上的显著优势。具体而言，不同高互信息维度所对应的样本集合并未呈现出杂乱无章的分布，而是分别集中于“解释性补全”“议题混入”以及“整体议题错配”等具有较强一致性的行为类型。这说明，SAE 所学习到的稀疏特征在一定程度上将原本纠缠于隐藏状态中的多种错误模式解耦为相对独立的语义单元。换言之，SKID 最终用于判别的并不是难以理解的黑盒分数，而是一组能够被自然语言刻画、并可对应到具体文本行为的稀疏特征，这使得模型具备了较强的事后解释能力。

进一步地，上述结果也从侧面验证了本文设计中引入 SAE 模块的必要性。若直接在原始稠密隐藏状态上进行分析，不同语义因素往往高度耦合，单个维度通常难以对应稳定而清晰的行为模式；而经过 SAE 映射后，特征空间中的部分维度能够被赋予更强的单义性，从而使“高响应样本检索—共性行为归纳—幻觉类型命名”这一分析链条成为可能。尤其值得注意的是，这些被识别出的维度不仅能够区分“是否幻觉”，还能够进一步揭示“幻觉是以何种形式发生的”。这意味着 SKID 的优势不仅体现在检测性能上，还体现在其能够提供更细粒度的错误结构认知，可能为后续的幻觉归因、风险分析以及定向纠正提供了可操作的依据。

总体而言，该实验表明，SAE 为 SKID 带来的并非简单的特征压缩或维度变换，而是一种更具语义可读性的表征重构机制。借助这一机制，模型内部原本难以直接理解的激活模式被转化为具有可命名、可归纳、可分析特性的稀疏特征，从而显著增强方法在实际应用中的易用性和用户信任度。这种“检测性能与语义可解释性并重”的特性，也正是 SKID 相较于传统黑盒判别方法的重要优势之一。

4.4 本章小结

本章围绕大语言模型 RAG 幻觉检测问题，在明确任务设定的基础上，提出了基于检索知识冲突消解的 SKID 方法。该方法首先借由稀疏自编码器将大模型特定层的隐式表征映射到高维系数空间，以将原始隐藏状态中高度纠缠的语义信息解耦为更具可解释性的特征单元；随后筛选滤除输出文本中已于检索知识中出现过的 token，以解耦内外知识混合信号，将检测重点集中于更具判别价值的内部知识残差信号之上；最终，从特征维度基于互信息指标筛选出最具幻觉表征能力的少部分特征，训练广义加性分类器，得到最终的幻觉检测信号。

实验结果表明，SKID 在多个数据集和多种评价指标上均具有良好的竞争力，整体优于多种类型的基线方法。更多消融实验则进一步证明了 SKID 算法在更多数据集变体、评价指标上的稳定性能，各模块步骤的设置合理性，以及优越的可解释性。综合来看，本章方法在无需任何额外计算量的情况下提升了 RAG 幻觉检测的性能，充分利用外部检索知识消解了知识冲突，为后续相关研究提供了坚实的方法基础。

第五章 总结与展望

5.1 本文总结

随着大语言模型在智能问答、知识检索、文本生成等场景中的广泛应用，模型生成内容的真实性、可靠性与可解释性问题日益突出。幻觉现象作为制约大语言模型安全落地的重要因素，已经成为当前生成式人工智能研究中的关键问题。因此，围绕大语言模型幻觉检测问题，探索能够充分利用模型内部表征、兼顾检测性能与方法可解释性的检测技术，具有重要的理论意义与应用价值。本文围绕“基于内部表征的大语言模型幻觉检测方法研究”这一主题，从通用幻觉检测与 RAG 幻觉检测两个方向展开研究，针对现有方法在内部表征利用不充分、外部知识信号建模不足等问题，提出了两种具有针对性的幻觉检测方法。

针对通用幻觉检测任务，本文提出了一种基于多方向表征建模的幻觉检测方法 ATScore。该方法从大语言模型生成过程中的内部隐藏状态出发，构建统一的三维激活张量表示，并分别从 layer 方向与 token 方向对内部表征进行链式建模，在此基础上进一步提取链长度、转折角度等几何统计特征，构造无需额外训练的白盒幻觉检测信号。与现有多数仅沿单一方向、仅利用局部静态表示的内部表征方法相比，ATScore 能够在更统一的视角下刻画大模型内部状态的动态演化结构，更充分地挖掘与幻觉相关的异常模式。实验结果表明，ATScore 在多个公开数据集和多种评价指标上均取得了良好的检测效果，整体优于多种黑盒与白盒基线方法，表现出较强的稳定性与跨场景适用性。同时，消融实验进一步验证了多方向建模策略以及不同聚合方式对检测性能的影响，说明从内部表征演化轨迹中提取几何特征是一种有效且具有普适性的幻觉检测思路。

针对 RAG 幻觉检测任务，本文提出了一种基于检索知识冲突消解的幻觉检测方法 SKID。该方法立足于 RAG 场景中“模型内部知识—外部检索知识”并存且可能发生冲突的基本特点，从大语言模型内部表征出发，首先借助稀疏自编码器将原始隐藏状态映射到高维稀疏特征空间，以获得更具可解释性的语义表征；随后通过互信息筛选获得与幻觉判别最相关的稀疏特征维度，并进一步结合检索文档对输出内容进行 token 级过滤，尽可能滤除受外部知识直接支持的生成成分，将检测重点集中于更能反映内部知识偏差的残差信号之上；最后使用可解释的广义加性模型对冲突信号进行建模，实现对 RAG 幻觉的有效检测。实验结果表明，SKID 在多个 RAG 数据集和多种评价指标上均具有较好的竞争力，整体优于多类基线方法。进一步的分析还表明，SKID 不仅能够提升 RAG 幻觉检测性能，而且能够通过稀疏特征的语义归纳揭示“模型为何被判定为产生幻觉”，从而在检测准确性与结果可解释性之间取得较好的统一。

总体来看，本文的两项研究工作在研究目标与技术路线方面具有清晰的递进关系。

ATScore 面向通用幻觉检测场景，重点解决现有方法对大模型内部表征利用不充分的问题，建立了从内部激活结构中挖掘幻觉信号的基本分析框架；SKID 则进一步面向 RAG 幻觉检测场景，在继承内部表征分析思路的基础上，将外部检索知识显式纳入检测过程，通过冲突消解机制对内部知识与外部知识之间的关系进行建模，并进一步提升方法的可解释性。二者共同构成了一个从一般生成场景到检索增强生成场景、从内部动态建模到内外知识关系建模逐步推进的研究体系。

综上所述，本文围绕大语言模型幻觉检测问题，针对不同应用场景下的关键挑战，提出了两种基于内部表征的检测方法，并通过系统实验验证了其有效性、稳定性与一定的通用性。本文的研究工作表明，大语言模型内部表征中蕴含着丰富而可利用的幻觉判别信息；与此同时，在 RAG 场景下，若能进一步结合外部检索知识对内部表征进行冲突分析，则能够更准确地识别复杂生成条件下的幻觉行为。本文的研究不仅为后续大语言模型幻觉检测方法的设计提供了新的思路，也为构建更加安全、可信、可解释的大语言模型应用系统提供了有价值的方法支撑。

5.2 未来展望

尽管本文围绕通用幻觉检测与 RAG 幻觉检测两个方向进行了较为系统的研究，并取得了一定成果，但大语言模型幻觉问题本身仍具有高度复杂性与开放性，相关研究远未结束。随着模型规模、应用场景与外部工具使用方式的不断扩展，未来在幻觉检测领域仍有许多值得进一步深入探索的问题。结合本文已有工作，未来可从以下几个方面展开进一步研究。

首先，在通用幻觉检测方向上，仍可进一步提升对内部表征动态结构的建模能力。本文提出的 ATScore 方法主要从 layer 方向与 token 方向分别构造链式表征，并通过几何统计量刻画隐藏状态的演化特征。这一思路验证了内部表征动态变化中确实蕴含有价值的幻觉信号，但当前所使用的几何特征仍相对基础，主要集中于链长度、转折角度等较低阶统计信息。未来可以考虑从更丰富的链式表示出发，引入更加细粒度的动力学描述方式，例如局部波动模式、多尺度变化趋势、不同层级间的协同演化关系等，以进一步刻画模型在生成正确内容与生成幻觉内容时内部状态变化机制的差异。此外，当前方法主要在单模型、单次生成的设定下进行分析，未来还可以进一步探索其在跨模型迁移、跨任务泛化以及更复杂生成场景中的适用性，从而增强方法的普适性与鲁棒性。

其次，在 RAG 幻觉检测方向上，如何更精细地建模内部知识与外部检索知识之间的关系，仍然是一个值得持续深入的问题。本文提出的 SKID 方法通过过滤检索文档中已出现的 token，并聚焦未被外部知识直接支持的生成片段，实现了对内外知识冲突的初步刻画。这种思路具有较好的直观性与有效性，但从更一般的角度来看，模型生成内容与检索知识之间的关系并不总是简单的“出现”或“未出现”关系。未来可以进一步考虑从事实蕴含、表征维度以及知识粒度对齐等更细致的层面，对外部知识支持关系进行建模。例如，某些生成内容虽然在表面 token 层面未直接出现在检索文档中，但其语

义上可能仍受到检索证据支持；相反，也存在表面形式重合但事实关系发生偏移的情况。因此，如何由浅层的 token 匹配进一步走向更深层的语义冲突分析，是未来提升 RAG 幻觉检测准确性的重要方向。

综上所述，本文的研究工作为基于内部表征的大语言模型幻觉检测提供了有益探索，但无论是内部动态表征的深层建模、RAG 场景下内外知识关系的细粒度刻画，还是检测结果的解释能力、在线反馈能力与系统化部署能力，仍然存在广阔的研究空间。未来，随着大语言模型能力的持续提升以及应用场景的不断拓展，面向高可靠性、高实用性与高可解释性的幻觉检测技术将具有更加重要的研究意义与应用价值。

致　谢

致谢！

参考文献

[1] ZHAO W X, ZHOU K, LI J, et al. A survey of large language models[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2303.18223, 2026.

[2] MINAEE S, MIKOLOV T, NIKZAD N, et al. Large language models: A survey[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2402.06196, 2025.

[3] MIN B, ROSS H, SULEM E, et al. Recent advances in natural language processing via large pre-trained language models: A survey[J]. ACM Computing Surveys, 2023, 56(2): 1-40.

[4] RADFORD A, NARASIMHAN K, SALIMANS T, et al. Improving language understanding by generative pre-training[DB/OL]. [2026-03-17]. https://api.semanticscholar.org/CorpusID:49313245, 2018.

[5] RADFORD A, WU J, CHILD R, et al. Language models are unsupervised multitask learners[DB/OL]. [2026-03-30]. https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf, 2019.

[6] BROWN T, MANN B, RYDER N, et al. Language models are few-shot learners[C]. Advances in Neural Information Processing Systems. Curran Associates, Inc., 2020. 1877-1901.

[7] ACHIAM J, ADLER S, AGARWAL S, et al. Gpt-4 technical report[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2303.08774, 2024.

[8] TOUVRON H, LAVRIL T, IZACARD G, et al. Llama: Open and efficient foundation language models[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2302.13971, 2023.

[9] TOUVRON H, MARTIN L, STONE K, et al. Llama 2: Open foundation and fine-tuned chat models[DB/OL]. [2026-03-26]. https://arxiv.org/abs/2307.09288, 2023.

[10] GRATTAFIORI A, DUBEY A, JAUHRI A, et al. The llama 3 herd of models[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2407.21783, 2024.

[11] BAI J, BAI S, CHU Y, et al. Qwen technical report[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2309.16609, 2023.

[12] YANG A, LI A, YANG B, et al. Qwen3 technical report[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2505.09388, 2025.

[13] HUANG L, YU W, MA W, et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions[J]. ACM Transactions on Information Systems, 2025, 43(2):1-55.

[14] JI Z, LEE N, FRIESKE R, et al. Survey of hallucination in natural language generation [J]. ACM computing surveys, 2023, 55(12):1-38.

[15] GENG J, CAI F, WANG Y, et al. A survey of confidence estimation and calibration in large language models[C]. Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). Association for Computational Linguistics, 2024. 6577-6595.

[16] LUO J, LI T, WU D, et al. Hallucination detection and hallucination mitigation: An investigation[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2401.08358, 2024.

[17] GAO Y, XIONG Y, GAO X, et al. Retrieval-augmented generation for large language models: A survey[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2312.10997, 2024.

[18] HUANG Y, HUANG J. A survey on retrieval-augmented text generation for large language models[DB/OL]. [2026-03-30]. https://arxiv.org/abs/2404.10981, 2024.

[19] WU S, XIONG Y, CUI Y, et al. Retrieval-augmented generation for natural language processing: A survey[DB/OL]. [2026-03-30]. https://arxiv.org/abs/2407.13193, 2025.

[20] SKEAN O, AREFIN M R, ZHAO D, et al. Layer by layer: Uncovering hidden representations in language models[C]. Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025. 55854-55875.

[21] LAPTEV D, BALAGANSKY N, AKSENOV Y, et al. Analyze feature flow to enhance interpretation and steering in language models[C]. Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025. 32593-32616.

[22] LIN C Y. Rouge: A package for automatic evaluation of summaries[C]. Text Summarization Branches Out. Association for Computational Linguistics, 2004. 74-81.

[23] MANAKUL P, LIUSIE A, GALES M. Selfcheckgpt: Zero-resource black-box hallucination detection for generative large language models[C]. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2023. 9004-9017.

[24] SRIRAMANAN G, BHARTI S, SADASIVAN V S, et al. Llm-check: Investigating detection of hallucinations in large language models[C]. Advances in Neural Information Processing Systems. Curran Associates, Inc., 2024. 34188-34216.

[25] ABDALJALIL S, SHARMA P, KURBAN H, et al. Scalable and enhanced hallucination detection in llms using semantic clustering[DB/OL]. [2026-03-17]. https://openreview.net/forum?id=GXzwq6waYb, 2024.

[26] LONG Y, WU X, ZHANG Y, et al. Copy-paste to mitigate large language model hallucinations[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2510.00508, 2026.

[27] LIN S, HILTON J, EVANS O. Teaching models to express their uncertainty in words[J]. Transactions on Machine Learning Research, 2022.

[28] CHEN C, LIU K, CHEN Z, et al. Inside: Llms' internal states retain the power of hallucination detection[C]. The Twelfth International Conference on Learning Representations. OpenReview.net, 2024. 3056-3076.

[29] LIU L, POURREZA R, PANCHAL S, et al. Enhancing hallucination detection with noise injection[DB/OL]. [2026-03-17]. https://openreview.net/forum?id=2bWf4M5tRo, 2025.

[30] KUHN L, GAL Y, FARQUHAR S. Semantic uncertainty: Linguistic invariances for uncertainty estimation in natural language generation[C]. The Eleventh International Conference on Learning Representations. OpenReview.net, 2023. 29857-29875.

[31] LI K, PATEL O, VIÉGAS F, et al. Inference-time intervention: Eliciting truthful answers from a language model[C]. Advances in Neural Information Processing Systems. Curran Associates, Inc., 2023. 41451-41530.

[32] AZARIA A, MITCHELL T. The internal state of an llm knows when it's lying[C]. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2023. 967-976.

[33] DU X, XIAO C, LI Y. Haloscope: Harnessing unlabeled llm generations for hallucination detection[C]. Advances in Neural Information Processing Systems. Curran Associates, Inc., 2024. 102948-102972.

[34] BURNS C, YE H, KLEIN D, et al. Discovering latent knowledge in language models without supervision[C]. The Eleventh International Conference on Learning Representations. OpenReview.net, 2023. 18404-18431.

[35] WANG Y, ZHANG P, YANG B, et al. Latent space chain-of-embedding enables output-free llm self-evaluation[C]. The Thirteenth International Conference on Learning Representations. OpenReview.net, 2025. 50130-50162.

[36] BAR-SHALOM G, FRASCA F, GALRON Y, et al. Beyond token probes: Hallucination detection via activation tensors with act-vit[C]. Advances in Neural Information Processing Systems. Curran Associates, Inc., 2025.

[37] NIU M, HADDADI H, PANG G. Robust hallucination detection in llms via adaptive token selection.(2025)[C]. Advances in Neural Information Processing Systems. Curran Associates, Inc., 2025.

[38] SUN Z, ZANG X, ZHENG K, et al. Redeep: Detecting hallucination in retrieval-augmented generation via mechanistic interpretability[C]. The Thirteenth International Conference on Learning Representations. OpenReview.net, 2025. 102578-102607.

[39] HU H, HE C, XIE X, et al. Lrp4rag: Detecting hallucinations in retrieval-augmented generation via layer-wise relevance propagation[DB/OL]. [2026-03-30]. https://arxiv.org/abs/2408.15533, 2025.

[40] YEH S, LI S, MALLICK T. Lumina: Detecting hallucinations in rag system with context-knowledge signals[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2509.21875, 2025.

[41] SHU D, WU X, ZHAO H, et al. A survey on sparse autoencoders: Interpreting the internal mechanisms of large language models[C]. Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2025. 1690-1712.

[42] CUNNINGHAM H, EWART A, RIGGS L, et al. Sparse autoencoders find highly interpretable features in language models[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2309.08600, 2023.

[43] XIONG G, HE Z, LIU B, et al. Toward faithful retrieval-augmented generation with sparse autoencoders[DB/OL]. [2026-03-17]. https://arxiv.org/abs/2512.08892, 2025.

[44] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems. Curran Associates, Inc., 2017.

[45] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]. Proceedings of the 2019 conference of the North

American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). Association for Computational Linguistics, 2019. 4171-4186.

[46] WOLFE C. Decoder-only transformers: The workhorse of generative llms, building the world's most influential neural network architecture from scratch...[DB/OL]. [2026-03-30]. https://cameronrwolfe.substack.com/p/decoder-only-transformers-the-workhorse, 2024.

[47] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks[C]. Advances in Neural Information Processing Systems. Curran Associates, Inc., 2020. 9459-9474.

[48] BORGEAUD S, MENSCH A, HOFFMANN J, et al. Improving language models by retrieving from trillions of tokens[C]. Proceedings of the 39th International Conference on Machine Learning. PMLR, 2022. 2206-2240.

[49] LAZARIDOU A, GRIBOVSKAYA E, STOKOWIEC W, et al. Internet-augmented language models through few-shot prompting for open-domain question answering[DB/OL]. [2026-03-30]. https://arxiv.org/abs/2203.05115, 2022.

[50] NG A, et al. Sparse autoencoder[DB/OL]. [2026-03-30]. https://graphics.stanford.edu/courses/cs233-21-spring/ReferencedPapers/SAE.pdf, 2011.

[51] BRICKEN T, TEMPLETON A, BATSON J, et al. Towards monosemanticity: Decomposing language models with dictionary learning[DB/OL]. [2026-03-30]. https://transformer-circuits.pub/2023/monosemantic-features/index.html, 2023.

[52] HUBEN R, CUNNINGHAM H, SMITH L R, et al. Sparse autoencoders find highly interpretable features in language models[C]. The Twelfth International Conference on Learning Representations. OpenReview.net, 2024. 39435-39453.

[53] XU R, QI Z, GUO Z, et al. Knowledge conflicts for llms: A survey[C]. Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2024. 8541-8565.

[54] LI G, CHEN Y, TONG H. Taming knowledge conflicts in language models[C]. Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025. 34074-34104.

[55] LONGPRE S, PERISETLA K, CHEN A, et al. Entity-based knowledge conflicts in question answering[C]. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2021. 7052-7063.

[56] MENG K, SHARMA A S, ANDONIAN A J, et al. Mass-editing memory in a transformer[C]. The Eleventh International Conference on Learning Representations. OpenReview.net, 2023. 8694-8714.

[57] FANG J, JIANG H, WANG K, et al. Alphaedit: Null-space constrained knowledge editing for language models[C]. The Thirteenth International Conference on Learning Representations. OpenReview.net, 2025. 43287-43317.

[58] BAI Z, WANG P, XIAO T, et al. Hallucination of multimodal large language models: A survey[DB/OL]. [2026-03-30]. https://arxiv.org/abs/2404.18930, 2025.

[59] HUO F, XU W, ZHANG Z, et al. Self-introspective decoding: Alleviating hallucinations for large vision-language models[C]. The Thirteenth International Conference on Learning Representations. OpenReview.net, 2025. 75182-75205.

[60] LIU S, YE H, ZOU J. Reducing hallucinations in large vision-language models via latent space steering[C]. The Thirteenth International Conference on Learning Representations. OpenReview.net, 2025. 54333-54350.

[61] YANG T, LI Z, CAO J, et al. Understanding and mitigating hallucination in large vision-language models via modular attribution and intervention[C]. The Thirteenth International Conference on Learning Representations. OpenReview.net, 2025. 22541-22563.

[62] WANG C, CHEN X, ZHANG N, et al. Mllm can see? dynamic correction decoding for hallucination mitigation[C]. The Thirteenth International Conference on Learning Representations. OpenReview.net, 2025. 8811-8835.

[63] PAPINENI K, ROUKOS S, WARD T, et al. Bleu: a method for automatic evaluation of machine translation[C]. Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2002. 311-318.

[64] ZHANG T, KISHORE V, WU F, et al. Bertscore: Evaluating text generation with bert [C]. The Eighth International Conference on Learning Representations. OpenReview.net, 2020. 5333-5375.

[65] COBBE K, KOSARAJU V, BAVARIAN M, et al. Training verifiers to solve math word problems[DB/OL]. [2026-03-24]. https://arxiv.org/abs/2110.14168, 2021.

[66] SHI F, SUZGUN M, FREITAG M, et al. Language models are multilingual chain-of-thought reasoners[DB/OL]. [2026-03-24]. https://arxiv.org/abs/2210.03057, 2022.

[67] TALMOR A, HERZIG J, LOURIE N, et al. Commonsenseqa: A question answering challenge targeting commonsense knowledge[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Association for Computational Linguistics, 2019. 4149-4158.

[68] CHEN W, YIN M, KU M, et al. Theoremqa: A theorem-driven question answering dataset [C]. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2023. 7889-7901.

[69] LIN S, HILTON J, EVANS O. Truthfulqa: Measuring how models mimic human falsehoods[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2022. 3214-3252.

[70] BANDARKAR L, LIANG D, MULLER B, et al. The belebele benchmark: a parallel reading comprehension dataset in 122 language variants[C]. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2024. 749-775.

[71] LIU W, LIN R, LIU Z, et al. Learning with hyperspherical uniformity[C]. Proceedings of The 24th International Conference on Artificial Intelligence and Statistics. PMLR, 2021. 1180-1188.

[72] WANG R, WEI Z, YUE G, et al. Revisiting hallucination detection with effective rank-based uncertainty[DB/OL]. [2026-03-24]. https://arxiv.org/abs/2510.08389, 2025.

[73] NIU C, WU Y, ZHU J, et al. Ragtruth: A hallucination corpus for developing trustworthy retrieval-augmented language models[C]. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2024. 10862-10878.

[74] HU X, RU D, QIU L, et al. Refchecker: Reference-based fine-grained hallucination checker and benchmark for large language models[DB/OL]. [2026-03-26]. https://arxiv.org/abs/2405.14486, 2024.

[75] CONOVER M, HAYES M, MATHUR A, et al. Free dolly: Introducing the world's first truly open instruction-tuned llm[DB/OL]. [2026-03-26]. https://www.databricks.com/blog/2023/04/12/dolly-first-open-commercially-viable-instruction-tuned-llm, 2023.

[76] TANG L, GOYAL T, FABBRI A, et al. Understanding factual errors in summarization: Errors, summarizers, datasets, error detectors[C]. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2023. 11626-11644.

[77] ZHAO Y, DEVOTO A, HONG G, et al. Steering knowledge selection behaviours in LLMs via SAE-based representation engineering[C]. Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). Association for Computational Linguistics, 2025. 5117-5136.

[78] KADAVATH S, CONERLY T, ASKELL A, et al. Language models (mostly) know what they know[DB/OL]. [2026-03-26]. https://arxiv.org/abs/2207.05221, 2022.

[79] MALININ A, GALES M. Uncertainty estimation in autoregressive structured prediction [C]. The Ninth International Conference on Learning Representations. OpenReview.net, 2021. 9773-9803.

心求至善

SOUTHEAST UNIVERSITY